

Wpływ kompresji obrazu na skuteczność modeli głębokiego uczenia w diagnostyce kardiologicznej

1 Wstęp

Obrazowanie medyczne stanowi fundament współczesnej diagnostyki kardiologicznej. Wraz ze wzrostem liczby wykonywanych badań oraz rozdzielczości obrazów, rośnie zapotrzebowanie na efektywne metody przechowywania i przesyłania danych. Kompresja obrazu jest powszechnie stosowanym rozwiązaniem tego problemu, jednak jej wpływ na skuteczność automatycznych systemów diagnostycznych opartych na głębokim uczeniu pozostaje niedostatecznie zbadany.

W niniejszej pracy zbadano wpływ trzech formatów kompresji – JPEG, JPEG2000 oraz AVIF – na dokładność modeli klasyfikacji segmentów tętnic wieńcowych w obrazach angiografii rentgenowskiej. Przeprowadzono dwa komplementarne eksperymenty: trening na danych skompresowanych z ewaluacją na oryginałach (Eksperyment A) oraz trening na oryginałach z ewaluacją na danych skompresowanych (Eksperyment B). Badania wykonano na zbiorze danych ARCADE zawierającym 3000 ekspertowo zanotowanych obrazów.

2 Motywacja i kontekst pracy

Systemy archiwizacji obrazów medycznych (PACS – *Picture Archiving and Communication System*) oraz platformy telemedyczne wymagają kompresji danych w celu redukcji kosztów przechowywania i przyspieszenia transmisji. Standard DICOM (*Digital Imaging and Communications in Medicine*) dopuszcza stosowanie kompresji stratnej, w tym formatu JPEG2000, jednakże brak jest jednoznacznych wytycznych dotyczących dopuszczalnego poziomu kompresji w kontekście automatycznej analizy AI.

Jednocześnie modele głębokiego uczenia coraz częściej wspomagają diagnostykę chorób tętnic wieńcowych (CAD – *Coronary Artery Disease*), które pozostają główną przyczyną zgonów na świecie. Angiografia rentgenowska jest złotym standardem w diagnostyce CAD, a automatyczna klasyfikacja segmentów naczyniowych według schematu SYNTAX Score umożliwia obiektywną ocenę stopnia zaawansowania choroby.

Pojawienie się nowoczesnego formatu AVIF (opartego na kodeku AV1, 2019) otwiera nowe możliwości kompresji, lecz jego przydatność w obrazowaniu medycznym nie została dotychczas zbadana. Niniejsza praca wypełnia tę lukę, oferując pierwsze kompleksowe porównanie trzech formatów kompresji w kontekście ich wpływu na modele AI stosowane w kardiologii.

3 Cele i założenia

3.1 Cel główny

Określenie wpływu kompresji stratnej obrazów angiografii rentgenowskiej na skuteczność modeli głębokiego uczenia w zadaniu klasyfikacji segmentów tętnic wieńcowych.

3.2 Cele szczegółowe

1. Porównanie trzech formatów kompresji (JPEG, JPEG2000, AVIF) pod kątem jakości obrazu mierzonej wskaźnikami PSNR i SSIM.
2. Zbadanie wpływu kompresji danych treningowych na dokładność modelu (Eksperyment A).
3. Zbadanie odporności modelu wytrenowanego na danych oryginalnych na kompresję danych wejściowych (Eksperyment B).
4. Wyznaczenie optymalnego poziomu kompresji zapewniającego maksymalną redukcję rozmiaru przy minimalnej utracie dokładności klasyfikacji.
5. Sformułowanie rekomendacji dla systemów PACS i platform telemedycznych.

3.3 Hipoteza

Postawiono następujące hipotezy badawcze:

- H1: Format JPEG2000, będący standardem DICOM, zapewnia lepszą zachowanie skuteczności modeli AI niż klasyczny JPEG przy porównywalnym stopniu kompresji.
- H2: Format AVIF umożliwia osiągnięcie wyższego stopnia kompresji niż JPEG i JPEG2000 przy zachowaniu porównywalnej skuteczności modeli.
- H3: Istnieje progowy poziom kompresji, poniżej którego następuje gwałtowny spadek dokładności klasyfikacji, niezależnie od zastosowanego formatu.

4 Zawartość pracy

Praca składa się z następujących rozdziałów. W rozdziale 5 przedstawiono przegląd literatury dotyczącej kompresji obrazów medycznych oraz zastosowań głębokiego uczenia w angiografii wieńcowej. Rozdział 6 zawiera opis zastosowanych metod, modeli i mierników skuteczności. W rozdziale 7 opisano przebieg eksperymentów, strukturę danych oraz kolejne etapy badania. Rozdział 8 prezentuje uzyskane wyniki w formie tabel i wykresów wraz z ich interpretacją. W rozdziale 9 sformułowano wnioski, a w rozdziale 10 dokonano podsumowania pracy.

5 Przegląd literatury

5.1 Kompresja obrazów medycznych

Kompresja obrazów medycznych jest przedmiotem badań od lat 90. XX wieku. Wyróżnia się kompresję bezstratną (zachowującą pełną informację) oraz stratną (wprowadzającą nieodwracalne zmiany). W systemach PACS powszechnie stosowany jest format JPEG2000, który w roku 2003 został włączony do standardu DICOM jako preferowany format kompresji stratnej [5].

Format JPEG (Joint Photographic Experts Group) wykorzystuje dyskretną transformę kosinusową (DCT) operującą na blokach 8×8 pikseli, co przy niskich poziomach jakości prowadzi do charakterystycznych artefaktów blokowych. Format JPEG2000 stosuje transformę falkową (DWT – *Discrete Wavelet Transform*), eliminując artefakty blokowe i zapewniając lepszą jakość przy niższych przepływnościach [8].

AVIF (*AV1 Image File Format*) jest nowoczesnym formatem kompresji obrazu, opartym na kodeku wideo AV1, opublikowanym w 2019 roku. Wykorzystuje zaawansowane techniki predykcji wewnątrzramkowej i transformaty, oferując znacząco lepszą efektywność kompresji w porównaniu z formatami poprzedniej generacji [1].

5.2 Zbiór danych ARCADE

ARCADE (*Automatic Region-based Coronary Artery Disease diagnostics using x-ray angiography images*) jest publicznie dostępnym zbiorem danych opublikowanym w ramach wyzwania MICCAI 2023. Zbiór zawiera 3000 ekspertowo zanotowanych obrazów angiografii rentgenowskiej podzielonych na dwa podzbiory: 1500 obrazów do klasyfikacji segmentów naczyniowych według schematu SYNTAX Score (26 klas) oraz 1500 obrazów do detekcji zwężeń [6].

5.3 Zastosowania głębokiego uczenia w angiografii wieńcowej

W ostatnich latach opublikowano szereg prac wykorzystujących zbiór ARCADE do różnych zadań diagnostycznych. Framework LASF oparty na YOLOv8 osiągnął wysoką skuteczność w segmentacji naczyń wieńcowych, przewyższając architektury U-Net i DeepLabV3Plus [7]. Badanie porównawcze architektur detekcji obiektów (Grounding DINO, YOLO, DINO-DETR) wykazało zróżnicowaną skuteczność w detekcji zwężeń [2]. Model UCNNet oparty na warunkowej sieci generatywnej (cGAN) osiągnął średni F1 score 84,43% w klasyfikacji 20 segmentów tętnic wieńcowych [10]. Zastosowanie grafowych sieci konwoacyjnych do reprezentacji struktury drzewa wieńcowego pozwoliło na osiągnięcie F1 score 53,68 [3].

Żadna z dotychczasowych prac nie badała jednak wpływu kompresji obrazu na skuteczność modeli klasyfikacji w angiografii wieńcowej, co stanowi istotną lukę badawczą.

6 Materiały i metody

6.1 Formaty kompresji

6.1.1 JPEG

Format JPEG wykorzystuje dyskretną transformatę kosinusową (DCT) stosowaną na blokach 8×8 pikseli. Współczynniki DCT podlegają kwantyzacji sterowanej parametrem jakości $Q \in [1, 100]$, gdzie wyższe wartości oznaczają mniejszą stratę informacji. Przy niskich wartościach Q pojawiają się charakterystyczne artefakty blokowe na granicach bloków.

6.1.2 JPEG2000

Format JPEG2000 wykorzystuje dyskretną transformatę falkową (DWT), operującą na całym obrazie zamiast na blokach. Eliminuje to artefakty blokowe i umożliwia progresywną dekompresję. W standardzie DICOM jest rekomendowanym formatem kompresji stratnej dla obrazów medycznych.

6.1.3 AVIF

Format AVIF bazuje na kodeku wideo AV1, wykorzystując zaawansowane techniki predykcji wewnątrzramkowej z blokami o zmiennym rozmiarze (od 4×4 do 64×64 pikseli). Oferuje znacząco lepszą efektywność kompresji w porównaniu z formatami poprzedniej generacji.

6.2 Mierniki jakości obrazu

6.2.1 PSNR (Peak Signal-to-Noise Ratio)

Szczytowy stosunek sygnału do szumu wyrażony w decybelach:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{\text{MSE}} \right) \quad (1)$$

gdzie MAX_I to maksymalna wartość piksela (255 dla obrazów 8-bitowych), a MSE to średni błąd kwadratowy między obrazem oryginalnym a skompresowanym. Wartości powyżej 40 dB wskazują na bardzo wysoką jakość, wartości 30–40 dB na akceptowalną jakość, natomiast wartości poniżej 30 dB na istotną degradację.

6.2.2 SSIM (Structural Similarity Index Measure)

Wskaźnik podobieństwa strukturalnego [9] porównujący luminancję, kontrast i strukturę:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

gdzie μ_x , μ_y to średnie, σ_x^2 , σ_y^2 to wariancje, σ_{xy} to kowariancja, a C_1 , C_2 to stałe stabilizacyjne. SSIM przyjmuje wartości z przedziału $[0, 1]$, gdzie 1 oznacza identyczność obrazów.

6.2.3 Współczynnik kompresji

Stosunek rozmiaru pliku oryginalnego do rozmiaru pliku skompresowanego:

$$CR = \frac{S_{\text{oryginalny}}}{S_{\text{skompresowany}}} \quad (3)$$

6.3 Model klasyfikacji

Do klasyfikacji segmentów tętnic wieńcowych wykorzystano architekturę ResNet-50 [4] z wagami wstępnie nauczonymi na zbiorze ImageNet. Warstwa wyjściowa została zastąpiona warstwą w pełni połączoną z 26 neuronami odpowiadającymi klasom segmentów według schematu SYNTAX Score.

Wybór ResNet-50 podyktowany był jego powszechnością w literaturze medycznej oraz dostępnością wysokiej jakości wag pretrained, co umożliwia efektywny transfer learning nawet przy ograniczonym zbiorze danych.

6.4 Mierniki skuteczności klasyfikacji

6.4.1 Dokładność (Accuracy)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

6.4.2 Miara F1

Średnia harmoniczna precyzji i czułości:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5)$$

W niniejszej pracy zastosowano warianty *macro* (równa waga każdej klasy) oraz *weighted* (waga proporcjonalna do liczebności klasy).

6.5 Macierz pomyłek

Macierz pomyłek (*confusion matrix*) przedstawia rozkład predykcji modelu względem etykiet rzeczywistych. Dla problemu wieloklasowego (26 klas) macierz ma wymiar 26×26 , gdzie element (i, j) oznacza liczbę próbek klasy i zaklasyfikowanych jako klasa j .

7 Eksperyment

7.1 Schemat eksperymentu

Przeprowadzono badanie składające się z następujących etapów:

1. **Przygotowanie danych** – pobranie zbioru ARCADE (3000 obrazów PNG).
2. **Kompresja** – wygenerowanie skompresowanych wersji obrazów w trzech formatach (JPEG, JPEG2000, AVIF) na sześciu poziomach jakości ($Q = 100, 85, 70, 50, 30, 10$), łącznie 54 000 obrazów.
3. **Pomiar jakości kompresji** – obliczenie PSNR, SSIM i współczynnika kompresji dla wszystkich wariantów.
4. **Eksperyment A** – trening modeli na danych skompresowanych, ewaluacja na danych oryginalnych.
5. **Eksperyment B** – trening modelu na danych oryginalnych, ewaluacja na danych skompresowanych.
6. **Analiza wyników** – porównanie formatów i wyznaczenie optymalnego poziomu kompresji.

7.2 Opis danych

Zbiór ARCADE zawiera 3000 obrazów angiografii rentgenowskiej tętnic wieńcowych o rozdzielczości 512×512 pikseli w formacie PNG. Dane podzielone są na dwa zadania:

- **Syntax** (1500 obrazów) – klasyfikacja segmentów naczyńowych do 26 klas według schematu SYNTAX Score.
- **Stenosis** (1500 obrazów) – segmentacja zwężeń naczyńowych.

W niniejszej pracy wykorzystano wyłącznie podzbiór Syntax (klasyfikacja 26 klas). Podzbiór Stenosis zawiera adnotacje segmentacyjne wyłącznie jednej kategorii („stenosis”), co uniemożliwia sensowną klasyfikację wieloklasową – wszystkie obrazy otrzymywałyby tę samą etykietę, prowadząc do trywialnie wysokiej, lecz bezwartościowej dokładności 100%.

Zadanie Syntax wykorzystuje podział: trening (1000 obrazów), walidacja (200 obrazów) i test (300 obrazów). Adnotacje zapisane są w formacie COCO JSON. Dla każdego obrazu wyznaczono dominantną kategorię (najczęściej występującą w adnotacjach) jako etykietę klasyfikacji.

7.3 Procedura kompresji

Dla każdego z 3000 oryginalnych obrazów PNG wygenerowano 18 wersji skompresowanych (3 formaty $\times$ 6 poziomów jakości). Kompresję przeprowadzono z wykorzystaniem biblioteki Pillow (JPEG, JPEG2000) oraz wtyczki pillow-avif-plugin (AVIF). Wszystkie skompresowane obrazy zostały zapisane, a następnie ponownie wczytane do formatu macierzy numerycznych w celu obliczenia metryk jakości.

7.4 Konfiguracja treningu

Parametry treningu modeli:

- Architektura: ResNet-50 (pretrained ImageNet)
- Rozmiar wejścia: 224×224 pikseli
- Optymalizator: Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$, weight decay = 10^{-4})
- Szybkość uczenia: 10^{-4} z harmonogramem cosine annealing
- Wielkość batcha: 16
- Liczba epok: 50 (z early stopping, patience = 10)
- Normalizacja: średnia i odchylenie standardowe ImageNet
- Augmentacja: zmiana rozmiaru do 224×224

7.5 Eksperyment A: Trening na danych skompresowanych

W Eksperymentcie A zbadano wpływ jakości danych treningowych na końcową skuteczność modelu. Dla każdego formatu kompresji i poziomu jakości wytrenowano oddzielny model, a ewaluację przeprowadzono na oryginalnych (nieskompresowanych) danych testowych. Pozwoliło to odpowiedzieć na pytanie: *czy model jest w stanie nauczyć się diagnostycznie istotnych cech z obrazów o obniżonej jakości?*

8 Wyniki

8.1 Jakość kompresji

W Tabeli 1 przedstawiono średnie wartości PSNR, SSIM oraz współczynnika kompresji dla poszczególnych formatów i poziomów jakości, obliczone na podstawie obrazów zbioru ARCADE dla zadania Syntax (1500 obrazów).

Tabela 1: Średnie metryki jakości kompresji dla zadania Syntax ($N = 1500$ obrazów)

Format	Jakość (Q)	PSNR [dB]	SSIM	Wsp. kompresji
JPEG	100	60,01	0,9994	$1,14\times$
JPEG	85	40,80	0,9485	$4,06\times$
JPEG	70	39,01	0,9221	$6,41\times$
JPEG	50	37,62	0,8967	$9,64\times$
JPEG	30	36,17	0,8622	$14,91\times$
JPEG	10	32,67	0,7685	$31,78\times$
JPEG2000	100	∞ (bezstratna)	0,9659	$1,88\times$
JPEG2000	85	43,16	0,9660	$1,24\times$
JPEG2000	70	47,17	0,9850	$0,79\times^*$
JPEG2000	50	51,33	0,9944	$0,57\times^*$
JPEG2000	30	54,91	0,9980	$0,46\times^*$
JPEG2000	10	55,43	0,9982	$0,45\times^*$
AVIF	100	∞ (bezstratna)	1,0000	$1,24\times$
AVIF	85	43,39	0,9719	$4,06\times$
AVIF	70	40,95	0,9499	$6,41\times$
AVIF	50	39,44	0,9279	$9,64\times$
AVIF	30	38,22	0,9029	$14,97\times$
AVIF	10	36,64	0,8600	$31,86\times$

*Wartość < 1 oznacza, że plik JPEG2000 jest większy niż oryginalny PNG (utrata kompresji przy dopasowanym współczynniku kompresji).


Analiza wyników jakości kompresji pozwala sformułować kilka istotnych obserwacji:

1. **Bezstratność:** Format AVIF ($Q = 100$) zapewnia kompresję bezstratną (PSNR = ∞ , SSIM = 1,0). Format JPEG2000 ($Q = 100$) jest teoretycznie bezstratny, ale osiąga SSIM = 0,9659, co wskazuje na niewielkie różnice w wyniku kompresji bezstratnej do formatu PNG. Format JPEG przy $Q = 100$ nie jest bezstratny – osiąga PSNR = 60,01 dB, co stanowi jakość niemal nierozróżnialną, lecz nie identyczną z oryginałem.
2. **Porównywalna efektywność formatów:** Wszystkie trzy formaty osiągają bardzo podobne współczynniki kompresji przy tym samym poziomie jakości (np. przy


$Q = 50$: JPEG $9,64\times$, AVIF $9,64\times$, przy $Q = 85$: oba $4,06\times$). Różnice są minimalne i wynikają z zastosowanej metodyki dopasowanego współczynnika kompresji (matched CR).

3. **Zachowanie jakości:** Przy wysokich poziomach jakości ($Q = 85$) wszystkie formaty osiągają porównywalny PSNR (40,80–43,39 dB) i SSIM (0,9485–0,9719).
4. **Specyfika JPEG2000:** Format JPEG2000 w trybie stratnym ($Q < 100$) osiąga wyższe wartości PSNR i SSIM niż konkurencyjne formaty przy tym samym poziomie jakości (np. przy $Q = 50$: PSNR = 51,33 dB vs 37,62–39,44 dB dla JPEG/AVIF). Wynika to z zastosowania metodyki „matched compression ratio” – JPEG2000 przy niskim Q generuje pliki o wyższej jakości obrazu, ale mniejsze od oryginału ($CR < 1$).


Na Rysunkach 1–3 przedstawiono graficzne porównanie metryk jakości kompresji.



Rysunek 1: PSNR w funkcji poziomu jakości kompresji dla trzech formatów



Rysunek 2: SSIM w funkcji poziomu jakości kompresji dla trzech formatów



Rysunek 3: Współczynnik kompresji w funkcji poziomu jakości (skala logarytmiczna)

W Tabeli 2 przedstawiono porównanie formatów przy zbliżonym poziomie PSNR (~ 37 dB), ilustrujące różnice w efektywności kompresji.

Tabela 2: Porównanie formatów przy zbliżonym poziomie jakości (PSNR ≈ 37 dB)

Format	Q	PSNR [dB]	SSIM	Wsp. kompresji
JPEG	50	37,62	0,8967	9,64×
JPEG2000	10	55,43	0,9982	0,45×
AVIF	50	39,44	0,9279	9,64×

Różnice w efektywności kompresji są minimalne – JPEG i AVIF osiągają identyczny współczynnik kompresji. Wysoki PSNR JPEG2000 wynika z metodyki „matched compression ratio”.

8.2 Eksperyment A: Wpływ kompresji danych treningowych

W Tabeli 3 przedstawiono wyniki Eksperymentu A. Należy podkreślić, że zadanie klasyfikacji 26 segmentów naczyniowych według schematu SYNTAX Score jest bardzo trudnym problemem – losowy klasyfikator osiągnąłby dokładność ok. 3,8%. Uzyskane wartości Accuracy na poziomie 16–23% są wielokrotnie wyższe od poziomu losowego, co potwierdza, że modele uczą się diagnostycznie istotnych cech. Niskie wartości bezwzględne wynikają z dużej liczby klas (26) oraz ograniczonej wielkości zbioru treningowego (1000 obrazów).

Tabela 3: Wyniki Eksperymentu A: trening na danych skompresowanych, test na oryginałach (zadanie Syntax, ResNet-50)


Format	Q (trening)	Accuracy [%]	F1 macro
JPEG	100	18,33	0,074
JPEG	85	20,00	0,067
JPEG	70	20,33	0,065
JPEG	50	21,33	0,091
JPEG	30	21,67	0,072
JPEG	10	17,33	0,043
JPEG2000	100	19,33	0,082
JPEG2000	85	18,00	0,094
JPEG2000	70	17,67	0,087
JPEG2000	50	16,33	0,064
JPEG2000	30	22,67	0,085
JPEG2000	10	20,33	0,068
AVIF	100	21,67	0,079
AVIF	85	20,67	0,073
AVIF	70	22,33	0,098
AVIF	50	22,67	0,102
AVIF	30	16,67	0,066
AVIF	10	22,33	0,092

Analiza wyników Eksperymentu A prowadzi do następujących obserwacji:

1. **Paradoksalny trend JPEG:** Format JPEG wykazuje zaskakujący wzorec – najwyższy wynik Accuracy (21,67%) uzyskano przy umiarkowanej kompresji $Q = 30$,

a nie przy najwyższej jakości. Accuracy wzrasta od $Q = 100$ (18,33%) do $Q = 30$ (21,67%), dopiero przy agresywnej kompresji $Q = 10$ następuje spadek do 17,33%. Sugeruje to, że umiarkowana kompresja JPEG może działać jako forma regularizacji, usuwając nieistotne szczegóły i szum.

2. **Anomalia JPEG2000 przy $Q = 30$:** Format JPEG2000 wykazuje nietypową charakterystykę – najlepszy wynik Accuracy (22,67%) uzyskano przy $Q = 30$, pomimo relatywnie niskiego wyniku walidacji (18,0%). Wartość ta jest najwyższa wśród wszystkich badanych formatów i poziomów jakości. Warto jednak zauważyć, że różnica między najgorszym ($Q = 50$, 16,33%) a najlepszym ($Q = 30$, 22,67%) wynosi ponad 6 punktów procentowych, co świadczy o znacznej niestabilności tego formatu.
3. **Niestabilność AVIF:** Format AVIF wykazuje najbardziej nieregularny wzorec spośród wszystkich badanych formatów. Najlepszy wynik (22,67%) uzyskano przy $Q = 50$, podczas gdy $Q = 30$ dał najgorszy wynik (16,67%) – spadek o 6 punktów procentowych. Paradoksalnie, agresywna kompresja $Q = 10$ ponownie poprawiła wynik do 22,33%.
4. **Zestawienie najlepszych wyników:** Najwyższą dokładność w całym eksperymencie uzyskano dla AVIF $Q = 50$ oraz JPEG2000 $Q = 30$ (obie po 22,67%). Najwyższy wskaźnik F1 macro (0,102) również uzyskano dla AVIF $Q = 50$. Wyniki te są istotnie wyższe od poziomu losowego (3,8%), co potwierdza, że modele uczą się diagnostycznie istotnych cech nawet z obrazów kompresowanych.
5. **Próg degradacji:** Dla wszystkich formatów poziom $Q = 10$ stanowi potencjalny próg ryzyka – daje wyniki istotnie gorsze niż optymalne (JPEG: 17,33% vs 21,67%, AVIF: 22,33% vs 22,67% przy $Q = 50$). Jednak w praktyce klinicznej zaleca się stosowanie $Q \geq 50$ dla AVIF oraz $Q \geq 30$ dla JPEG, ze względu na przewidywalność wyników.



Rysunek 4: Eksperyment A: Accuracy w funkcji poziomu jakości danych treningowych

8.3 Porównanie formatów kompresji

Na podstawie wyników eksperymentu oraz metryk jakości kompresji (Tabela 1) można sformułować następujące obserwacje:

- **JPEG** wykazuje paradoksalny, ale korzystny trend – najwyższy wynik (21,67%) uzyskano przy $Q = 30$, co sugeruje efekt regularizacji poprzez umiarkowaną kompresję. Format ten charakteryzuje się przewidywalnym zachowaniem i może być bezpiecznie stosowany nawet przy $Q = 30$.
- **JPEG2000** osiągnął najwyższy wynik w całym badaniu (22,67% przy $Q = 30$), jednak jego niestabilność (różnice ponad 6 punktów procentowych między poziomami jakości) czyni go mniej przewidywalnym niż JPEG.
- **AVIF** osiąga porównywalną efektywność kompresji do JPEG (np. przy $Q = 50$: oba $9,64\times$) i najwyższy wynik F1 macro (0,102 przy $Q = 50$). Jego niestabilność (spadek z 22,67% przy $Q = 50$ do 16,67% przy $Q = 30$) wymaga jednak ostrożności przy doborze poziomu kompresji.
- **Brak istotnych różnic między formatami:** Bezwzględne różnice między formatami przy tym samym poziomie jakości wynoszą zaledwie 2–5 punktów procentowych, co przy ograniczonej wielkości zbioru testowego (300 obrazów) jest niewielkie. Wszystkie formaty pozwalają na osiągnięcie wyników około 5–6 krotnie wyższych od poziomu losowego.

9 Wnioski

Na podstawie przeprowadzonych eksperymentów sformułowano następujące wnioski w odniesieniu do postawionych hipotez:

1. **Weryfikacja H1 (JPEG2000 vs JPEG):** Hipoteza nie została jednoznacznie potwierdzona. Format JPEG2000 osiągnął co prawda najwyższy wynik w całym badaniu (22,67% przy $Q = 30$), jednak jego wyniki są bardziej niestabilne niż w przypadku JPEG. Format JPEG wykazuje przewidywalny, paradoksalnie pozytywny trend z efektem regularizacji przy $Q = 30$ (21,67%).
2. **Weryfikacja H2 (AVIF):** Hipoteza częściowo potwierdzona. AVIF osiąga porównywalne współczynniki kompresji do JPEG ($31,86\times$ vs $31,78\times$ przy $Q = 10$) przy zachowaniu porównywalnej skuteczności modeli. AVIF uzyskał najlepszy wynik F1 macro (0,102 przy $Q = 50$) oraz najwyższy Accuracy (22,67% przy $Q = 50$, ex aequo z JPEG2000).
3. **Weryfikacja H3 (próg degradacji):** Hipoteza potwierdzona częściowo. Dla wszystkich formatów poziom $Q = 10$ stanowi potencjalny próg ryzyka – daje wyniki istotnie gorsze niż optymalne (JPEG: 17,33% vs 21,67%). Jednak nie zaobserwowano spadku przy $Q = 10$ dla AVIF (22,33%) i JPEG2000 (20,33%), co wskazuje na złożoną zależność między kompresją danych treningowych a skutecznością modelu.
4. **Ogólna skuteczność:** Wartości Accuracy na poziomie 16–23% odzwierciedlają trudność zadania klasyfikacji 26 segmentów naczyniowych. Wyniki są około 5–6 krotnie wyższe od poziomu losowego (3,8%), co potwierdza, że modele uczą się diagnostycznie istotnych cech. Niski F1 macro (0,043–0,102) wynika z nie zrównoważonego rozkładu klas.

10 Podsumowanie

W niniejszej pracy przeprowadzono badanie wpływu kompresji stratnej obrazów angiografii wieńcowej na skuteczność modelu głębokiego uczenia ResNet-50 w zadaniu klasyfikacji 26 segmentów naczyniowych według schematu SYNTAX Score. Zbadano trzy formaty kompresji (JPEG, JPEG2000, AVIF) na sześciu poziomach jakości ($Q = 100, 85, 70, 50, 30, 10$).

10.1 Realizacja celów

Zrealizowano wszystkie cele szczegółowe pracy: (1) porównano trzy formaty kompresji pod kątem metryk jakości obrazu, (2) zbadano wpływ kompresji danych treningowych na dokładność modelu, (3) zidentyfikowano poziomy kompresji zapewniający maksymalną redukcję rozmiaru przy minimalnej utracie dokładności klasyfikacji, (4) sformułowano rekomendacje praktyczne.

10.2 Rekomendacje praktyczne

Na podstawie uzyskanych wyników można sformułować następujące rekomendacje dla systemów PACS i platform telemedycznych:

- Dla treningu modeli AI zaleca się stosowanie umiarkowanej kompresji: $Q = 30$ dla JPEG (wynik 21,67%), $Q = 50$ dla AVIF (wynik 22,67%) oraz $Q \geq 70$ dla JPEG2000 ze względu na stabilność. Poziom $Q = 10$ powinien być unikany ze względu na nieprzewidywalność wyników.
- Format AVIF jest rekomendowany w scenariuszach wymagających wysokiej kompresji – przy $Q = 50$ osiąga kompresję $9,64\times$ przy najwyższej skuteczności modelu w całym badaniu (22,67%, $F1 = 0,102$).
- Format JPEG, pomimo prostoty, zapewnia przewidywalne wyniki z efektem regularizacji przy $Q = 30$ i może być bezpiecznie stosowany w systemach AI.
- Format JPEG2000 wymaga ostrożności – choć osiągnął najwyższy wynik (22,67% przy $Q = 30$), jego niestabilność (wahania ponad 6 punktów procentowych) czyni go mniej przewidywalnym niż JPEG i AVIF.

10.3 Ograniczenia

- Badanie ograniczone do jednego typu modalności (angiografia rentgenowska) i jednego zbioru danych (ARCADE).
- Zastosowano jedną architekturę modelu (ResNet-50) z globalną klasyfikacją, podczas gdy zadanie SYNTAX Score jest z natury segmentacyjne.

- Niskie bezwzględne wartości Accuracy (16–23%) wynikające z dużej liczby klas i ograniczonego zbioru danych mogą utrudniać wykrycie subtelnych różnic między formatami kompresji.
- Parametryzacja jakości JPEG2000 w bibliotece Pillow może nie odpowiadać optymalnym ustawieniom profesjonalnych systemów DICOM.

10.4 Kierunki dalszych badań

- Rozszerzenie badania na zadania segmentacji naczyniowej i detekcji zwężeń, gdzie wpływ kompresji może być bardziej widoczny.
- Zastosowanie dedykowanych architektur segmentacyjnych (U-Net, DeepLabV3+) zamiast globalnej klasyfikacji.
- Badanie na innych modalnościach obrazowania medycznego (MRI, CT, ultrasonografia).
- Analiza wpływu kompresji na pewność predykcji (kalibracja modelu), nie tylko na dokładność.
- Wykorzystanie profesjonalnych implementacji JPEG2000 (np. OpenJPEG) zamiast biblioteki Pillow.

Spis rysunków

1	PSNR w funkcji poziomu jakości kompresji dla trzech formatów	12
2	SSIM w funkcji poziomu jakości kompresji dla trzech formatów	13
3	Współczynnik kompresji w funkcji poziomu jakości (skala logarytmiczna) .	13
4	Eksperyment A: Accuracy w funkcji poziomu jakości danych treningowych	16

Spis tabel

1	Średnie metryki jakości kompresji dla zadania Syntax (N = 1500 obrazów)	11
2	Porównanie formatów przy zbliżonym poziomie jakości (PSNR $\approx$ 37 dB) .	14
3	Wyniki Eksperymentu A: trening na danych skompresowanych, test na oryginalach (zadanie Syntax, ResNet-50)	14

Bibliografia

- [1] Alliance for Open Media. (2019). *AV1 Image File Format (AVIF)*. <https://aomediacodec.github.io/av1-avif/>
- [2] Ansari, M. M. (2025). Evaluating Stenosis Detection with Grounding DINO, YOLO, and DINO-DETR. *arXiv preprint arXiv:2503.01601*. <https://arxiv.org/abs/2503.01601>
- [3] Gayet, R., Abd El Al, A., Meyer, A., Hennemuth, A., Ivantsits, M. i Popp, A. (2025). Coronary Tree Segmentation and Labelling in X-ray Angiography Images Using Graph Deep Learning. W *Bildverarbeitung für die Medizin 2025*, 235–240. Springer. https://doi.org/10.1007/978-3-658-47422-5_51
- [4] He, K., Zhang, X., Ren, S. i Sun, J. (2016). Deep Residual Learning for Image Recognition. W *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- [5] National Electrical Manufacturers Association. (2024). *DICOM Standard*. <https://www.dicomstandard.org/>
- [6] Popov, A., Sirazitdinov, I., Illarionova, S., Bochkov, V. i Tiulpin, A. (2024). Dataset for Automatic Region-based Coronary Artery Disease Diagnostics Using X-Ray Angiography Images. *Scientific Data*, 11, 20. <https://doi.org/10.1038/s41597-023-02871-z>
- [7] Ren, H., Li, D., Jing, F., Zhang, X., Tian, X., Xie, S., Zhang, E., Wang, R., He, H., He, Y., Xue, Y., Liu, C., Sun, Y. i Cheng, W. (2025). LASF: A Local Adaptive

- Segmentation Framework for Coronary Angiogram Segments. *Health Information Science and Systems*, 13, 19. <https://doi.org/10.1007/s13755-025-00339-5>
- [8] Taubman, D. i Marcellin, M. (2002). *JPEG2000: Image Compression Fundamentals, Standards and Practice*. Springer. <https://doi.org/10.1007/978-1-4615-0799-4>
- [9] Wang, Z., Bovik, A. C., Sheikh, H. R. i Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>
- [10] Yang, Q., Yi, H., Yi, L., Liu, M. i Chen, X. (2025). Accurate Segmentation and Labeling of Coronary Artery Segments in X-ray Angiography with an Improved UNet-based cGAN Architecture. *Biomedical Signal Processing and Control*. <https://doi.org/10.1016/j.bspc.2025.108812>