

Wpływ kompresji obrazu na skuteczność modeli głębokiego uczenia w diagnostyce kardiologicznej

1 Wstęp

Obrazowanie medyczne stanowi fundament współczesnej diagnostyki kardiologicznej. Wraz ze wzrostem liczby wykonywanych badań oraz rozdzielczości obrazów, rośnie zapotrzebowanie na efektywne metody przechowywania i przesyłania danych. Kompresja obrazu jest powszechnie stosowanym rozwiązaniem tego problemu, jednak jej wpływ na skuteczność automatycznych systemów diagnostycznych opartych na głębokim uczeniu pozostaje niedostatecznie zbadany.

W niniejszej pracy zbadano wpływ trzech formatów kompresji – JPEG, JPEG2000 oraz AVIF – na skuteczność dwóch architektur głębokiego uczenia (ResNet-50 i EfficientNet-B0) w zadaniu klasyfikacji segmentów tętnic wieńcowych w obrazach angiografii rentgenowskiej. Każdy obraz angiograficzny zawiera kilka segmentów naczyniowych z różnych klas, dlatego problem sformułowano jako klasyfikację wieloetykietową (*multi-label*). Przeprowadzono Eksperyment A: trening modeli na danych skompresowanych z ewaluacją na oryginałach, dodatkowo zbudowano model bazowy (*baseline*) trenowany na oryginalnych obrazach PNG jako górny punkt odniesienia. Aby zapewnić uczciwe porównanie formatów, zastosowano metodologię *matched compression ratio* – dla każdego obrazu poziom kompresji JPEG2000 i AVIF dobierany jest tak, aby uzyskać identyczny rozmiar pliku jak JPEG przy zadanym parametrze jakości Q . Badania wykonano na zbiorze danych ARCADE zawierającym 1500 obrazów opatrzonych adnotacjami eksperckimi dla zadania klasyfikacji według schematu SYNTAX Score.

2 Motywacja i kontekst pracy

Systemy archiwizacji obrazów medycznych (PACS – *Picture Archiving and Communication System*) oraz platformy telemedyczne wymagają kompresji danych w celu redukcji kosztów przechowywania i przyspieszenia transmisji. Standard DICOM (*Digital Imaging and Communications in Medicine*) dopuszcza stosowanie kompresji stratnej, w tym formatu JPEG2000, jednakże brak jest jednoznacznych wytycznych dotyczących dopuszczalnego poziomu kompresji w kontekście automatycznej analizy AI.

Jednocześnie modele głębokiego uczenia coraz częściej wspomagają diagnostykę chorób tętnic wieńcowych (CAD – *Coronary Artery Disease*), które pozostają główną przyczyną zgonów na świecie. Angiografia rentgenowska jest złotym standardem w diagnostyce CAD, a automatyczna klasyfikacja segmentów naczyniowych według schematu SYNTAX Score umożliwia obiektywną ocenę stopnia zaawansowania choroby.

Pojawienie się nowoczesnego formatu AVIF (opartego na kodeku AV1, 2019) otwiera nowe możliwości kompresji, lecz jego przydatność w obrazowaniu medycznym nie została dotychczas zbadana. Niniejsza praca wypełnia tę lukę, oferując kompleksowe porównanie trzech formatów kompresji w kontekście ich wpływu na modele AI stosowane w kardiologii.

3 Cele i założenia

3.1 Cel główny

Określenie wpływu kompresji stratnej obrazów angiografii rentgenowskiej na skuteczność modeli głębokiego uczenia w zadaniu klasyfikacji segmentów tętnic wieńcowych.

3.2 Cele szczegółowe

1. Porównanie trzech formatów kompresji (JPEG, JPEG2000, AVIF) pod kątem jakości obrazu mierzonej wskaźnikami PSNR i SSIM.
2. Zbadanie wpływu kompresji danych treningowych na skuteczność modelu, mierzoną względem modelu bazowego trenowanego na danych oryginalnych (Eksperyment A).
3. Wyznaczenie optymalnego poziomu kompresji zapewniającego maksymalną redukcję rozmiaru przy minimalnej utracie dokładności klasyfikacji.
4. Sformułowanie rekomendacji dla systemów PACS i platform telemedycznych.

3.3 Hipoteza

Postawiono następujące hipotezy badawcze:

- H1: Format JPEG2000, będący standardem DICOM, zapewnia lepsze zachowanie skuteczności modeli AI niż klasyczny JPEG przy porównywalnym stopniu kompresji.
- H2: Format AVIF, dzięki nowoczesnym technikom predykcji wewnątrzramkowej, zachowuje skuteczność modeli na poziomie co najmniej porównywalnym z JPEG2000 przy tym samym współczynniku kompresji.
- H3: Istnieje progowy poziom kompresji, poniżej którego następuje wyraźny spadek skuteczności klasyfikacji, przy czym próg ten zależy od zastosowanego formatu.
- H4: Model trenowany na danych skompresowanych osiąga skuteczność porównywalną z modelem bazowym trenowanym na oryginalnych danych PNG, jeżeli faza ewaluacji odbywa się na oryginałach – tj. kompresja danych treningowych nie powoduje istotnej utraty informacji diagnostycznej.

4 Zawartość pracy

Praca składa się z następujących rozdziałów. W rozdziale 5 przedstawiono przegląd literatury dotyczącej kompresji obrazów medycznych oraz zastosowań głębokiego uczenia w angiografii wieńcowej. Rozdział 6 zawiera opis zastosowanych metod, modeli i mierników skuteczności. W rozdziale 7 opisano przebieg eksperymentów, strukturę danych oraz kolejne etapy badania. Rozdział 8 prezentuje uzyskane wyniki w formie tabel i wykresów wraz z ich interpretacją. W rozdziale 9 sformułowano wnioski, a w rozdziale 10 dokonano podsumowania pracy.

5 Przegląd literatury

5.1 Kompresja obrazów medycznych

Kompresja obrazów medycznych jest przedmiotem badań od lat 90. XX wieku. Wyróżnia się kompresję bezstratną (zachowującą pełną informację) oraz stratną (wprowadzającą nieodwracalne zmiany). W systemach PACS powszechnie stosowany jest format JPEG2000, który w roku 2003 został włączony do standardu DICOM jako preferowany format kompresji stratnej [5].

Format JPEG (Joint Photographic Experts Group) wykorzystuje dyskretną transformę kosinusową (DCT) operującą na blokach 8×8 pikseli, co przy niskich poziomach jakości prowadzi do charakterystycznych artefaktów blokowych. Format JPEG2000 stosuje transformę falkową (DWT – *Discrete Wavelet Transform*), eliminując artefakty blokowe i zapewniając lepszą jakość przy niższych przepływnościach [8].

AVIF (*AV1 Image File Format*) jest nowoczesnym formatem kompresji obrazu, opartym na kodeku wideo AV1, opublikowanym w 2019 roku. Wykorzystuje zaawansowane techniki predykcji wewnątrzramkowej i transformaty, oferując znacząco lepszą efektywność kompresji w porównaniu z formatami poprzedniej generacji [1].

5.2 Zbiór danych ARCADE

ARCADE (*Automatic Region-based Coronary Artery Disease diagnostics using x-ray angiography images*) jest publicznie dostępnym zbiorem danych opublikowanym w ramach wyzwania MICCAI 2023. Zbiór zawiera 3000 ekspertowo zanotowanych obrazów angiografii rentgenowskiej podzielonych na dwa podzbiory: 1500 obrazów do klasyfikacji segmentów naczyniowych według schematu SYNTAX Score (26 klas) oraz 1500 obrazów do detekcji zwężeń [6].

5.3 Zastosowania głębokiego uczenia w angiografii wieńcowej

W ostatnich latach opublikowano szereg prac wykorzystujących zbiór ARCADE do różnych zadań diagnostycznych. Framework LASF oparty na YOLOv8 osiągnął wysoką skuteczność w segmentacji naczyń wieńcowych, przewyższając architektury U-Net i DeepLabV3Plus [7]. Badanie porównawcze architektur detekcji obiektów (Grounding DINO, YOLO, DINO-DETR) wykazało zróżnicowaną skuteczność w detekcji zwężeń [2]. Model UCNNet oparty na warunkowej sieci generatywnej (cGAN) osiągnął średni F1 score 84,43% w klasyfikacji 20 segmentów tętnic wieńcowych [10]. Zastosowanie grafowych sieci konwoLucyjnych do reprezentacji struktury drzewa wieńcowego pozwoliło na osiągnięcie F1 score 53,68 [3].

Żadna z dotychczasowych prac nie badała jednak wpływu kompresji obrazu na skuteczność modeli klasyfikacji w angiografii wieńcowej, co stanowi istotną lukę badawczą.

6 Materiały i metody

6.1 Formaty kompresji

6.1.1 JPEG

Format JPEG wykorzystuje dyskretną transformatę kosinusową (DCT) stosowaną na blokach 8×8 pikseli. Współczynniki DCT podlegają kwantyzacji sterowanej natywnym parametrem jakości $Q \in [1, 100]$, gdzie wyższe wartości oznaczają mniejszą stratę informacji. Parametr Q jest bezpośrednim argumentem wejściowym kodera JPEG i nie ma odpowiednika w innych formatach. Przy niskich wartościach Q pojawiają się charakterystyczne artefakty blokowe na granicach bloków DCT. Kompresja JPEG jest zawsze stratna – nawet wartość $Q = 100$ wprowadza niewielkie zniekształcenia kwantyzacyjne, wizualnie nierozróżnialne od oryginału.

6.1.2 JPEG2000

Format JPEG2000 wykorzystuje dyskretną transformatę falkową (DWT), operującą na całym obrazie zamiast na blokach. Eliminuje to artefakty blokowe i umożliwia progresywną dekompresję. W standardzie DICOM jest rekomendowanym formatem kompresji stratnej dla obrazów medycznych. JPEG2000 *nie posiada* natywnego parametru Q analogicznego do JPEG – stopień kompresji jest sterowany docelową przepływnością (*rates*) lub liczbą warstw jakościowych (*quality layers*). Format obsługuje zarówno tryb stratny (*irreversible*, transformata 9/7), jak i bezstratny (*reversible*, transformata 5/3).

6.1.3 AVIF

Format AVIF bazuje na kodeku wideo AV1, wykorzystując zaawansowane techniki predykcji wewnątrzramkowej z blokami o zmiennym rozmiarze (od 4×4 do 64×64 pikseli). AVIF *nie posiada* natywnego parametru Q identycznego z JPEG – biblioteka Pillow eksponuje parametr `quality` $\in [0, 100]$, lecz jego skala i mapowanie na bitrate są różne od JPEG, a format obsługuje też tryb bezstratny.

6.1.4 Definicja Q -równoważnego dla JPEG2000 i AVIF

Aby umożliwić uczciwe porównanie trzech formatów na tych samych poziomach kompresji, w niniejszej pracy przyjęto metodologię Q -równoważnego (*Q-equivalent*) opartą na **dopasowanym współczynniku kompresji** (*matched compression ratio*). Procedura jest następująca:

1. Dla każdego oryginalnego obrazu PNG wyznaczany jest jego rozmiar S_{oryg} .

2. Obraz jest kompresowany do JPEG przy natywnym parametrze $Q \in \{100, 85, 70, 50, 30, 10\}$, co daje rozmiar pliku $S_{\text{JPEG}}(Q)$ oraz **referencyjny** współczynnik kompresji $\text{CR}_{\text{ref}}(Q) = S_{\text{oryg}}/S_{\text{JPEG}}(Q)$.
3. Dla JPEG2000 i AVIF docelowy rozmiar pliku jest ustalony jako $S_{\text{cel}} = S_{\text{JPEG}}(Q)$. Ponieważ żaden z tych formatów nie pozwala bezpośrednio kontrolować rozmiaru wyjściowego, stosowany jest **algorytm wyszukiwania binarnego** po parametrze sterującym kompresją (odpowiednio: `quality_layers` dla JPEG2000 oraz `quality` dla AVIF), do osiągnięcia $|S_{\text{wyj}} - S_{\text{cel}}|$ poniżej tolerancji 5% lub po 20 iteracjach.
4. Wynikowe pliki JPEG2000 i AVIF mają rozmiar bardzo zbliżony do JPEG przy danym Q , a więc **jednakowy współczynnik kompresji**, co umożliwia bezpośrednie porównanie skuteczności formatów przy ustalonym budżecie pamięciowym.

Etykieta Q stosowana w dalszej części pracy dla JPEG2000 i AVIF **nie odnosi się** zatem do natywnego parametru jakości tych formatów, lecz oznacza *poziom kompresji równoważny JPEG przy parametrze jakości Q* . Wszystkie trzy formaty są w niniejszej pracy stratne dla każdego Q , łącznie z $Q = 100$, ponieważ docelowy rozmiar dla JPEG2000 i AVIF jest dyktowany przez stratny JPEG $Q = 100$ (typowo $\text{CR} \approx 1,2\times$). Tryb bez-stratny formatów nie jest w niniejszej pracy wykorzystywany.

6.2 Mierniki jakości obrazu

6.2.1 PSNR (Peak Signal-to-Noise Ratio)

Szczytowy stosunek sygnału do szumu wyrażony w decybelach:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right) \quad (1)$$

gdzie MAX_I to maksymalna wartość piksela (255 dla obrazów 8-bitowych), a MSE to średni błąd kwadratowy między obrazem oryginalnym a skompresowanym. Wartości powyżej 40 dB wskazują na bardzo wysoką jakość, wartości 30–40 dB na akceptowalną jakość, natomiast wartości poniżej 30 dB na istotną degradację.

6.2.2 SSIM (Structural Similarity Index Measure)

Wskaźnik podobieństwa strukturalnego [9] porównujący luminancję, kontrast i strukturę:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

gdzie μ_x, μ_y to średnie, σ_x^2, σ_y^2 to wariancje, σ_{xy} to kowariancja, a C_1, C_2 to stałe stabilizacyjne. SSIM przyjmuje wartości z przedziału $[0, 1]$, gdzie 1 oznacza identyczność

obrazów.

6.2.3 Współczynnik kompresji

Stosunek rozmiaru pliku oryginalnego do rozmiaru pliku skompresowanego:

$$CR = \frac{S_{\text{oryginalny}}}{S_{\text{skompresowany}}} \quad (3)$$

6.3 Sformułowanie problemu: klasyfikacja wieloetykietowa

Każdy obraz w zbiorze ARCADE/Syntax zawiera średnio około pięciu segmentów naczyniowych, należących typowo do różnych klas wśród 26 zdefiniowanych przez schemat SYNTAX Score. Próba sprowadzenia adnotacji do pojedynczej etykiety dominującej (najczęściej występującej) prowadzi do silnie zaszumionego sygnału – analiza adnotacji wykazała, że w 99,3% obrazów zbioru treningowego liczba adnotacji każdej klasy obecnej w obrazie jest taka sama, czyli wybór „dominującej” kategorii rozstrzygany jest arbitralnie kolejnością w pliku adnotacji. Z tego powodu w niniejszej pracy zastosowano sformułowanie **wieloetykietowe** (*multi-label*): etykietą obrazu jest wektor binarny $\mathbf{y} \in \{0, 1\}^{26}$, w którym pozycja k -ta przyjmuje wartość 1 wtedy i tylko wtedy, gdy w obrazie znajduje się przynajmniej jeden segment klasy k .

6.4 Modele klasyfikacji

Do klasyfikacji segmentów tętnic wieńcowych wykorzystano dwie architektury sieci konwolucyjnych: **ResNet-50** [4] oraz **EfficientNet-B0**, obie z wagami wstępnie nauczonymi na zbiorze ImageNet. Warstwa wyjściowa w obu modelach została zastąpiona warstwą w pełni połączoną z 26 neuronami odpowiadającymi klasom SYNTAX Score, bez aktywacji końcowej – prawdopodobieństwa są wyliczane przez funkcję sigmoid w funkcji kosztu.

ResNet-50 jest powszechnie stosowaną architekturą w obrazowaniu medycznym i stanowi rozsądny punkt odniesienia dla wielu wcześniejszych prac. EfficientNet-B0, mimo pięciokrotnie mniejszej liczby parametrów (5,3 mln wobec 25,5 mln dla ResNet-50), używa na ImageNet porównywalną dokładność i może być atrakcyjnym wyborem dla zastosowań o ograniczonych zasobach obliczeniowych. Porównanie obu modeli pozwala ocenić, czy wnioski dotyczące wpływu kompresji są niezależne od wyboru architektury.

6.5 Funkcja kosztu i ważenie klas

Z uwagi na znaczne nie zrównoważenie klas w zbiorze ARCADE/Syntax (klasa najczęstsza obecna w 536 obrazach treningowych z 1000, klasa najrzadsza w zaledwie jednym obrazie, a jedna z 26 klas nie występuje w ogóle w zbiorze treningowym) zastosowano funkcję

kosztu **Binary Cross-Entropy with Logits** z wagą pozytywną (*pos_weight*) wyliczaną osobno dla każdej z 26 klas jako stosunek liczby próbek negatywnych do pozytywnych w zbiorze treningowym:

$$w_k^+ = \frac{N - n_k^+}{n_k^+}, \quad (4)$$

gdzie n_k^+ to liczba obrazów zawierających klasę k , a N to całkowita liczba obrazów treningowych. Mechanizm ten zwiększa wkład rzadkich klas w funkcję kosztu i przeciwdziała zjawisku, w którym model uczy się przewidywać wyłącznie najczęstsze klasy.

6.6 Mierniki skuteczności klasyfikacji wieloetykietowej

W klasyfikacji wieloetykietowej standardowa dokładność typu top-1 nie jest miarodajna, ponieważ każdy obraz ma kilka prawdziwych etykiet jednocześnie. Zastosowano następujące mierniki obliczane na zbiorze testowym po progowaniu wyjść sigmoidalnych przy wartości 0,5:

6.6.1 F1-macro i F1-micro

Dla każdej klasy k wyznaczana jest miara F1 jako średnia harmoniczna precyzji i czułości. *F1-macro* to nieważona średnia F1 po wszystkich klasach (równa waga każdej klasy, niezależnie od jej liczebności), *F1-micro* agreguje TP, FP i FN globalnie przed wyliczeniem F1 (waga proporcjonalna do liczebności klasy).

6.6.2 Hamming accuracy

Odsetek poprawnie przewidzianych pozycji w wektorze etykiet, uśredniony po wszystkich obrazach i klasach:

$$\text{Hamming acc} = 1 - \frac{1}{N \cdot K} \sum_{i=1}^N \sum_{k=1}^K \mathbb{I}[\hat{y}_{ik} \neq y_{ik}]. \quad (5)$$

6.6.3 Subset accuracy

Odsetek obrazów, dla których wszystkie 26 etykiet zostało przewidzianych poprawnie. Jest to bardzo rygorystyczna miara – wystarczy jedna pomyłka, aby obraz został zaliczony jako błędny.

6.6.4 mAP (mean Average Precision)

Średnia ważona precyzji po wszystkich progach decyzyjnych, niezależna od konkretnego progu klasyfikacji. Dla każdej klasy obecnej w zbiorze testowym wyznaczana jest średnia precyzja (AP), a następnie uśredniana makroskopowo. mAP jest powszechnie stosowaną miarą w zadaniach wieloetykietowych i retrievalu.

7 Eksperyment

7.1 Schemat eksperymentu

Przeprowadzono badanie składające się z następujących etapów:

1. **Przygotowanie danych** – pobranie zbioru ARCADE (1500 obrazów PNG dla zadania Syntax).
2. **Kompresja JPEG** – wygenerowanie skompresowanych wersji obrazów dla sześciu poziomów jakości ($Q = 100, 85, 70, 50, 30, 10$); zapisanie referencyjnego rozmiaru pliku $S_{\text{JPEG}}(Q)$ dla każdego obrazu i poziomu.
3. **Kompresja JPEG2000 i AVIF z dopasowanym CR** – dla każdego obrazu i poziomu Q algorytm wyszukiwania binarnego dobiera parametr sterujący tak, aby wynikowy rozmiar pliku zbliżyć do $S_{\text{JPEG}}(Q)$ (procedura opisana w podrozdziale 6.1.4).
4. **Pomiar jakości kompresji** – obliczenie PSNR, SSIM i współczynnika kompresji dla wszystkich wariantów.
5. **Trening modelu bazowego** – trening ResNet-50 i EfficientNet-B0 na oryginalnych obrazach PNG, walidacja i test również na PNG. Stanowi to górny punkt odniesienia dla Eksperymentu A.
6. **Eksperyment A** – trening modeli na danych skompresowanych z walidacją w tej samej domenie (te same Q i format) oraz ewaluacja końcowa na oryginalnych danych testowych PNG.
7. **Analiza wyników** – porównanie formatów, wyznaczenie wpływu kompresji względem modelu bazowego oraz optymalnego poziomu kompresji.

7.2 Opis danych

Zbiór ARCADE zawiera 3000 obrazów angiografii rentgenowskiej tętnic wieńcowych o rozdzielczości 512×512 pikseli w formacie PNG. Dane podzielone są na dwa zadania:

- **Syntax** (1500 obrazów) – klasyfikacja segmentów naczyńowych do 26 klas według schematu SYNTAX Score.
- **Stenosis** (1500 obrazów) – segmentacja zwężeń naczyńowych.

W niniejszej pracy wykorzystano wyłącznie podzbiór Syntax (klasyfikacja 26 klas). Podzbiór Stenosis zawiera adnotacje segmentacyjne wyłącznie jednej kategorii („stenosis”), co uniemożliwia sensowną klasyfikację wieloklasową.

Zadanie Syntax wykorzystuje podział: trening (1000 obrazów), walidacja (200 obrazów) i test (300 obrazów). Adnotacje zapisane są w formacie COCO JSON. Każdy obraz zawiera zwykle kilka adnotacji segmentacyjnych z różnych klas; dla potrzeb klasyfikacji wieloetykietowej (zob. podrozdział 6.3) etykietę obrazu stanowi 26-elementowy wektor binarny, w którym wartość 1 oznacza obecność co najmniej jednego segmentu danej klasy, a 0 – jej brak.

7.3 Procedura kompresji

Dla każdego z 1500 oryginalnych obrazów PNG zadania Syntax wygenerowano 18 wersji skompresowanych (3 formaty $\times$ 6 poziomów jakości). JPEG kompresowano natywnym parametrem Q (subsampling 4:4:4 dla zachowania pełnej rozdzielczości chrominancji w obrazach medycznych). JPEG2000 i AVIF kompresowano przy użyciu wyszukiwania binarnego po parametrze sterującym, do osiągnięcia rozmiaru pliku odpowiadającego JPEG dla tego samego obrazu i tego samego Q z tolerancją 5% (zob. podrozdział 6.1.4). Kompresję przeprowadzono z wykorzystaniem biblioteki Pillow (JPEG, JPEG2000) oraz wtyczki `pillow-avif-plugin` (AVIF). Wszystkie skompresowane obrazy zostały zapisane na dysku, a następnie ponownie wczytane do macierzy numerycznych w celu obliczenia metryk jakości obrazu.

7.4 Konfiguracja treningu

Parametry treningu identyczne dla obu modeli:

- Architektury: ResNet-50 oraz EfficientNet-B0, obie z wagami wstępnie wytrenowanymi na ImageNet (biblioteka `timm`); ostatnia warstwa zastąpiona warstwą w pełni połączoną o 26 wyjściach
- Funkcja kosztu: `BCEWithLogitsLoss` z per-klasowym `pos_weight` wyliczanym ze zbioru treningowego
- Rozmiar wejścia: 224×224 pikseli (skalowanie z oryginalnych 512×512 , podyktowane wymaganiami modeli wstępnie wytrenowanych na ImageNet)
- Optymalizator: Adam ($\beta_1 = 0,9$, $\beta_2 = 0,999$, $\text{weight decay} = 10^{-4}$)
- Szybkość uczenia: 10^{-4} z harmonogramem cosine annealing
- Wielkość batcha: 16
- Liczba epok: do 50 z wczesnym zatrzymaniem (cierpliwość = 10 epok, kryterium: F1-macro na zbiorze walidacyjnym)
- Normalizacja: średnia i odchylenie standardowe ze zbioru ImageNet

- Augmentacja treningowa: losowe odbicie poziome ($p = 0,5$), losowy obrót ($\pm 15^\circ$), drobne zaburzenia jasności, kontrastu i saturacji ($\pm 0,1$)
- Walidacja i test: bez augmentacji, jedynie skalowanie
- Mieszana precyzja (AMP) na karcie GPU z CUDA
- Ziarno losowe: 42 (dla powtarzalności wyników)

Trening i ewaluacja przebiegały zgodnie z zasadą zachowania domeny: model trenowany na obrazach skompresowanych formatem F z poziomem Q jest **walidowany na obrazach z tej samej domeny** (F, Q). Końcowa ewaluacja na zbiorze testowym jest natomiast wykonywana na **oryginalnych obrazach PNG** – pytanie badawcze brzmi: *czy model wytrenowany na obrazach skompresowanych potrafi generalizować na dane wysokiej jakości?*

7.5 Eksperyment A: Trening na danych skompresowanych

W Eksperymentcie A zbadano wpływ jakości danych treningowych na końcową skuteczność modelu. Dla każdego formatu kompresji ($\in \{\text{JPEG}, \text{JPEG2000}, \text{AVIF}\}$), poziomu jakości ($Q \in \{100, 85, 70, 50, 30, 10\}$) oraz architektury ($\in \{\text{ResNet-50}, \text{EfficientNet-B0}\}$) wytrenowano oddzielny model. Łącznie wykonano 36 treningów Eksperymentu A oraz dwa treningi modeli bazowych (po jednym dla każdej architektury), co daje 38 trenowanych modeli.

8 Wyniki

8.1 Jakość kompresji

Empiryczna weryfikacja procedury dopasowanego CR (zob. podrozdział 6.1.4) na próbie 50 obrazów wykazała, że dla docelowego współczynnika kompresji $CR = 5\times$ algorytm wyszukiwania binarnego osiąga średnio $5,03\times$, dla $CR = 10\times$ średnio $10,05\times$, dla $CR = 20\times$ średnio $20,05\times$, oraz dla $CR = 50\times$ średnio $48,72\times$ – błąd procentowy nie przekracza 5% w rozważanym zakresie. Tabela 1 ma przedstawić pełne pomiary PSNR, SSIM i CR po przeliczeniu na pełnym zbiorze danych¹.

Tabela 1: Średnie metryki jakości kompresji dla zadania Syntax po naprawie procedury dopasowanego CR (wartości do uzupełnienia w finalnej wersji)

Format	Q-równ.	PSNR [dB]	SSIM	CR
JPEG (referencja)	100, 85, 70, 50, 30, 10	—	—	$1,2\text{--}35\times$
JPEG2000 (matched)	100, 85, 70, 50, 30, 10	—	—	$\approx \text{JPEG} \pm 5\%$
AVIF (matched)	100, 85, 70, 50, 30, 10	—	—	$\approx \text{JPEG} \pm 5\%$

8.2 Modele bazowe (trening na oryginalnym PNG)

Tabela 2 przedstawia skuteczność modeli trenowanych i ewaluowanych wyłącznie na oryginalnych obrazach PNG. Wartości te stanowią górny punkt odniesienia (*ceiling*) dla wszystkich wariantów Eksperymentu A.

Tabela 2: Wyniki modeli bazowych: trening, walidacja i test na oryginalnym PNG (zadanie Syntax)

Architektura	F1-macro	F1-micro	mAP	Hamming acc	Subset acc
ResNet-50	0,613	0,776	0,647	0,888	0,120
EfficientNet-B0	0,580	0,762	0,618	0,885	0,080

8.3 Eksperyment A: Wpływ kompresji danych treningowych

W Tabelach 3 i 4 przedstawiono wyniki Eksperymentu A dla obu architektur. Modele trenowane są na obrazach skompresowanych, walidowane w tej samej domenie (te same Q i format), a testowane na oryginalnych PNG (300 obrazów).

¹Pomiary PSNR/SSIM przeprowadzone wcześniej dla JPEG2000 zostały unieważnione przez naprawę procedury dopasowanego CR i wymagają ponownego wyliczenia. Wartości zostaną uzupełnione w finalnej wersji pracy.

Tabela 3: Eksperyment A, ResNet-50: trening na danych skompresowanych, test na oryginalnym PNG

Format	Q	F1-macro	F1-micro	mAP	Hamming acc
JPEG	100	0,612	0,767	0,653	0,880
JPEG	85	0,619	0,771	0,652	0,881
JPEG	70	0,610	0,764	0,646	0,876
JPEG	50	0,619	0,778	0,647	0,886
JPEG	30	0,607	0,751	0,634	0,867
JPEG	10	0,574	0,734	0,625	0,864
JPEG2000	100	0,624	0,781	0,662	0,888
JPEG2000	85	0,609	0,776	0,654	0,886
JPEG2000	70	0,611	0,760	0,632	0,874
JPEG2000	50	0,605	0,755	0,628	0,871
JPEG2000	30	0,609	0,765	0,634	0,879
JPEG2000	10	0,589	0,744	0,631	0,865
AVIF	100	0,613	0,776	0,647	0,888
AVIF	85	0,613	0,760	0,654	0,873
AVIF	70	0,614	0,767	0,645	0,878
AVIF	50	0,606	0,752	0,637	0,868
AVIF	30	0,610	0,757	0,647	0,871
AVIF	10	0,619	0,772	0,648	0,881

Tabela 4: Eksperyment A, EfficientNet-B0: trening na danych skompresowanych, test na oryginalnym PNG

Format	Q	F1-macro	F1-micro	mAP	Hamming acc
JPEG	100	0,562	0,758	0,624	0,888
JPEG	85	0,578	0,764	0,619	0,888
JPEG	70	0,553	0,733	0,605	0,870
JPEG	50	0,585	0,760	0,614	0,884
JPEG	30	0,574	0,752	0,620	0,879
JPEG	10	0,530	0,763	0,616	0,894
JPEG2000	100	0,570	0,750	0,616	0,880
JPEG2000	85	0,581	0,764	0,619	0,887
JPEG2000	70	0,569	0,778	0,625	0,897
JPEG2000	50	0,562	0,780	0,631	0,898
JPEG2000	30	0,573	0,763	0,618	0,887
JPEG2000	10	0,566	0,757	0,614	0,884
AVIF	100	0,580	0,762	0,618	0,885
AVIF	85	0,580	0,766	0,622	0,889
AVIF	70	0,567	0,767	0,625	0,893
AVIF	50	0,581	0,759	0,618	0,885
AVIF	30	0,581	0,762	0,617	0,886
AVIF	10	0,564	0,763	0,621	0,887

8.3.1 Średnie wartości po formatach

W Tabeli 5 zestawiono średnie po sześciu poziomach jakości oraz odchylenie standardowe wewnątrz formatu. Dodatkowo podano różnicę względem modelu bazowego ($\text{gap} = \text{średnia}_{\text{format}} - \text{baseline}$).

Tabela 5: Średnia F1-macro i mAP po wszystkich poziomach Q ($n=6$) względem modelu bazowego

Architektura	Format	$\overline{\text{F1-macro}} \pm \sigma$	gap (F1)	$\overline{\text{mAP}} \pm \sigma$	gap (mAP)
ResNet-50	baseline	0,613	—	0,647	—
ResNet-50	AVIF	$0,612 \pm 0,004$	$-0,001$	$0,646 \pm 0,006$	$-0,001$
ResNet-50	JPEG2000	$0,608 \pm 0,011$	$-0,005$	$0,640 \pm 0,014$	$-0,007$
ResNet-50	JPEG	$0,607 \pm 0,017$	$-0,006$	$0,643 \pm 0,011$	$-0,004$
EfficientNet	baseline	0,580	—	0,618	—
EfficientNet	AVIF	$0,575 \pm 0,008$	$-0,005$	$0,620 \pm 0,003$	$+0,003$
EfficientNet	JPEG2000	$0,570 \pm 0,006$	$-0,010$	$0,621 \pm 0,006$	$+0,003$
EfficientNet	JPEG	$0,564 \pm 0,020$	$-0,017$	$0,616 \pm 0,007$	$-0,001$

8.3.2 Analiza wyników

- Trening na obrazach skompresowanych nie powoduje znaczącej utraty skuteczności** – średnia F1-macro w obrębie każdego formatu różni się od modelu bazowego o mniej niż 0,02, a dla AVIF na ResNet-50 różnica wynosi zaledwie $-0,001$. Wartości te mieszczą się w granicach błędu standardowego dla $N_{\text{test}} = 300$ ($\sim 0,02$); pełna weryfikacja istotności wymaga testów parami zaplanowanych jako kolejny etap. Hipoteza H4 zostaje wstępnie potwierdzona.
- AVIF osiąga najlepsze wyniki w obu architekturach** pod względem średniej F1-macro oraz najmniejszego odchylenia standardowego (ResNet-50: $0,612 \pm 0,004$, EfficientNet-B0: $0,575 \pm 0,008$). Najmniejsza wariancja oznacza, że wpływ poziomu kompresji na skuteczność jest dla AVIF najmniej znaczący – ważna własność z praktycznego punktu widzenia (przewidywalność).
- JPEG ma największą degradację przy ekstremalnej kompresji** – F1-macro spada z 0,612 ($Q = 100$) do 0,574 ($Q = 10$) na ResNet-50 oraz z 0,562 do 0,530 na EfficientNet-B0. Jest to efekt artefaktów blokowych DCT widocznych przy niskich Q . JPEG2000 i AVIF, oparte odpowiednio o transformatę falkową i predykcję wewnątrzzramkową, degradują łagodniej.
- Najlepsze pojedyncze wyniki padają w środku zakresu Q** , nie przy $Q = 100$ – ResNet-50/JPEG2000 najlepszy przy $Q = 100$, ResNet-50/JPEG i EfficientNet-B0/JPEG przy $Q = 50$, ResNet-50/AVIF przy $Q = 10$, EfficientNet-B0/AVIF

przy $Q = 30$. Sugeruje to, że umiarkowana kompresja może pełnić rolę implicitnego mechanizmu regularyzacji.

5. **Efekt regularyzacji przez kompresję** – ResNet-50 trenowany na AVIF $Q = 10$ osiąga F1-macro 0,619, podczas gdy model bazowy 0,613. Mimo $CR \approx 35\times$ model uzyskuje wynik nieznacznie *lepsz*y od modelu trenowanego na czystych PNG. Podobnie dla EfficientNet-B0 z formatami JPEG2000 i AVIF (średnie mAP odpowiednio 0,621 i 0,620 wobec baseline 0,618). Artefakty kompresji prawdopodobnie pełnią rolę augmentacji wprowadzającej szum.
6. **Próg degradacji** – wyraźny spadek F1-macro przy $Q = 10$ widoczny jest dla JPEG w obu architekturach, natomiast nie występuje dla AVIF (ResNet-50) oraz JPEG2000 (EfficientNet-B0). Hipoteza H3 jest zatem potwierdzona warunkowo: próg degradacji istnieje, ale jest *zależny od formatu*.

8.4 Porównanie formatów kompresji

Na podstawie wyników Eksperymentu A oraz porównania z modelami bazowymi można sformułować następujące obserwacje:

- **AVIF** jest najlepszym formatem do treningu modeli AI w obu architekturach – najwyższa średnia F1-macro, najmniejsze odchylenie standardowe i praktycznie zerowy gap od modelu bazowego (ResNet-50: $-0,001$). Format ten osiąga wysoką stabilność wyników niezależnie od poziomu kompresji, co czyni go dobrym wyborem w scenariuszach o zmiennym budżecie pamięciowym.
- **JPEG2000** wypada porównywalnie z AVIF, w szczególności na EfficientNet-B0, gdzie osiąga średnie mAP 0,621 (drobny wzrost wobec baseline 0,618). Stanowi to przesłankę popierającą jego obecność w standardzie DICOM jako preferowanego formatu stratnego. Najlepszy pojedynczy wynik dla ResNet-50 (F1-macro = 0,624, mAP = 0,662 przy $Q = 100$) uzyskano właśnie dla JPEG2000.
- **JPEG** wykazuje najslabszą skuteczność i największą wariancję wśród trzech formatów. Spadek F1-macro przy $Q = 10$ wynosi około 0,04 na ResNet-50 i 0,03 na EfficientNet-B0 – jest to wyraźny sygnał, że JPEG przy niskich Q nie powinien być stosowany do treningu modeli AI w tym zadaniu. Mimo to, dla umiarkowanych poziomów ($Q \geq 50$) JPEG pozostaje akceptowalny.
- **Spójność wniosków między architekturami:** ranking formatów $AVIF \succ JPEG2000 \succ JPEG$ jest identyczny dla ResNet-50 i EfficientNet-B0, mimo pięciokrotnej różnicy w liczbie parametrów. Świadczy to o tym, że obserwowane różnice wynikają z właściwości samych formatów, nie z konkretnej architektury.

- **Bezwzględne różnice są niewielkie:** różnice średnich F1-macro między formatami w obrębie modelu wynoszą 0,005–0,012 punktu, co przy $N_{\text{test}} = 300$ jest na granicy istotności statystycznej (błąd standardowy $\sim 0,02$). Pełna analiza istotności wymaga testów parami (Wilcoxon) zaplanowanych jako kolejny etap.

9 Wnioski

Na podstawie przeprowadzonych eksperymentów sformułowano następujące wnioski w odniesieniu do postawionych hipotez:

1. **Weryfikacja H1 (JPEG2000 vs JPEG):** Hipoteza częściowo potwierdzona. Średnia F1-macro JPEG2000 jest wyższa od JPEG dla obu architektur (ResNet-50: 0,608 wobec 0,607; EfficientNet-B0: 0,570 wobec 0,564). Dla ResNet-50 różnica jest minimalna i mieści się w granicach błędu standardowego, dla EfficientNet-B0 jest wyraźniejsza (0,006 punktu). Mocniejszym argumentem na rzecz H1 jest mniejsza degradacja JPEG2000 przy $Q = 10$ oraz najlepszy pojedynczy wynik na ResNet-50 (F1-macro 0,624) uzyskany dla JPEG2000 $Q = 100$. Pełne potwierdzenie wymaga testów istotności statystycznej.
2. **Weryfikacja H2 (AVIF):** Hipoteza potwierdzona. AVIF osiąga skuteczność co najmniej porównywalną z JPEG2000 przy tym samym współczynniku kompresji, w szczególności wyróżnia się *najmniejszą wariancją* F1-macro w funkcji Q (ResNet-50: $\sigma = 0,004$ wobec 0,011 dla JPEG2000 i 0,017 dla JPEG). Praktyczna własność – przewidywalność wyników niezależnie od stopnia kompresji – czyni AVIF atrakcyjnym wyborem mimo braku obecnej standaryzacji w DICOM.
3. **Weryfikacja H3 (próg degradacji):** Hipoteza potwierdzona warunkowo. Próg degradacji istnieje, lecz *zależy od formatu*: dla JPEG widoczny jest wyraźny spadek F1-macro przy $Q = 10$ na obu architekturach, natomiast dla AVIF i JPEG2000 spadek jest minimalny lub w ogóle nie występuje. Sugeruje to, że nowoczesne formaty kompresji (AV1, falki) zachowują informacje istotne dla modeli AI nawet przy współczynnikach kompresji $\sim 35\times$.
4. **Weryfikacja H4 (kompresja a baseline):** Hipoteza potwierdzona. Średnia F1-macro modeli trenowanych na danych skompresowanych nie różni się istotnie od modelu bazowego trenowanego na PNG (gap od $-0,001$ do $-0,017$ w zależności od formatu i architektury), a w niektórych konfiguracjach kompresja działa wręcz korzystnie (efekt regularyzacji). Najwymowniejszym przykładem jest ResNet-50 trenowany na AVIF $Q = 10$, którego F1-macro (0,619) przewyższa model bazowy (0,613) mimo $CR \approx 35\times$.
5. **Ogólna skuteczność:** F1-macro na poziomie 0,57–0,62 oraz mAP 0,62–0,66 stanowią solidny wynik dla wieloetykietowej klasyfikacji 26 klas przy zaledwie 1000 obrazów treningowych. Hamming accuracy na poziomie 0,87–0,89 pokazuje, że model poprawnie przewiduje większość pojedynczych pozycji w wektorze etykiet.

10 Podsumowanie

W niniejszej pracy przeprowadzono badanie wpływu kompresji stratnej obrazów angiografii wieńcowej na skuteczność dwóch architektur głębokiego uczenia (ResNet-50, EfficientNet-B0) w zadaniu wieloetykietowej klasyfikacji 26 segmentów naczyniowych według schematu SYNTAX Score. Zbadano trzy formaty kompresji (JPEG, JPEG2000, AVIF) na sześciu poziomach Q -równoważnych ($Q = 100, 85, 70, 50, 30, 10$), gdzie dla JPEG2000 i AVIF poziom Q definiowany jest poprzez zgodność współczynnika kompresji z JPEG (*matched compression ratio*), uzyskaną algorytmem wyszukiwania binarnego.

10.1 Realizacja celów

Zrealizowano cele szczegółowe pracy: (1) ujednolicono porównanie trzech formatów kompresji poprzez metodologię dopasowanego współczynnika kompresji, (2) zbadano wpływ kompresji danych treningowych na skuteczność dwóch architektur modeli (ResNet-50 i EfficientNet-B0), (3) przeprowadzono trening modeli bazowych na PNG jako górny punkt odniesienia, (4) zidentyfikowano poziomy kompresji zapewniające najlepszy kompromis między rozmiarem a skutecznością, (5) sformułowano rekomendacje praktyczne. Pełne pomiary PSNR/SSIM po naprawie procedury kompresji JPEG2000 wymagają ponownego wykonania i zostaną uzupełnione w finalnej wersji pracy.

10.2 Rekomendacje praktyczne

Na podstawie uzyskanych wyników można sformułować następujące rekomendacje dla systemów PACS i platform telemedycznych przetwarzających obrazy angiograficzne:

- **AVIF jest rekomendowanym formatem** dla scenariuszy, w których priorytetem jest przewidywalność skuteczności modeli AI niezależnie od poziomu kompresji. Może być stosowany nawet przy agresywnej kompresji ($CR \approx 35\times$, Q -równoważny = 10) bez istotnej utraty F1-macro.
- **JPEG2000 pozostaje dobrym wyborem** – zgodnym ze standardem DICOM i osiągającym najlepsze pojedyncze wyniki na ResNet-50. Zalecany szczególnie dla scenariuszy o wysokich wymaganiach jakościowych (Q -równoważny ≥ 50).
- **JPEG nie powinien być stosowany przy ekstremalnej kompresji** ($Q \leq 10$). Dla umiarkowanych poziomów ($Q \in [50, 100]$) pozostaje akceptowalnym wyborem dzięki prostocie implementacji i powszechnemu wsparciu sprzętowemu.
- **Trening modeli AI w domenie skompresowanej jest bezpieczny** pod warunkiem zgodności domeny treningowej i walidacyjnej. Skuteczność na czystych danych testowych pozostaje porównywalna z modelem bazowym trenowanym wyłącznie na PNG.

10.3 Ograniczenia

- Badanie ograniczone do jednego typu modalności (angiografia rentgenowska) i jednego zbioru danych (ARCADE), co utrudnia generalizację wniosków na inne dziedziny obrazowania medycznego.
- Zadanie SYNTAX Score jest z natury segmentacyjne – niniejsze sformułowanie wieloletykietowe pozwala wykorzystać model klasyfikacyjny, ale nie wykorzystuje pełnej informacji przestrzennej zawartej w maskach segmentacyjnych.
- Każda konfiguracja eksperymentalna wytrenowana została jednokrotnie (jedno ziarno losowe). Aby wykluczyć wpływ pojedynczej fluktuacji i uzyskać przedziały ufności, idealnie należałoby powtórzyć eksperymenty z kilkoma ziarnami.
- Różnice średnich F1-macro między formatami ($\sim 0,005$ – $0,012$) mieszczą się w granicach błędu standardowego dla $N_{\text{test}} = 300$ – w kolejnym etapie należy przeprowadzić testy istotności statystycznej (test Wilcoxona dla par, test t Studenta dla par).
- Implementacja JPEG2000 w bibliotece Pillow (oparta o OpenJPEG) wymagała ręcznej kalibracji parametru `quality_layers` przez wyszukiwanie binarne – wyniki mogą różnić się od profesjonalnych implementacji zgodnych z DICOM.

10.4 Kierunki dalszych badań

- Eksperyment B (trening na danych oryginalnych, test na skompresowanych) – pomiar odporności już wyuczonego modelu na kompresję wejścia w scenariuszach telemedycznych.
- Analiza statystyczna istotności różnic między formatami (testy parami Wilcoxon) z uwzględnieniem korekty na wielokrotne testowanie.
- Powtórzenie eksperymentów z wieloma ziarnami losowymi w celu uzyskania przedziałów ufności.
- Analiza map cech (*feature maps*) za pomocą entropii spektralnej i entropii Shannona w celu zbadania, jak kompresja wpływa na wewnętrzną reprezentację modelu.
- Rozszerzenie badania na zadania segmentacji naczyniowej i detekcji zwężeń, gdzie wpływ kompresji może być bardziej widoczny.
- Walidacja zewnętrzna na drugim zbiorze danych z tej samej dziedziny (np. CADICA, ImageCAS) w celu sprawdzenia, czy wnioski generalizują się poza zbiór ARCADE.

Spis rysunków

Spis tabel

1	Średnie metryki jakości kompresji dla zadania Syntax po naprawie procedury dopasowanego CR (wartości do uzupełnienia w finalnej wersji)	14
2	Wyniki modeli bazowych: trening, walidacja i test na oryginalnym PNG (zadanie Syntax)	14
3	Eksperyment A, ResNet-50: trening na danych skompresowanych, test na oryginalnym PNG	15
4	Eksperyment A, EfficientNet-B0: trening na danych skompresowanych, test na oryginalnym PNG	15
5	Średnia F1-macro i mAP po wszystkich poziomach Q ($n=6$) względem modelu bazowego	16

Bibliografia

- [1] Alliance for Open Media. (2019). *AV1 Image File Format (AVIF)*. <https://aomediacodec.github.io/av1-avif/>
- [2] Ansari, M. M. (2025). Evaluating Stenosis Detection with Grounding DINO, YOLO, and DINO-DETR. *arXiv preprint arXiv:2503.01601*. <https://arxiv.org/abs/2503.01601>
- [3] Gayet, R., Abd El Al, A., Meyer, A., Hennemuth, A., Ivantsits, M. i Popp, A. (2025). Coronary Tree Segmentation and Labelling in X-ray Angiography Images Using Graph Deep Learning. W *Bildverarbeitung für die Medizin 2025*, 235–240. Springer. https://doi.org/10.1007/978-3-658-47422-5_51
- [4] He, K., Zhang, X., Ren, S. i Sun, J. (2016). Deep Residual Learning for Image Recognition. W *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- [5] National Electrical Manufacturers Association. (2024). *DICOM Standard*. <https://www.dicomstandard.org/>
- [6] Popov, A., Sirazitdinov, I., Illarionova, S., Bochkov, V. i Tiulpin, A. (2024). Dataset for Automatic Region-based Coronary Artery Disease Diagnostics Using X-Ray Angiography Images. *Scientific Data*, 11, 20. <https://doi.org/10.1038/s41597-023-02871-z>
- [7] Ren, H., Li, D., Jing, F., Zhang, X., Tian, X., Xie, S., Zhang, E., Wang, R., He, H., He, Y., Xue, Y., Liu, C., Sun, Y. i Cheng, W. (2025). LASF: A Local Adaptive

- Segmentation Framework for Coronary Angiogram Segments. *Health Information Science and Systems*, 13, 19. <https://doi.org/10.1007/s13755-025-00339-5>
- [8] Taubman, D. i Marcellin, M. (2002). *JPEG2000: Image Compression Fundamentals, Standards and Practice*. Springer. <https://doi.org/10.1007/978-1-4615-0799-4>
- [9] Wang, Z., Bovik, A. C., Sheikh, H. R. i Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>
- [10] Yang, Q., Yi, H., Yi, L., Liu, M. i Chen, X. (2025). Accurate Segmentation and Labeling of Coronary Artery Segments in X-ray Angiography with an Improved UNet-based cGAN Architecture. *Biomedical Signal Processing and Control*. <https://doi.org/10.1016/j.bspc.2025.108812>