

Wpływ kompresji obrazu na skuteczność modeli głębokiego uczenia w diagnostyce kardiologicznej

1 Wstęp

Obrazowanie medyczne stanowi fundament współczesnej diagnostyki kardiologicznej. Wraz ze wzrostem liczby wykonywanych badań oraz rozdzielczości obrazów rośnie zapotrzebowanie na efektywne metody przechowywania i przesyłania danych. Kompresja obrazu jest powszechnie stosowanym rozwiązaniem tego problemu, a jej wpływ na jakość obrazu medycznego oraz na skuteczność algorytmów analizy obrazu był przedmiotem licznych badań [11, 12]. Wpływ kompresji na skuteczność automatycznych systemów diagnostycznych opartych na głębokim uczeniu pozostaje jednak niedostatecznie zbadany, w szczególności dla nowszych formatów oraz w zadaniu klasyfikacji segmentów tętnic wieńcowych [11].

W niniejszej pracy zbadano wpływ trzech formatów kompresji – JPEG, JPEG2000 oraz AVIF – na skuteczność dwóch architektur głębokiego uczenia (ResNet-50 i EfficientNet-B0) w zadaniu klasyfikacji segmentów tętnic wieńcowych w obrazach angiografii rentgenowskiej. Każdy obraz angiograficzny zawiera kilka segmentów naczyniowych z różnych klas, dlatego problem sformułowano jako klasyfikację wieloetykietową (*multi-label*). Przeprowadzono trzy komplementarne eksperymenty: Eksperyment A (trening na danych skompresowanych, ewaluacja na oryginałach), Eksperyment B (trening na oryginałach, ewaluacja na danych skompresowanych) oraz Eksperyment C (trening na danych o mieszanej kompresji, ewaluacja na oryginałach i na danych skompresowanych); dodatkowo zbudowano model bazowy (*baseline*) trenowany i testowany na oryginalnych obrazach PNG jako górny punkt odniesienia. Aby zapewnić uczciwe porównanie formatów, zastosowano metodologię *matched compression ratio* – dla każdego obrazu poziom kompresji JPEG2000 i AVIF dobierany jest tak, aby uzyskać identyczny rozmiar pliku jak JPEG przy zadanym parametrze jakości Q . Badania wykonano na zbiorze danych ARCADE zawierającym 1500 obrazów opatrzonych adnotacjami eksperckimi dla zadania klasyfikacji według schematu SYNTAX Score.

2 Motywacja i kontekst pracy

Systemy archiwizacji obrazów medycznych (PACS – *Picture Archiving and Communication System*) oraz platformy telemedyczne wymagają kompresji danych w celu redukcji kosztów przechowywania i przyspieszenia transmisji. Standard DICOM (*Digital Imaging and Communications in Medicine*) dopuszcza stosowanie kompresji stratnej, w tym formatów JPEG i JPEG2000 [5]; co więcej, towarzystwa radiologiczne (m.in. Royal College of Radiologists oraz Canadian Association of Radiologists) opublikowały zalecane współczynniki kompresji stratnej zależne od modalności i okolicy anatomicznej, uznając taką kompresję za diagnostycznie akceptowalną [11]. Brak jest natomiast jednoznacznych wytycznych dotyczących dopuszczalnego poziomu kompresji w kontekście automatycznej analizy z użyciem modeli głębokiego uczenia.

Jednocześnie modele głębokiego uczenia coraz częściej wspomagają diagnostykę chorób tętnic wieńcowych (CAD – *Coronary Artery Disease*), które pozostają główną przyczyną zgonów na świecie. Angiografia rentgenowska jest złotym standardem w diagnostyce CAD, a automatyczna klasyfikacja segmentów naczyniowych według schematu SYNTAX Score umożliwia obiektywną ocenę stopnia zaawansowania choroby.

Pojawienie się nowoczesnego formatu AVIF (opartego na kodeku AV1, 2019 [1]) otwiera nowe możliwości kompresji, lecz jego przydatność w obrazowaniu medycznym nie została dotychczas zbadana. Niniejsza praca wypełnia tę lukę, porównując trzy formaty kompresji pod kątem ich wpływu na modele AI stosowane w kardiologii.

3 Cele i założenia

3.1 Cel główny

Określenie wpływu kompresji stratnej obrazów angiografii rentgenowskiej na skuteczność modeli głębokiego uczenia w zadaniu klasyfikacji segmentów tętnic wieńcowych.

3.2 Cele szczegółowe

1. Porównanie trzech formatów kompresji (JPEG, JPEG2000, AVIF) pod kątem jakości obrazu mierzonej wskaźnikami PSNR i SSIM.
2. Zbadanie wpływu kompresji danych treningowych na skuteczność modelu, mierzoną względem modelu bazowego trenowanego na danych oryginalnych (Eksperyment A).
3. Zbadanie wpływu kompresji danych testowych na skuteczność modelu wytrenowanego na danych oryginalnych (Eksperyment B).
4. Sprawdzenie, czy trening na danych o mieszanej kompresji (różne poziomy Q jednocześnie) uodparnia model na kompresję danych testowych, nie obniżając skuteczności na danych oryginalnych (Eksperyment C).
5. Wyznaczenie optymalnego poziomu kompresji zapewniającego maksymalną redukcję rozmiaru przy minimalnej utracie skuteczności klasyfikacji.
6. Sformułowanie rekomendacji dla systemów PACS i platform telemedycznych.

3.3 Hipoteza

Postawiono następujące hipotezy badawcze:

- H1: Format JPEG2000, będący standardem DICOM, zapewnia lepsze zachowanie skuteczności modeli AI niż klasyczny JPEG przy porównywalnym stopniu kompresji.
- H2: Format AVIF, dzięki nowoczesnym technikom predykcji wewnątrzramkowej, zachowuje skuteczność modeli na poziomie co najmniej porównywalnym z JPEG2000 przy tym samym współczynniku kompresji.
- H3: Istnieje progowy poziom kompresji, poniżej którego następuje wyraźny spadek skuteczności klasyfikacji, przy czym próg ten zależy od zastosowanego formatu.
- H4: W zadaniu wieloetykietowej klasyfikacji segmentów SYNTAX, przy teście na oryginalnych obrazach PNG, model trenowany na danych skompresowanych nie wykazuje istotnego spadku skuteczności w porównaniu z modelem bazowym; nie można

jednak na tej podstawie wnioskować o braku wpływu kompresji na pełną wartość diagnostyczną angiografii klinicznej.

- H5: Kompresja danych *testowych* (model trenowany na oryginałach, ewaluowany na obrazach skompresowanych) obniża skuteczność modelu, przy czym wielkość spadku zależy od formatu kompresji.
- H6: Trening na danych o mieszanej kompresji (jeden model uczony jednocześnie na obrazach o różnych poziomach Q) łagodzi spadek skuteczności obserwowany przy kompresji danych testowych (H5), nie obniżając przy tym skuteczności na oryginalnych obrazach testowych.

4 Zawartość pracy

Praca składa się z następujących rozdziałów. W rozdziale 5 przedstawiono przegląd literatury dotyczącej kompresji obrazów medycznych oraz zastosowań głębokiego uczenia w angiografii wieńcowej. Rozdział 6 zawiera opis zastosowanych metod, modeli i mierników skuteczności. W rozdziale 7 opisano przebieg eksperymentów, strukturę danych oraz kolejne etapy badania. Rozdział 8 prezentuje uzyskane wyniki w formie tabel i wykresów wraz z ich interpretacją. W rozdziale 9 sformułowano wnioski, a w rozdziale 10 dokonano podsumowania pracy.

5 Przegląd literatury

5.1 Kompresja obrazów medycznych

Kompresja obrazów medycznych jest przedmiotem badań od lat 90. XX wieku, a jej wpływ na jakość diagnostyczną oraz na metryki percepcyjne pozostaje aktywnym obszarem badawczym [11, 12]. Wyróżnia się kompresję bezstratną (zachowującą pełną informację) oraz stratną (wprowadzającą nieodwracalne zmiany). W systemach PACS powszechnie stosowany jest format JPEG2000, włączony do standardu DICOM jako jeden z obsługiwanych formatów kompresji stratnej [5].

Format JPEG (Joint Photographic Experts Group) wykorzystuje dyskretną transformatę kosinusową (DCT) operującą na blokach 8×8 pikseli, co przy niskich poziomach jakości prowadzi do charakterystycznych artefaktów blokowych [8]. Format JPEG2000 stosuje transformatę falkową (DWT – *Discrete Wavelet Transform*), operującą na całym obrazie, dzięki czemu eliminuje artefakty blokowe; wprowadza jednak własne zniekształcenia, przede wszystkim rozmycie oraz artefakty typu *ringing* (oscylacje wokół ostrych krawędzi) [8, 12]. Wykazano ponadto, że jakość obrazu skompresowanego falkowo zależy od jego zawartości – np. dla obrazów CT obecność kości o wysokiej intensywności wpływa na jakość rekonstrukcji przy danym współczynniku kompresji [12].

AVIF (*AV1 Image File Format*) jest formatem kompresji obrazu opartym na kodeku wideo AV1, opublikowanym w 2019 roku [1]. Wykorzystuje techniki predykcji wewnątrzramkowej i transformaty, dzięki czemu uzyskuje wyższą efektywność kompresji niż formaty poprzedniej generacji [1].

5.2 Zbiór danych ARCADE

ARCADE (*Automatic Region-based Coronary Artery Disease diagnostics using x-ray angiography images*) jest publicznie dostępnym zbiorem danych opublikowanym w ramach wyzwania MICCAI 2023. Zbiór zawiera 3000 obrazów angiografii rentgenowskiej opatrzonych adnotacjami eksperckimi podzielonych na dwa podzbiory: 1500 obrazów do klasyfikacji segmentów naczyniowych według schematu SYNTAX Score (26 klas) oraz 1500 obrazów do detekcji zwężeń [6].

5.3 Zastosowania głębokiego uczenia w angiografii wieńcowej

W ostatnich latach opublikowano szereg prac wykorzystujących zbiór ARCADE do różnych zadań diagnostycznych. Architektura LASF oparta na YOLOv8 osiągnęła wysoką skuteczność w segmentacji naczyń wieńcowych, przewyższając architektury U-Net i DeepLabV3Plus [7]. Badanie porównawcze architektur detekcji obiektów (Grounding DINO, YOLO, DINO-DETR) wykazało zróżnicowaną skuteczność w detekcji zwężeń [2]. Mo-

del UCNet oparty na warunkowej sieci generatywnej (cGAN) osiągnął średnią miarę F1 84,43% w klasyfikacji 20 segmentów tętnic wieńcowych [10]. Zastosowanie grafowych sieci konwolucyjnych do reprezentacji struktury drzewa wieńcowego pozwoliło na osiągnięcie miary F1 równej 53,68 [3].

Żadna z dotychczasowych prac nie badała jednak wpływu kompresji obrazu na skuteczność modeli klasyfikacji w angiografii wieńcowej, co stanowi istotną lukę badawczą.

6 Materiały i metody

6.1 Formaty kompresji

6.1.1 JPEG

Format JPEG wykorzystuje dyskretną transformatę kosinusową (DCT) stosowaną na blokach 8×8 pikseli. Współczynniki DCT podlegają kwantyzacji sterowanej natywnym parametrem jakości $Q \in [1, 100]$, gdzie wyższe wartości oznaczają mniejszą stratę informacji. Parametr Q jest bezpośrednim argumentem wejściowym kodera JPEG i nie ma odpowiednika w innych formatach. Przy niskich wartościach Q pojawiają się charakterystyczne artefakty blokowe na granicach bloków DCT. Kompresja JPEG jest zawsze stratna – nawet wartość $Q = 100$ wprowadza niewielkie zniekształcenia kwantyzacyjne, wizualnie nierozróżnialne od oryginału.

6.1.2 JPEG2000

Format JPEG2000 wykorzystuje dyskretną transformatę falkową (DWT), operującą na całym obrazie zamiast na blokach. Eliminuje to artefakty blokowe i umożliwia progresywną dekompresję, wprowadza jednak własne zniekształcenia – rozmycie drobnych struktur oraz artefakty typu *ringing* wokół ostrych krawędzi [8, 12]. Format JPEG2000 jest jednym z formatów kompresji stratnej obsługiwanych przez standard DICOM; przedmiotem rekomendacji towarzystw radiologicznych nie jest jednak sam format, lecz dopuszczalne współczynniki kompresji dla poszczególnych modalności, formułowane zarówno dla JPEG, jak i JPEG2000 [11]. JPEG2000 *nie posiada* natywnego parametru Q analogicznego do JPEG – stopień kompresji jest sterowany docelową przepływnością (*rates*) lub liczbą warstw jakościowych (*quality layers*). Format obsługuje zarówno tryb stratny (*irreversible*, transformata 9/7), jak i bezstratny (*reversible*, transformata 5/3).

6.1.3 AVIF

Format AVIF bazuje na kodeku wideo AV1, wykorzystując zaawansowane techniki predykcji wewnątrzramkowej z blokami o zmiennym rozmiarze (od 4×4 do 64×64 pikseli). AVIF *nie posiada* natywnego parametru Q identycznego z JPEG – biblioteka Pillow eksponuje parametr `quality` $\in [0, 100]$, lecz jego skala i mapowanie na bitrate są różne od JPEG, a format obsługuje też tryb bezstratny.

6.1.4 Definicja Q -równoważnego dla JPEG2000 i AVIF

Aby umożliwić uczciwe porównanie trzech formatów na tych samych poziomach kompresji, w niniejszej pracy przyjęto metodologię Q -równoważnego (*Q-equivalent*) opartą

na **dopasowanym współczynniku kompresji** (*matched compression ratio*). Procedura jest następująca:

1. Dla każdego oryginalnego obrazu wyznaczany jest rozmiar jego surowego (nieskompresowanego) bufora pikseli $S_{\text{raw}} = H \cdot W \cdot C$ (8 bitów na próbkę), zgodnie z definicją CR w podrozdziale 6.2.3.
2. Obraz jest kompresowany do JPEG przy natywnym parametrze $Q \in \{10, 20, 30, 40, 50, 60, 70, 75, 80\}$, co daje rozmiar pliku $S_{\text{JPEG}}(Q)$ oraz **referencyjny** współczynnik kompresji $\text{CR}_{\text{ref}}(Q) = S_{\text{raw}}/S_{\text{JPEG}}(Q)$.
3. Dla JPEG2000 i AVIF docelowy rozmiar pliku jest ustalony jako $S_{\text{cel}} = S_{\text{JPEG}}(Q)$. JPEG2000 pozwala wprowadzić sterować przepływnością bezpośrednio (parametr docelowej przepływności, w użytej implementacji `quality_layers` w trybie `rates`), jednak celem nie jest tu ustalona przepływność, lecz odtworzenie rozmiaru konkretnego pliku JPEG dla danego obrazu; AVIF z kolei sterowany jest parametrem `quality` o odmiennej skali, niemającym bezpośredniego przełożenia na rozmiar. Aby zapewnić jednolitą procedurę i precyzyjne dopasowanie do S_{cel} , dla obu formatów zastosowano **algorytm wyszukiwania binarnego** po parametrze sterującym kompresją, do osiągnięcia $|S_{\text{wyj}} - S_{\text{cel}}|$ poniżej tolerancji 5% lub po 20 iteracjach.
4. Wynikowe pliki JPEG2000 i AVIF mają rozmiar zbliżony do JPEG przy danym Q (w granicach tolerancji 5%, nie jest on identyczny), a więc porównywalny współczynnik kompresji, co umożliwia bezpośrednie porównanie skuteczności formatów przy ustalonym budżecie pamięciowym.

Etykieta Q stosowana w dalszej części pracy dla JPEG2000 i AVIF **nie odnosi się** zatem do natywnego parametru jakości tych formatów, lecz oznacza *poziom kompresji równoważny JPEG przy parametrze jakości Q* . Wszystkie trzy formaty są w niniejszej pracy stratne dla każdego Q , łącznie z $Q = 100$, ponieważ docelowy rozmiar dla JPEG2000 i AVIF jest dyktowany przez stratny JPEG $Q = 100$ (typowo $\text{CR} \approx 4\times$ względem surowego bufora pikseli). Tryb bezstratny formatów nie jest w niniejszej pracy wykorzystywany.

6.2 Mierniki jakości obrazu

6.2.1 PSNR (Peak Signal-to-Noise Ratio)

Szczytowy stosunek sygnału do szumu wyrażony w decybelach:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right) \quad (1)$$

gdzie MAX_I to maksymalna wartość piksela (255 dla obrazów 8-bitowych), a MSE to średni błąd kwadratowy między obrazem oryginalnym a skompresowanym. Wartości powyżej 40 dB wskazują na bardzo wysoką jakość, wartości 30–40 dB na akceptowalną jakość, natomiast wartości poniżej 30 dB na istotną degradację.

6.2.2 SSIM (Structural Similarity Index Measure)

Wskaźnik podobieństwa strukturalnego [9] porównujący luminancję, kontrast i strukturę:

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

gdzie μ_x, μ_y to średnie, σ_x^2, σ_y^2 to wariancje, σ_{xy} to kowariancja, a C_1, C_2 to stałe stabilizacyjne. SSIM przyjmuje wartości z przedziału $[0, 1]$, gdzie 1 oznacza identyczność obrazów.

6.2.3 Współczynnik kompresji

Stosunek rozmiaru nieskompresowanego (surowego) bufora pikseli do rozmiaru pliku skompresowanego:

$$CR = \frac{S_{\text{raw}}}{S_{\text{skompresowany}}}, \quad S_{\text{raw}} = H \cdot W \cdot C \cdot \frac{\text{bity}}{8} \quad (3)$$

gdzie S_{raw} to rozmiar surowego obrazu w bajtach ($H \times W$ pikseli, C kanałów, 8 bitów na próbkę). Przyjęcie surowego bufora (a nie rozmiaru bezstratnego pliku PNG) jako odniesienia jest zgodne z konwencją ISO 15444 / DICOM i zapewnia, że CR mierzy bezwzględny stopień kompresji informacji obrazowej, niezależnie od formatu źródłowego.

6.3 Sformułowanie problemu: klasyfikacja wieloetykietowa

Każdy obraz w zbiorze ARCADE/Syntax zawiera średnio około pięciu segmentów naczyniowych, należących typowo do różnych klas wśród 26 zdefiniowanych przez schemat SYNTAX Score. Próba sprowadzenia adnotacji do pojedynczej etykiety dominującej prowadzi do silnie zaszumionego sygnału. Analiza adnotacji wykazała, że w 99,3% obrazów zbioru treningowego wszystkie klasy obecne w obrazie występują z jednakową częstością. W konsekwencji wybór klasy dominującej nie wynika z zawartości obrazu, lecz jest determinowany wyłącznie kolejnością zapisania adnotacji w pliku. Z tego powodu w niniejszej pracy zastosowano sformułowanie **wieloetykietowe** (*multi-label*). Model niezależnie przewiduje obecność lub brak każdej z 26 klas w obrazie, a etykietą obrazu jest wektor binarny $\mathbf{y} \in \{0, 1\}^{26}$. Klasa k jest uznawana za obecną (pozycja k równa 1), jeśli w obrazie występuje co najmniej jeden segment oznaczony tą klasą.

6.4 Modele klasyfikacji

Do klasyfikacji segmentów tętnic wieńcowych wykorzystano dwie architektury sieci konwolucyjnych: **ResNet-50** [4] oraz **EfficientNet-B0** [13], obie z wagami wstępnie nauczonymi na zbiorze ImageNet. Strojenie sieci wstępnie nauczonych na ImageNet jest standardową i skuteczną strategią w analizie obrazów medycznych, dorównującą lub przewyższającą trening od podstaw, zwłaszcza przy ograniczonej liczbie obrazów treningowych [14]. Warstwa wyjściowa w obu modelach została zastąpiona warstwą w pełni połączoną z 26 neuronami odpowiadającymi klasom SYNTAX Score, bez aktywacji końcowej – prawdopodobieństwa są wyliczane przez funkcję sigmoid w funkcji kosztu.

ResNet-50 [4] jest jedną z najczęściej stosowanych architektur w analizie obrazów medycznych i stanowi powszechnie przyjmowany punkt odniesienia [14]. EfficientNet-B0 [13], mimo pięciokrotnie mniejszej liczby parametrów (5,3 mln wobec 25,5 mln dla ResNet-50), uzyskuje na ImageNet porównywalną dokładność i może być atrakcyjnym wyborem dla zastosowań o ograniczonych zasobach obliczeniowych. Porównanie obu modeli pozwala ocenić, czy wnioski dotyczące wpływu kompresji są niezależne od wyboru architektury.

6.5 Funkcja kosztu i ważenie klas

Z uwagi na znaczne nie zrównoważenie klas w zbiorze ARCADE/Syntax (klasa najczęstsza obecna w 536 obrazach treningowych z 1000, klasa najrzadsza w zaledwie jednym obrazie, a jedna z 26 klas nie występuje w ogóle w zbiorze treningowym) zastosowano funkcję kosztu **Binary Cross-Entropy with Logits** z wagą pozytywną (*pos_weight*) wyliczaną osobno dla każdej z 26 klas jako stosunek liczby próbek negatywnych do pozytywnych w zbiorze treningowym:

$$w_k^+ = \frac{N - n_k^+}{n_k^+}, \quad (4)$$

gdzie n_k^+ to liczba obrazów zawierających klasę k , a N to całkowita liczba obrazów treningowych. Mechanizm ten zwiększa wkład rzadkich klas w funkcję kosztu i przeciwdziała zjawisku, w którym model uczy się przewidywać wyłącznie najczęstsze klasy.

6.6 Mierniki skuteczności klasyfikacji wieloetykietowej

W klasyfikacji wieloetykietowej standardowa dokładność typu top-1 nie jest miarodajna, ponieważ każdy obraz ma kilka prawdziwych etykiet jednocześnie. Zastosowano następujące mierniki obliczane na zbiorze testowym po progowaniu wyjść sigmoidalnych przy wartości 0,5:

6.6.1 F1-macro i F1-micro

Dla każdej klasy k wyznaczana jest miara F1 jako średnia harmoniczna precyzji i czułości. *F1-macro* to nieważona średnia F1 po wszystkich klasach (równa waga każdej klasy, niezależnie od jej liczebności), *F1-micro* agreguje TP, FP i FN globalnie przed wyliczeniem F1 (waga proporcjonalna do liczebności klasy).

6.6.2 Hamming accuracy

Odsetek poprawnie przewidzianych pozycji w wektorze etykiet, uśredniony po wszystkich obrazach i klasach:

$$\text{Hamming acc} = 1 - \frac{1}{N \cdot K} \sum_{i=1}^N \sum_{k=1}^K \mathbb{1}[\hat{y}_{ik} \neq y_{ik}], \quad (5)$$

gdzie N to liczba obrazów, $K = 26$ liczba klas, a $\mathbb{1}[\cdot]$ funkcja wskaźnikowa (równa 1, gdy warunek jest spełniony, i 0 w przeciwnym razie). Miarę tę raportujemy, ponieważ – w odróżnieniu od subset accuracy – nie karze całego obrazu za pojedynczą pomyłkę i ocenia skuteczność na poziomie pojedynczych etykiet.

6.6.3 Subset accuracy

Odsetek obrazów, dla których *wszystkie* 26 etykiet zostało przewidzianych poprawnie:

$$\text{Subset acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[\hat{\mathbf{y}}_i = \mathbf{y}_i]. \quad (6)$$

Jest to bardzo rygorystyczna miara – wystarczy jedna pomyłka, aby obraz został zaliczony jako błędny. Z uwagi na jej niski poziom i ograniczoną informacyjność (rzędu 0,10–0,14, por. Tabela 2) raportujemy ją jedynie dla modeli bazowych; w analizie porównawczej Eksperymentu A opieramy się na mAP (zob. podrozdział 6.6.4), F1 oraz Hamming accuracy.

6.6.4 mAP (mean Average Precision)

Dla każdej klasy obecnej w zbiorze testowym wyznaczana jest średnia precyzja (AP), będąca polem pod krzywą precyzja–czułość, a zatem niezależna od wyboru progu klasyfikacji; wartości AP są następnie uśredniane makroskopowo po klasach. mAP jest powszechnie stosowaną miarą w zadaniach wieloetykietowych oraz w wyszukiwaniu informacji.

7 Eksperyment

7.1 Schemat eksperymentu

Przeprowadzono badanie składające się z następujących etapów:

1. **Przygotowanie danych** – pobranie zbioru ARCADE (1500 obrazów PNG dla zadania Syntax).
2. **Kompresja JPEG** – wygenerowanie skompresowanych wersji obrazów dla trzynastu poziomów jakości ($Q \in \{10, 20, 30, 40, 50, 60, 70, 75, 80, 85, 90, 95, 100\}$); zapisanie referencyjnego rozmiaru pliku $S_{\text{JPEG}}(Q)$ dla każdego obrazu i poziomu.
3. **Kompresja JPEG2000 i AVIF z dopasowanym CR** – dla każdego obrazu i poziomu Q algorytm wyszukiwania binarnego dobiera parametr sterujący tak, aby wynikowy rozmiar pliku zbliżyć do $S_{\text{JPEG}}(Q)$ (procedura opisana w podrozdziale 6.1.4).
4. **Pomiar jakości kompresji** – obliczenie PSNR, SSIM i współczynnika kompresji dla wszystkich wariantów.
5. **Trening modelu bazowego** – trening ResNet-50 i EfficientNet-B0 na oryginalnych obrazach PNG, walidacja i test również na PNG. Stanowi to górny punkt odniesienia dla Eksperymentu A.
6. **Eksperyment A** – trening modeli na danych skompresowanych z walidacją w tej samej domenie (te same Q i format) oraz ewaluacja końcowa na oryginalnych danych testowych PNG.
7. **Eksperyment B** – scenariusz odwrotny: model bazowy (trenowany na PNG) ewaluowany na *skompresowanym* zbiorze testowym dla każdego formatu i poziomu Q .
8. **Eksperyment C** – trening jednego modelu na danych o *mieszanej* kompresji (losowy poziom Q przy każdym dostępie do obrazu, kompresja jako augmentacja) i ewaluacja zarówno na oryginalnych PNG, jak i na każdym poziomie Q – sprawdzenie, czy ekspozycja na artefakty w treningu łagodzi spadek z Eksperymentu B.
9. **Analiza wyników** – porównanie formatów oraz wyznaczenie wpływu kompresji danych treningowych (Eksperyment A), testowych (Eksperyment B) i mieszanej kompresji treningu (Eksperyment C) względem modelu bazowego.

7.2 Opis danych

Zbiór ARCADE zawiera 3000 obrazów angiografii rentgenowskiej tętnic wieńcowych o rozdzielczości 512×512 pikseli w formacie PNG. Dane podzielone są na dwa zadania:

- **Syntax** (1500 obrazów) – klasyfikacja segmentów naczyniowych do 26 klas według schematu SYNTAX Score.
- **Stenosis** (1500 obrazów) – segmentacja zwężeń naczyniowych.

W niniejszej pracy wykorzystano wyłącznie podzbiór Syntax (26 klas). Podzbiór Stenosis zawiera adnotacje segmentacyjne wyłącznie jednej kategorii („stenosis”), dlatego nie stanowi odpowiedniego zbioru do badań nad klasyfikacją wieloetykietową.

Podzbiór Syntax wykorzystuje podział: trening (1000 obrazów), walidacja (200 obrazów) i test (300 obrazów). Adnotacje zapisane są w formacie COCO JSON. Każdy obraz zawiera zwykle kilka adnotacji segmentacyjnych z różnych klas; dla potrzeb klasyfikacji wieloetykietowej (zob. podrozdział 6.3) etykietę obrazu stanowi 26-elementowy wektor binarny, w którym wartość 1 oznacza obecność co najmniej jednego segmentu danej klasy, a 0 – jej brak.

7.3 Procedura kompresji

Dla każdego z 1500 oryginalnych obrazów PNG zadania Syntax wygenerowano 39 wersji skompresowanych (3 formaty $\times$ 13 poziomów jakości). JPEG kompresowano natywnym parametrem Q (subsampling 4:4:4 dla zachowania pełnej rozdzielczości chrominancji w obrazach medycznych). JPEG2000 i AVIF kompresowano przy użyciu wyszukiwania binarnego po parametrze sterującym, do osiągnięcia rozmiaru pliku odpowiadającego JPEG dla tego samego obrazu i tego samego Q z tolerancją 5% (zob. podrozdział 6.1.4). Kompresję przeprowadzono z wykorzystaniem biblioteki Pillow (JPEG, JPEG2000) oraz wtyczki `pillow-avif-plugin` (AVIF). Wszystkie skompresowane obrazy zostały zapisane na dysku, a następnie ponownie wczytane do macierzy numerycznych w celu obliczenia metryk jakości obrazu.

7.4 Konfiguracja treningu

Parametry treningu identyczne dla obu modeli:

- Architektury: ResNet-50 oraz EfficientNet-B0, obie z wagami wstępnie wytrenowanymi na ImageNet (biblioteka `timm`); ostatnia warstwa zastąpiona warstwą w pełni połączoną o 26 wyjściach
- Funkcja kosztu: `BCEWithLogitsLoss` z per-klasowym `pos_weight` wyliczanym ze zbioru treningowego
- Rozmiar wejścia: 224×224 pikseli (skalowanie z oryginalnych 512×512 , podyktowane wymaganiami modeli wstępnie wytrenowanych na ImageNet)
- Optymalizator: Adam ($\beta_1 = 0,9$, $\beta_2 = 0,999$, weight decay = 10^{-4})

- Szybkość uczenia: 10^{-4} z harmonogramem cosine annealing
- Wielkość batcha: 16
- Liczba epok: do 50 z wczesnym zatrzymaniem (*patience* = 10 epok, kryterium: F1-macro na zbiorze walidacyjnym)
- Normalizacja: średnia i odchylenie standardowe ze zbioru ImageNet
- Augmentacja treningowa: losowy obrót ($\pm 15^\circ$) oraz drobne zaburzenia jasności, kontrastu i saturacji ($\pm 0,1$). **Świadomie nie zastosowano odbicia poziomego** – anatomia tętnic wieńcowych jest asymetryczna (lewa tętnica wieńcowa obejmuje segmenty 5–15, a prawa segmenty 1–4), więc odbicie zmieniałoby przypisanie klas.
- Walidacja i test: bez augmentacji, jedynie skalowanie
- Mieszana precyzja (AMP) na karcie GPU z CUDA
- Ziarno losowe: 42 (dla powtarzalności wyników)

Trening i ewaluacja przebiegały zgodnie z zasadą zachowania domeny: model trenowany na obrazach skompresowanych formatem F z poziomem Q jest **walidowany na obrazach z tej samej domeny** (F, Q). Końcowa ewaluacja na zbiorze testowym jest natomiast wykonywana na **oryginalnych obrazach PNG** – pytanie badawcze brzmi: *czy model wytrenowany na obrazach skompresowanych potrafi generalizować na dane wysokiej jakości?*

7.5 Eksperyment A: Trening na danych skompresowanych

W Eksperymentcie A zbadano wpływ jakości danych treningowych na końcową skuteczność modelu. Dla każdego formatu kompresji ($\in \{\text{JPEG}, \text{JPEG2000}, \text{AVIF}\}$), poziomu jakości ($Q \in \{10, 20, 30, 40, 50, 60, 70, 75, 80, 85, 90, 95, 100\}$) oraz architektury ($\in \{\text{ResNet-50}, \text{EfficientNet-B0}\}$) wytrenowano oddzielny model. Łącznie wykonano 78 treningów Eksperymentu A oraz dwa treningi modeli bazowych (po jednym dla każdej architektury), co daje 80 trenowanych modeli.

7.6 Eksperyment B: Ewaluacja na danych skompresowanych

Eksperyment B stanowi lustrzane odbicie Eksperymentu A: bada wpływ kompresji danych *testowych* (a nie treningowych) na skuteczność modelu. Wykorzystano *ten sam* model bazowy (trenowany i walidowany wyłącznie na nieskompresowanych obrazach PNG), który następnie ewaluowano na skompresowanym zbiorze testowym – osobno dla każdego formatu ($\in \{\text{JPEG}, \text{JPEG2000}, \text{AVIF}\}$) i poziomu Q . Scenariusz ten odpowiada sytuacji praktycznej, w której model wytrenowany w środowisku badawczym (na czystych

danych) jest wdrażany w systemie kompresującym obraz przed analizą (np. PACS lub telemedycyna).

Kluczową cechą metodologiczną Eksperymentu B jest to, że **nie odbywa się w nim żaden trening** – jest to czysta ewaluacja jednego, ustalonego modelu na różnych wariantach danych wejściowych. W konsekwencji ewentualny spadek skuteczności *nie może* być przypisany losowości treningu (jednemu ziarnu), w odróżnieniu od zmienności obserwowanej w Eksperymentcie A – jest deterministycznym efektem kompresji danych testowych. Łącznie wykonano $2 \times 3 \times 13 = 78$ ewaluacji (2 architektury, 3 formaty, 13 poziomów Q).

7.7 Eksperyment C: Trening na mieszanej kompresji

Eksperyment C odpowiada na pytanie wynikające z Eksperymentu B: skoro model trenowany na PNG traci skuteczność na skompresowanym wejściu (zwłaszcza dla JPEG), to czy *celowa* ekspozycja na artefakty kompresji w treningu uodparnia go na to przesunięcie domeny? Scenariusz ten zaproponowała promotorka jako praktyczne rozwinięcie Eksperymentu B.

W odróżnieniu od Eksperymentu A, w którym każdy model trenowano przy *ustalonym* poziomie Q , w Eksperymentcie C poziom Q jest **losowany przy każdym dostępie do obrazu** ze zbioru $Q \in \{10, 20, \dots, 95, 100\}$ danego formatu – kompresja pełni więc rolę augmentacji danych, a model w trakcie treningu widzi pełen zakres artefaktów. Walidacja używa *deterministycznego* przypisania Q do obrazu (poziom wyznaczany funkcją skrótu z identyfikatora obrazu), tak aby sygnał wczesnego zatrzymania był stabilny, lecz reprezentatywny dla całego zakresu. Pozostałe parametry treningu (architektury, optymalizator, augmentacja, ziarno) są identyczne jak w Eksperymentcie A.

Każdy wytrenowany model ewaluowano następnie **dwukrotnie**: (i) na oryginalnym zbiorze testowym PNG – co stanowi kluczowy, *niecyrkularny* sprawdzian, ponieważ obrazy PNG **nie** wchodzi w skład mieszanki treningowej; oraz (ii) na każdym z 13 poziomów Q danego formatu, co pozwala bezpośrednio porównać przebieg skuteczności z Eksperymentem B. Wytrenowano po jednym modelu na każdy format i architekturę ($2 \times 3 = 6$ treningów), a każdy poddano $1 + 13 = 14$ ewaluacjom. Analizę ograniczono do skali opisowej: przy pojedynczym ziarnie na warunek ($n = 1$) zarówno w Eksperymentcie B, jak i C, formalny test istotności różnicy B–C nie byłby uprawniony, dlatego raportujemy spłaszczenie krzywej (spadek $Q_{100} \rightarrow Q_{10}$ oraz Spearman ρ), a nie jego istotność.

8 Wyniki


8.1 Jakość kompresji

Pomiary jakości obrazu przeprowadzono na zbiorze treningowym (1000 obrazów $\times$ 13 poziomów $Q \times 3$ formaty). Procedura dopasowanego CR (zob. podrozdział 6.1.4) działa poprawnie: przy każdym poziomie Q wszystkie trzy formaty osiągają niemal identyczny współczynnik kompresji (mediana błędu względem JPEG $\approx 2\text{--}3\%$, w granicach założonej tolerancji 5%). Wyjątkiem jest $Q = 100$: JPEG2000 i AVIF mają praktyczną dolną granicę kompresji stratnej, która dla analizowanego zbioru odpowiada współczynnikowi kompresji około $4\text{--}5\times$, i nie osiągają tak dużego pliku jak JPEG $Q = 100$, dlatego punkt $Q = 100$ pozostaje poza ścisłym reżimem dopasowanego współczynnika kompresji i jest podawany jedynie informacyjnie.

Tabela 1 przedstawia średnie metryki jakości (uśrednione po obrazach) dla wybranych poziomów Q . Pełny przebieg PSNR/SSIM/CR w funkcji Q ilustruje rysunek 1. Przy dopasowanym CR nowsze formaty zachowują wyższą wierność: dla każdego Q zachodzi $\text{AVIF} \gtrsim \text{JPEG2000} > \text{JPEG}$ zarówno w PSNR, jak i SSIM (np. przy $Q = 50$, CR $\approx 32\times$: PSNR 38,8 / 38,4 / 37,1 dB; przy $Q = 95$, CR $\approx 6,6\times$: 49,6 / 48,9 / 44,2 dB). Uporządkowanie to jest spójne dla średnich i median; dla niewielkiego odsetka ($\sim 2\%$) obrazów o gęstej teksturze wysokoczęstotliwościowej transformata falkowa 9/7 stosowana w JPEG2000 wypada jednak wyraźnie słabiej. Jakość rekonstrukcji falkowej zależy bowiem od zawartości obrazu: przy danym współczynniku kompresji obrazy o dużym udziale składowych wysokoczęstotliwościowych i ostrych krawędziach są rekonstruowane z większym błędem, co wykazano m.in. dla obrazów tomografii komputerowej zawierających struktury o wysokiej intensywności [12]. Efekt ten nieznacznie zaniża *średni* PSNR JPEG2000 dla tej grupy obrazów, lecz nie zmienia rankingu formatów.

Tabela 1: Średnie metryki jakości kompresji dla zadania Syntax (dopasowane CR; wartości uśrednione po 1000 obrazach treningowych). Pełny przebieg na rys. 1.

Format	Q	PSNR [dB]	SSIM	CR
JPEG	95	44,2	0,978	$6,6\times$
JPEG	50	37,1	0,889	$32,3\times$
JPEG	10	32,4	0,759	$107,4\times$
JPEG2000	95	48,9	0,992	$6,6\times$
JPEG2000	50	38,4	0,910	$32,4\times$
JPEG2000	10	35,7	0,838	$107,5\times$
AVIF	95	49,6	0,994	$6,7\times$
AVIF	50	38,8	0,921	$32,3\times$
AVIF	10	36,1	0,849	$107,6\times$



Rysunek 1: Jakość kompresji (PSNR, SSIM, współczynnik kompresji) w funkcji poziomu jakości Q dla trzech formatów przy dopasowanym CR. Oś Q odwrócona – kompresja rośnie w prawo.

8.2 Modele bazowe (trening na oryginalnym PNG)

Tabela 2 przedstawia skuteczność modeli trenowanych i ewaluowanych wyłącznie na oryginalnych obrazach PNG. Wartości te stanowią górny punkt odniesienia dla wszystkich wariantów Eksperymentu A.

Tabela 2: Wyniki modeli bazowych: trening, walidacja i test na oryginalnym PNG (zadanie Syntax)

Architektura	F1-macro	F1-micro	mAP	Hamming acc	Subset acc
ResNet-50	0,678	0,780	0,655	0,887	0,143
EfficientNet-B0	0,628	0,784	0,622	0,900	0,103

8.3 Eksperyment A: Wpływ kompresji danych treningowych

W Tabelach 3 i 4 przedstawiono wyniki Eksperymentu A dla obu architektur. Modele trenowane są na obrazach skompresowanych, walidowane w tej samej domenie (te same Q i format), a testowane na oryginalnych PNG (300 obrazów).

Tabela 3: Eksperyment A, ResNet-50: trening na danych skompresowanych, test na oryginalnym PNG

Format	Q	F1-macro	F1-micro	mAP	Hamming acc
JPEG	100	0,669	0,766	0,650	0,876
JPEG	95	0,668	0,764	0,650	0,874
JPEG	90	0,668	0,769	0,646	0,880
JPEG	85	0,669	0,760	0,650	0,871
JPEG	80	0,672	0,781	0,646	0,888
JPEG	75	0,679	0,780	0,666	0,887
JPEG	70	0,661	0,761	0,640	0,873
JPEG	60	0,667	0,770	0,655	0,880
JPEG	50	0,664	0,770	0,651	0,880
JPEG	40	0,665	0,762	0,640	0,874
JPEG	30	0,666	0,751	0,642	0,864
JPEG	20	0,676	0,769	0,646	0,877
JPEG	10	0,670	0,769	0,650	0,881
JPEG2000	100	0,685	0,778	0,661	0,883
JPEG2000	95	0,665	0,780	0,650	0,888
JPEG2000	90	0,676	0,782	0,662	0,888
JPEG2000	85	0,670	0,771	0,649	0,881
JPEG2000	80	0,674	0,775	0,665	0,884
JPEG2000	75	0,669	0,766	0,628	0,877
JPEG2000	70	0,661	0,779	0,650	0,887
JPEG2000	60	0,674	0,774	0,641	0,883
JPEG2000	50	0,683	0,779	0,645	0,884
JPEG2000	40	0,677	0,787	0,643	0,893
JPEG2000	30	0,679	0,784	0,649	0,889
JPEG2000	20	0,670	0,759	0,649	0,870
JPEG2000	10	0,662	0,748	0,632	0,862
AVIF	100	0,676	0,780	0,654	0,886
AVIF	95	0,672	0,775	0,656	0,883
AVIF	90	0,663	0,769	0,642	0,882
AVIF	85	0,664	0,767	0,658	0,879
AVIF	80	0,671	0,778	0,662	0,886
AVIF	75	0,674	0,772	0,660	0,882
AVIF	70	0,668	0,771	0,650	0,881
AVIF	60	0,680	0,782	0,656	0,888
AVIF	50	0,675	0,773	0,648	0,882
AVIF	40	0,687	0,784	0,659	0,888
AVIF	30	0,667	0,763	0,652	0,876
AVIF	20	0,673	0,761	0,649	0,871
AVIF	10	0,663	0,773	0,641	0,884

Tabela 4: Eksperyment A, EfficientNet-B0: trening na danych skompresowanych, test na oryginalnym PNG

Format	Q	F1-macro	F1-micro	mAP	Hamming acc
JPEG	100	0,611	0,739	0,604	0,858
JPEG	95	0,622	0,759	0,612	0,881
JPEG	90	0,639	0,786	0,628	0,901
JPEG	85	0,623	0,779	0,629	0,899
JPEG	80	0,636	0,784	0,632	0,900
JPEG	75	0,606	0,737	0,602	0,869
JPEG	70	0,611	0,775	0,618	0,895
JPEG	60	0,628	0,768	0,617	0,887
JPEG	50	0,621	0,790	0,634	0,904
JPEG	40	0,632	0,780	0,629	0,896
JPEG	30	0,632	0,775	0,634	0,895
JPEG	20	0,627	0,767	0,628	0,884
JPEG	10	0,547	0,743	0,611	0,886
JPEG2000	100	0,623	0,760	0,611	0,880
JPEG2000	95	0,628	0,792	0,627	0,906
JPEG2000	90	0,627	0,788	0,629	0,904
JPEG2000	85	0,636	0,781	0,634	0,897
JPEG2000	80	0,620	0,744	0,610	0,863
JPEG2000	75	0,628	0,785	0,627	0,902
JPEG2000	70	0,629	0,777	0,629	0,897
JPEG2000	60	0,626	0,746	0,613	0,863
JPEG2000	50	0,631	0,778	0,634	0,896
JPEG2000	40	0,633	0,781	0,636	0,896
JPEG2000	30	0,631	0,763	0,625	0,881
JPEG2000	20	0,611	0,784	0,628	0,901
JPEG2000	10	0,622	0,787	0,622	0,899
AVIF	100	0,623	0,784	0,622	0,900
AVIF	95	0,640	0,783	0,629	0,900
AVIF	90	0,628	0,783	0,635	0,898
AVIF	85	0,623	0,781	0,628	0,899
AVIF	80	0,638	0,776	0,629	0,895
AVIF	75	0,633	0,779	0,631	0,897
AVIF	70	0,629	0,780	0,628	0,897
AVIF	60	0,629	0,772	0,621	0,890
AVIF	50	0,620	0,783	0,631	0,897
AVIF	40	0,643	0,784	0,633	0,898
AVIF	30	0,640	0,777	0,630	0,893
AVIF	20	0,639	0,782	0,635	0,899
AVIF	10	0,626	0,756	0,612	0,866

8.3.1 Średnie wartości po formatach

W Tabeli 5 zestawiono średnie po trzynastu poziomach jakości oraz odchylenie standardowe wewnątrz formatu; przebieg F1-macro w funkcji Q dla obu architektur przedstawia rys. 3. Dodatkowo podano różnicę względem modelu bazowego (średnia w obrębie formatu minus wynik modelu bazowego). Wszystkie różnice – zarówno między formatami, jak i względem modelu bazowego – są rzędu pojedynczych punktów procentowych i mieszczą się w zakresie odchylenia standardowego po Q ($\sigma \approx 0,007$ – $0,024$); ich istotność oceniono formalnie w podrozdziale 8.4.

Tabela 5: Średnia F1-macro i mAP po wszystkich 13 poziomach Q ($n = 13$) względem modelu bazowego

Architektura	Format	$\overline{\text{F1-macro}} \pm \sigma$	różnica (F1)	$\overline{\text{mAP}} \pm \sigma$	różnica (mAP)
ResNet-50	model bazowy	0,678	—	0,655	—
ResNet-50	AVIF	$0,672 \pm 0,007$	$-0,007$	$0,653 \pm 0,007$	$-0,002$
ResNet-50	JPEG2000	$0,673 \pm 0,007$	$-0,006$	$0,648 \pm 0,011$	$-0,007$
ResNet-50	JPEG	$0,669 \pm 0,005$	$-0,009$	$0,648 \pm 0,007$	$-0,006$
EfficientNet-B0	model bazowy	0,628	—	0,622	—
EfficientNet-B0	AVIF	$0,632 \pm 0,007$	$+0,003$	$0,628 \pm 0,006$	$+0,006$
EfficientNet-B0	JPEG2000	$0,626 \pm 0,006$	$-0,002$	$0,625 \pm 0,009$	$+0,003$
EfficientNet-B0	JPEG	$0,618 \pm 0,024$	$-0,010$	$0,621 \pm 0,012$	$0,000$

8.3.2 Analiza wyników

Trening na obrazach skompresowanych nie powoduje utraty skuteczności wykrywalnej w tym planie badawczym. Średnia mAP w obrębie każdego formatu różni się od modelu bazowego o nie więcej niż 0,007 (ResNet-50) i 0,006 (EfficientNet-B0), a różnice te są mniejsze niż odchylenie standardowe wyników po Q ($\sigma \approx 0,007$ – $0,012$ dla mAP) i mieszczą się w granicach szumu treningowego.


Zmienność wyników między poziomami Q należy interpretować jako szum treningu, a nie efekt kompresji. Przemawiają za tym dwie obserwacje. Po pierwsze, wynik modelu bazowego (trening i test na PNG) leży *wewnątrz* rozrzutu wyników modeli trenowanych na danych skompresowanych, a dla kilku poziomów Q modele skompresowane nominalnie go przewyższają (np. EfficientNet-B0/AVIF: średnia mAP 0,628 wobec 0,622). Byłoby to niemożliwe jako realny efekt jakości danych, ponieważ trening na danych zdegradowanych nie może przyczynowo poprawić skuteczności na danych czystych. Po drugie, znak korelacji skuteczności z poziomem Q zmienia się między architekturami (dodatni dla ResNet-50, bliski zeru lub ujemny dla EfficientNet-B0); gdyby istniał rzeczywisty efekt kompresji, zależność byłaby kierunkowo spójna niezależnie od architektury. Obie obserwacje wskazują, że źródłem fluktuacji jest losowość pojedynczego treningu (jedno ziarno na warunek, zob. ograniczenia), a nie „efekt regularyzacji przez kompresję”.

Nie obserwuje się monotonicznego trendu skuteczności względem Q . Korelacja mAP z poziomem Q jest słaba i niespójna: dla ResNet-50 dodatnia (Spearman $\rho \leq 0,63$, w większości nieistotna), dla EfficientNet-B0 bliska zeru lub ujemna. Zmiana znaku korelacji między architekturami wskazuje, że w tym układzie nie istnieje stabilna, wykrywalna zależność między jakością obrazu a skutecznością (rys. 2).


AVIF osiąga nominalnie najwyższą średnią w obu architekturach (mAP 0,653 dla ResNet-50 i 0,628 dla EfficientNet-B0), lecz przewaga ta jest nieistotna statystycznie (po korekcie Holma $p \geq 0,12$) i niespójna między metrykami – dla F1-macro na ResNet-50 nominalnie prowadzi JPEG2000. Stanowi ona zatem co najwyżej drobną tendencję na granicy szumu, a nie dowód przewagi formatu (zob. podrozdział 8.4).

Wniosek o braku istotnej różnicy między formatami jest spójny między architekturami. Mimo pięciokrotnej różnicy w liczbie parametrów oraz silniejszego przeuczenia EfficientNet-B0 (luka trening-walidacja ~ 20 pp), obie architektury prowadzą do tej samej obserwacji jakościowej.

Nie stwierdzono również stabilnego, zależnego od formatu progu degradacji. Pojedyncze spadki (np. EfficientNet-B0/JPEG przy $Q = 10$: F1-macro 0,547) są odosobnionymi punktami mieszczącymi się w rozrzucie pojedynczego ziarna i nie powtarzają się spójnie między architekturami. Przy $N_{\text{test}} = 300$ i $n = 1$ ewentualny próg degradacji rzędu 1–2 pp pozostaje poniżej granicy wykrywalności tego planu badawczego.



Rysunek 2: Eksperyment A: mAP w funkcji poziomu kompresji Q dla ResNet-50 i EfficientNet-B0; pozioma linia przerywana oznacza model bazowy (PNG). Oś Q odwrócona – kompresja rośnie w prawo.



Rysunek 3: Eksperyment A: F1-macro w funkcji poziomu kompresji Q dla obu architektur; pozioma linia przerywana oznacza model bazowy (PNG).

8.4 Analiza statystyczna


Skuteczność formatów porównano w schemacie **sparowanym/blokowym**: poziomy jakości Q stanowią bloki wspólne dla wszystkich trzech formatów (ta sama siatka Q , te same obrazy), więc obserwacje są sparowane względem Q . Zastosowano test omnibus Friedmana (z miarą efektu Kendall's W), a następnie porównania parami sparowanym testem t oraz testem kolejności par Wilcoxona, z korektą Holma-Bonferroniego na wielokrotne porównania. Metryką wiodącą jest mAP (bezprogowa, odporna na nieoptymalność progu 0,5 przy silnym ważeniu klas); F1-macro i Hamming accuracy pełnią rolę pomocniczą.

Test omnibus. Dla mAP test Friedmana nie wykazał istotnych różnic między formatami w żadnej z architektur: ResNet-50 $\chi^2 = 2,00$, $p = 0,37$, $W = 0,08$; EfficientNet-B0 $\chi^2 = 3,23$, $p = 0,20$, $W = 0,12$ (efekt znikomy). Po korekcie Holma żadne z porównań parami nie jest istotne (najniższe skorygowane $p = 0,12$ dla pary AVIF–JPEG na EfficientNet-B0).

Test równoważności (TOST). Brak istotnej różnicy nie jest jeszcze dowodem równoważności, dlatego przeprowadzono dwustronny test równoważności (TOST) dla par formatów. Jako główną granicę równoważności przyjęto $\Delta = \pm 0,02$ mAP (2 pp). Podstawowym uzasadnieniem jest praktyczna nieistotność: różnica skuteczności rzędu 2 punktów procentowych mAP jest pomijalna z punktu widzenia zastosowania wspomagającego decyzję kliniczną. Próg ten jest dodatkowo spójny ze skalą szumu treningowego: odpowiada w przybliżeniu dwukrotności obserwowanego odchylenia standardowego wyników po Q ($\sigma \approx 0,007\text{--}0,012$ mAP), czyli najmniejszej różnicy, którą układ z jednym ziarnem mógłby w ogóle przypisać formatowi, a nie losowości treningu. Przy $\Delta = \pm 0,02$ wszystkie pary formatów są statystycznie równoważne w obu architekturach ($p \leq 0,005$). Jako analizę czułości podano także węższe granice: przy $\Delta = \pm 0,015$ równoważność nadal zachodzi dla wszystkich par ($p \leq 0,013$), a dopiero przy $\Delta = \pm 0,01$ spada do 4 z 6 par (niespełnione

pozostają dwie pary z AVIF, niosące drobną tendencję $\sim 0,5$ pp). Porównanie formatów odnosimy do reżimu dopasowanego CR ($Q = 10\text{--}95$); wykluczenie punktu $Q = 100$ nie zmienia wniosku (Friedman $p = 0,37 / 0,34$; równoważność TOST utrzymana). Należy zaznaczyć, że poziomy Q tworzące pary w teście pochodzą z pojedynczego ziarna treningowego na warunek, więc wynik TOST orzeka równoważność wyłącznie w granicach zmienności wynikającej z siatki Q , nie obejmując zmienności między ziarnami (zob. ograniczenia).

Wierność percepcyjna a skuteczność. Zbadano, czy lepsze metryki jakości obrazu (PSNR/SSIM) przekładają się na skuteczność klasyfikacji (rys. 4). Korelacja mAP z PSNR jest *niespójna między architekturami*: dla ResNet-50 dodatnia (Spearman $\rho \approx +0,45$ dla danych łączonych), dla EfficientNet-B0 bliska zeru/ujemna ($\rho \approx -0,16$, nieistotna). Gdyby wierność percepcyjna realnie determinowała skuteczność, zależność byłaby dodatnia i spójna w obu architekturach. Brak takiej spójności jest dodatkowym argumentem, że przy dopasowanym CR *wyraźna przewaga JPEG2000/AVIF w PSNR/SSIM nie przekłada się na skuteczność klasyfikacji*, a obserwowana zmienność jest zdominowana przez szum treningu. (Korelacje łączone liczone na $n = 39$ punktach mają charakter opisowy – 13 poziomów Q jest współdzielonych przez formaty, a każda komórka to pojedyncze ziarno.)



Rysunek 4: Skuteczność klasyfikacji (mAP testowe) w funkcji średniej wierności percepcyjnej danych treningowych (PSNR). Brak spójnego dodatniego trendu między architekturami wskazuje, że PSNR/SSIM nie są dobrym predyktorem skuteczności w tym zadaniu.

Podsumowanie analizy. Główny wynik należy raportować jako *brak dowodu na wpływ formatu kompresji na skuteczność* (a nie „dowód braku różnicy”), wzmocniony pozytywnym wynikiem testu równoważności przy $\Delta = \pm 0,02$ (oraz $\pm 0,015$). Przy pojedynczym ziarnie na warunek ($n = 1$) ewentualny efekt mniejszy niż $\sim 1\text{--}2$ pp jest poniżej granicy wykrywalności.

8.5 Porównanie formatów kompresji

Na podstawie wyników Eksperymentu A oraz porównania z modelami bazowymi można sformułować kilka obserwacji dotyczących porównania formatów.

Formalna analiza nie wykazała istotnych różnic skuteczności między JPEG, JPEG2000 i AVIF przy dopasowanym współczynniku kompresji (test Friedmana: $p = 0,37$ dla ResNet-50 i $p = 0,20$ dla EfficientNet-B0; wszystkie porównania parami nieistotne po korekcie Holma – zob. podrozdział 8.4). Test równoważności (TOST, $\Delta = \pm 0,02$) potwierdza wręcz praktyczną równoważność wszystkich trzech formatów w obu architekturach.

AVIF osiąga najwyższą średnią mAP w obu architekturach oraz nominalnie najmniejszy rozrzut wyników po Q , jednak wartości te nie zostały potwierdzone formalnie (różnica nieistotna po korekcie Holma; rozrzut nietestowany i na poziomie szumu pojedynczego ziarna), a tendencja jest kierunkowo niespójna między metrykami (dla F1-macro na ResNet-50 prowadzi JPEG2000). Nie uprawnia to do twierdzenia, że AVIF poprawia skuteczność. Z kolei JPEG ma największe odchylenie standardowe F1-macro (na EfficientNet-B0 podbite przez pojedynczy punkt $Q = 10$), lecz nie obserwuje się spójnego, monotonicznego spadku skuteczności przy najsilniejszej kompresji – model trenowany na JPEG $Q = 10$ osiąga wyniki porównywalne z wysokimi Q .

Wniosek o braku istotnej różnicy między formatami jest identyczny dla obu architektur mimo pięciokrotnej różnicy w liczbie parametrów i odmiennego reżimu przeuczenia, co wskazuje, że jest to cecha zadania, a nie pojedynczej architektury. Mimo wyraźnie wyższych wartości PSNR/SSIM dla JPEG2000 i AVIF przy dopasowanym CR przewaga w metrykach percepcyjnych nie przekłada się na skuteczność klasyfikacji (korelacja mAP–PSNR niespójna między architekturami). Przy dopasowanym CR wybór kodeka jest więc raczej decyzją inżynierską (kompatybilność, czas kodowania, wsparcie sprzętowe) niż decyzją wpływającą na skuteczność modelu w badanym zadaniu klasyfikacyjnym.

8.6 Interpretacja: dlaczego poziom kompresji nie wpływa na skuteczność w tym zadaniu

Płaski przebieg skuteczności względem poziomu kompresji Q wymaga komentarza, ponieważ kompresja stratna w sposób wymierny obniża wierność obrazu (spadek PSNR z ~ 49 do ~ 32 dB między $Q = 95$ a $Q = 10$, Tabela 1). Wynik ten nie oznacza, że kompresja jest dla obrazu obojętna, lecz że *przyjęte zadanie jest mało czułe na poziom Q* – z kilku powodów.

Zadanie ma charakter globalny: etykietą jest sama obecność segmentu danej klasy w obrazie, a nie odwzorowanie jego drobnej struktury (przebieg krawędzi naczyń, stopień zwięzienia, tekstura). Rozpoznanie obecności segmentu opiera się na ogólnym położeniu i przebiegu dużych naczyń oraz topologii drzewa wieńcowego, a więc na cechach o niskiej i średniej częstotliwości przestrzennej. Kompresja stratna degraduje natomiast

przede wszystkim odwzorowanie drobnej struktury i wysokich częstotliwości: w kodowaniu transformatowym to składowe wysokoczęstotliwościowe są kwantowane najsilniej [8], a widocznymi przejawami tej degradacji są blokowość JPEG, rozmycie oraz *ringing* JPEG2000 (zob. podrozdział 6.1). Cechy rozstrzygające o etykiecie pozostają więc w dużym stopniu zachowane nawet przy silnej kompresji, co jest spójne z brakiem spadku skuteczności przy $CR \approx 107\times$ ($Q = 10$).

Dodatkowo sieci wstępnie wytrenowane na ImageNet uczą się reprezentacji w znacznym stopniu odpornych na umiarkowane zaburzenia danych wejściowych. Istotna jest też zgodność domeny treningowej i walidacyjnej (ten sam format i poziom Q): model trenowany i walidowany na obrazach o tych samych artefaktach traktuje je jako stałą cechę danych, a nie jako sygnał mylący. Mechanizm ten dotyczy wyłącznie spójności domen i nie stoi w sprzeczności z interpretacją różnic między poziomami Q jako szumu treningu – nie oznacza on, że model czerpie z artefaktów korzyść, lecz że nie jest przez nie wprowadzany w błąd.

Należy podkreślić, że ten brak wpływu jest *kierunkowy*, a nie symetryczny. W Eksperymentcie A trudniejsza (skompresowana) domena treningu poprzedza łatwiejszy test na PNG, i w tym kierunku skuteczność pozostaje płaska; przy odwrotnym kierunku spada (Eksperyment B). Co istotne, model uczy się domeny skompresowanej *poprawnie* nawet przy najsilniejszej kompresji: dla EfficientNet-B0 trenowanego na JPEG $Q = 10$ skuteczność walidacyjna (F1-macro 64,4%) jest praktycznie równa bazowej (64,1%) – spadek, jeśli się pojawia, dotyczy wyłącznie *transferu* na czyste PNG, a nie nauczania się samej domeny. Jedynym odstępstwem od płaskości jest właśnie ten przypadek skrajny: na czystym PNG EfficientNet-B0 trenowany na JPEG $Q = 10$ traci 0,081 F1-macro (przy mAP zmienionym jedynie o $-0,011$). Pokazuje to, że bardzo silna degradacja danych treningowych może utrudnić transfer nawet w stronę łatwiejszej domeny, lecz w metryce progowo-niezależnej (mAP) efekt pozostaje pomijalny, a poza tym pojedynczym punktem skuteczność na PNG jest płaska w całym zakresie Q .

Brak zależności skuteczności od poziomu kompresji nie jest też swoisty dla danych medycznych. Wstępna, niezależna kontrola na zbiorze Fashion-MNIST (klasyfikacja, ten sam protokół: trening na danych skompresowanych, test na oryginałach) odtworzyła ten sam płaski wzorec skuteczności w zakresie $Q = 10\text{--}100$. Choć jest to zadanie o zupełnie innej domenie i rozdzielczości, zgodność wzorca wzmacnia interpretację, że płaskość wynika z ograniczonej *czułości tego planu badawczego na poziom Q* , a nie z ogólnej obojętności obrazu na kompresję.

Wniosek ten ograniczamy do badanego zadania. Brak wykrywalnego wpływu Q na skuteczność dotyczy konkretnie wieloetykietowej klasyfikacji obecności segmentów SYNTAX przy teście na oryginalnych PNG i nie może być uogólniany na inne zastosowania obrazów angiograficznych. Zadania wymagające odwzorowania drobnej struktury – segmentacja granic naczyń, detekcja i ilościowa ocena zwężeń – mogą wykazywać istotnie

większą wrażliwość na kompresję, ponieważ opierają się właśnie na cechach, które kompresja stratna degradoweja najsilniej.


8.7 Eksperyment B: Wpływ kompresji danych testowych

Eksperyment B sprawdza scenariusz odwrotny do Eksperymentu A: model bazowy (trenowany na PNG) jest ewaluowany na skompresowanym zbiorze testowym (zob. podrozdział 7.6). Ponieważ model jest ustalony, a zmienia się jedynie zbiór testowy, ewentualny spadek skuteczności jest deterministycznym efektem kompresji danych wejściowych, a nie szumem treningu. Wyniki przedstawia Tabela 6 oraz rysunek 5.

Tabela 6: Eksperyment B: średnie mAP po 13 poziomach Q ($n = 13$) oraz spadek mAP między $Q = 100$ a $Q = 10$. Model bazowy testowany na obrazach skompresowanych. Wartość bazowa (test na PNG): ResNet-50 mAP = 0,655; EfficientNet-B0 mAP = 0,622.

Architektura	Format	$\overline{\text{mAP}} \pm \sigma$	spadek $Q_{100} \rightarrow Q_{10}$	Spearman ρ
ResNet-50	JPEG	$0,650 \pm 0,010$	+0,033	+0,77**
ResNet-50	JPEG2000	$0,651 \pm 0,003$	+0,012	+0,32
ResNet-50	AVIF	$0,654 \pm 0,004$	-0,005	-0,17
EfficientNet-B0	JPEG	$0,611 \pm 0,030$	+0,109	+0,73**
EfficientNet-B0	JPEG2000	$0,620 \pm 0,006$	+0,016	+0,52
EfficientNet-B0	AVIF	$0,622 \pm 0,006$	+0,020	+0,47

** korelacja istotna na poziomie $p < 0,01$. Dodatkowo ρ oznacza spadek mAP wraz ze wzrostem kompresji (malejące Q).



Rysunek 5: Eksperyment B: mAP w funkcji poziomu kompresji *zbioru testowego* Q (model trenowany na PNG). Linia przerywana – wynik bazowy (test na PNG). Oś Q odwrócona – kompresja rośnie w prawo. W odróżnieniu od Eksperymentu A widoczny jest spadek skuteczności przy silnej kompresji, najsilniejszy dla JPEG.

W odróżnieniu od Eksperymentu A, w którym skuteczność była płaska, Eksperyment B *ujawnia* wpływ kompresji. Dla **JPEG** kompresja danych testowych istotnie obniża

skuteczność: korelacja mAP z poziomem Q jest dodatnia i istotna w obu architekturach (Spearman $\rho = 0,77$, $p = 0,002$ dla ResNet-50; $\rho = 0,73$, $p = 0,005$ dla EfficientNet-B0), a spadek mAP między $Q = 100$ a $Q = 10$ sięga 0,033 (ResNet-50) i 0,109 (EfficientNet-B0). Dla **JPEG2000** i **AVIF** korelacje są słabsze i nieistotne (po korekcji), a spadki nie przekraczają 0,02. Nominalnie najsilniejszą degradację obserwuje się więc dla JPEG; należy jednak zaznaczyć, że bezpośrednie porównanie formatów (test Friedmana z poziomami Q jako blokami) *nie* wykazało istotnej różnicy między nimi ($p = 0,23$ dla ResNet-50, $p = 0,15$ dla EfficientNet-B0). Przy pojedynczej ewaluacji na każdą komórkę moc tego porównania jest ograniczona, dlatego wniosek o przewadze łagodniejszych formatów formułujemy ostrożnie – jako tendencję spójną z charakterem artefaktów (blokowość JPEG), a nie jako różnicę potwierdzoną testem omnibus.

Degradacja JPEG ma przy tym charakter *progowy*, a nie stopniowy. Skuteczność pozostaje nieodróżnialna od wyniku bazowego (test na PNG) aż do $Q \approx 30$, a wyraźny spadek następuje dopiero przy $Q \leq 20$, z załamaniem przy $Q = 10$ (dla EfficientNet-B0 mAP spada wówczas z $\sim 0,62$ do 0,51). Jest to spójne z naturą kompresji DCT: artefakty blokowe i utrata wysokich częstotliwości stają się destrukcyjne dla cienkich struktur naczyniowych dopiero przy bardzo niskiej jakości. Potwierdza to pomiar wierności obrazu przy tej samej, silnej kompresji ($CR \approx 49\times$, $Q = 10$): JPEG osiąga SSIM 0,81 wobec 0,90 dla AVIF i 0,89 dla JPEG2000, a PSNR 33,5 dB wobec ~ 38 dB – nowsze formaty zachowują przy tym samym budżecie pamięciowym wyraźnie wyższą wierność, co tłumaczy ich odporność.

Skala degradacji zależy też od architektury: EfficientNet-B0 traci na JPEG $Q = 10$ około trzykrotnie więcej niż ResNet-50 ($-0,109$ wobec $-0,033$ mAP). Jest to spójne z obserwacjami z Eksperymentu A – EfficientNet-B0 miał niższy wynik bazowy i silniejsze przeuczenie, a zatem mniejszy zapas odporności na przesunięcie rozkładu danych wejściowych. W kontekście praktycznym czyni to ResNet-50 bezpieczniejszym wyborem dla scenariuszy, w których dane wejściowe mogą podlegać kompresji.

Wynik ten ma podwójne znaczenie. Po pierwsze – metodologiczne: dowodzi, że zastoszowany potok pomiarowy *jest czuły* na kompresję obrazu, gdy wpływa ona na zadanie. Płaski wynik Eksperymentu A nie wynika zatem z niewrażliwości aparatu, lecz jest realną własnością tamtego scenariusza. Po drugie – praktyczne: przy kompresji danych *wejściowych* model dotychczas niewidzący artefaktów staje się na nie wrażliwy.

Zestawienie obu eksperymentów ujawnia, że koszt niezgodności domen jest **silnie asymetryczny**, a nie symetryczny. Dla tej samej pary domen (PNG $\leftrightarrow$ JPEG $Q = 10$) decyduje kierunek: gdy artefakty występują wyłącznie w treningu, a test odbywa się na łatwiejszych danych PNG (Eksperyment A), spadek mAP jest pomijalny ($-0,011$ dla EfficientNet-B0 i $-0,008$ F1-macro dla ResNet-50); gdy zaś te same artefakty pojawiają się dopiero w teście (Eksperyment B), spadek jest około siedmio- do dziesięciokrotnie większy ($-0,109$ mAP dla EfficientNet-B0, $-0,053$ F1-macro dla ResNet-50). Gdyby de-

cydowała sama *symetryczna* (nie)zgodność domen, oba kierunki dawałyby porównywalny efekt – tymczasem różnią się o rząd wielkości. Właściwym uogólnieniem jest zatem nie tyle zgodność domen, ile jej *asymetria*: model traci skuteczność na artefaktach kompresji w teście przede wszystkim wtedy, gdy *nie zetknął się z nimi w treningu*, podczas gdy domena wysokiej jakości pozostaje w metryce mAP „łatwa” niezależnie od reżimu treningu (z jednym wyjątkiem skrajnej degradacji treningu, omówionym w podrozdziale 8.6). Ta interpretacja prowadzi bezpośrednio do Eksperymentu C: skoro szkodzą wyłącznie artefakty *nieznane* z treningu, to celowe wprowadzenie ich do treningu powinno spadek zlikwidować.


8.8 Eksperyment C: Trening na mieszanej kompresji

Eksperyment C bezpośrednio testuje powyższą interpretację: jeden model na format trenowano na *mieszance* poziomów Q (kompresja jako augmentacja, zob. podrozdział 7.7), a następnie ewaluowano zarówno na każdym poziomie Q , jak i na oryginalnym PNG. Tabela 7 zestawia spadek mAP ($Q_{100} \rightarrow Q_{10}$) oraz korelację Spearmana dla modelu trenowanego na PNG (Eksperyment B) i na mieszanej kompresji (Eksperyment C); rysunek 6 ilustruje to dla JPEG.

Tabela 7: Eksperyment C wobec B (mAP): spadek mAP między $Q = 100$ a $Q = 10$ oraz Spearman ρ dla modelu trenowanego na PNG (B) i na mieszanej kompresji (C), a także mAP modelu C na oryginalnym PNG (w nawiasie różnica względem modelu bazowego). PNG nie wchodzi w skład mieszanki treningowej. Wartość bazowa (test na PNG): ResNet-50 0,655; EfficientNet-B0 0,622.

Architektura	Format	Eksperyment B		Eksperyment C		C: test PNG
		spadek	ρ	spadek	ρ	
ResNet-50	JPEG	+0,033	+0,77**	+0,007	-0,07	0,659 (+0,005)
ResNet-50	JPEG2000	+0,012	+0,32	-0,001	-0,14	0,659 (+0,004)
ResNet-50	AVIF	-0,005	-0,17	-0,005	-0,38	0,655 (+0,001)
EfficientNet-B0	JPEG	+0,109	+0,73**	+0,009	+0,79**	0,628 (+0,006)
EfficientNet-B0	JPEG2000	+0,016	+0,52	+0,010	+0,81**	0,636 (+0,015)
EfficientNet-B0	AVIF	+0,020	+0,47	+0,002	-0,12	0,626 (+0,004)

** korelacja istotna na poziomie $p < 0,01$. Dodatkowo ρ oznacza spadek mAP wraz ze wzrostem kompresji (malejące Q).



Rysunek 6: Eksperyment C: mAP w funkcji kompresji zbioru testowego dla JPEG – model trenowany na PNG (Eksperyment B, krzywa opadająca) wobec modelu trenowanego na mieszanej kompresji (Eksperyment C, krzywa płaska). Linia przerywana – wynik bazowy (test na PNG). Oś Q odwrócona. Trening mieszany niemal całkowicie likwiduje spadek JPEG.

Trening na mieszanej kompresji *likwiduje* spadek mAP ujawniony w Eksperymentcie B. Najsilniejszy w Eksperymentcie B przypadek – EfficientNet-B0 na JPEG – traci między $Q = 100$ a $Q = 10$ jedynie 0,009 mAP wobec 0,109 poprzednio (redukcja amplitudy około dwunastokrotna); dla ResNet-50 spadek maleje z 0,033 do 0,007. Co kluczowe, dzieje się to **bez kosztu na oryginalnym PNG**: mAP modeli mieszanych na czystym zbiorze testowym jest praktycznie równe modelowi bazowemu (różnice od +0,001 do +0,015). Ponieważ obrazy PNG *nie* wchodzą w skład mieszanki treningowej, jest to sprawdzian niecyrkularny – potwierdza, że uodpornienie na kompresję nie odbywa się kosztem skuteczności na danych wysokiej jakości.

Trzeba jednak precyzyjnie określić zakres tego wniosku. Po pierwsze, redukcja dotyczy *amplitudy* spadku, lecz dla EfficientNet-B0 *monotoniczny trend* nie znika całkowicie: korelacja Spearmana pozostaje dodatnia i istotna (JPEG $\rho = 0,79$, JPEG2000 $\rho = 0,81$; $p < 0,01$), mimo że bezwzględna różnica skuteczności zmalała do poziomu szumu pojedynczego ziarna ($\sim 0,01$ mAP). Trening mieszany należy więc opisywać jako mechanizm, który *silnie łagodzi*, a nie *całkowicie eliminuje* wrażliwość mniejszej architektury na kompresję. Po drugie, demonstracja dotyczy formatu JPEG – jedyne, dla którego Eksperyment B wykazał wyraźny spadek; dla odpornych JPEG2000 i AVIF nie było czego leczyć. Po trzecie, rozkład poziomów Q w treningu celowo pokrywa poziomy Q użyte w teście; nie jest to wyciek danych (podziały treningowy, walidacyjny i testowy pozostają rozłączne na poziomie obrazów), lecz *zamierzone dopasowanie rozkładu* artefaktów, więc wniosek odnosi się do kompresji o poziomach „znanych” z treningu. Wynik opiera się przy tym na pojedynczym ziarnie na warunek ($n = 1$), zgodnie z ograniczeniami całego badania.

Trening mieszany wprowadza też niewielki, lecz systematyczny koszt w metrykach *progowych* dla EfficientNet-B0: na czystym PNG F1-micro i Hamming accuracy spadają

o około 1,8–2,1 pp względem modelu bazowego (np. dla JPEG: F1-micro 0,766 wobec 0,784). Ponieważ mAP – metryka niezależna od progu – jednocześnie nie maleje (a nominalnie rośnie), nie jest to utrata informacji, lecz *przesunięcie kalibracji progu decyzyjnego*: model trenowany na zróżnicowanej jakości wytwarza nieco inaczej wyskalowane prawdopodobieństwa, co przy stałym progu 0,5 obniża metryki progowe. Dla ResNet-50 efekt ten jest pomijalny (zmiany poniżej 0,5 pp, dla JPEG2000 nawet dodatnie).

9 Wnioski

Na podstawie przeprowadzonych eksperymentów sformułowano następujące wnioski w odniesieniu do postawionych hipotez:

1. *H1 (JPEG2000 a JPEG) – nie potwierdzona.* Średnie skuteczności JPEG2000 i JPEG różnią się o ułamki punktu procentowego, a różnica jest nieistotna statystycznie (sparowany test t i Wilcozona po korekcie Holma, $p > 0,3$ dla mAP w obu architekturach), przy czym test równoważności wskazuje na praktyczną równoważność obu formatów. Nie ma więc danych potwierdzających przewagę JPEG2000 nad JPEG w skuteczności klasyfikacji przy dopasowanym CR – mimo wyraźnie wyższej wierności percepcyjnej (PSNR/SSIM) JPEG2000.
2. *H2 (AVIF) – potwierdzona w sensie równoważności.* AVIF osiąga skuteczność statystycznie równoważną z JPEG2000 i JPEG (TOST, $\Delta = \pm 0,02$). Nominalnie najwyższa średnia AVIF oraz najmniejszy rozrzut wyników po Q nie są jednak istotne statystycznie (rozrzut pozostaje na poziomie szumu pojedynczego ziarna i nie był testowany formalnie) i nie stanowią dowodu przewagi.
3. *H3 (próg degradacji) – potwierdzona warunkowo, zależnie od scenariusza.* Przy kompresji danych *treningowych* (Eksperyment A) nie wykryto progu degradacji – skuteczność jest płaska w całym zakresie Q , ponieważ model adaptuje się do artefaktów obecnych w treningu. Próg ujawnia się natomiast przy kompresji danych *testowych* (Eksperyment B, format JPEG): skuteczność pozostaje stabilna do $Q \approx 30$, a wyraźny spadek następuje przy $Q \leq 20$. Próg jest więc zależny od formatu (widoczny dla JPEG, niewidoczny dla JPEG2000/AVIF), zgodnie z hipotezą, lecz dotyczy konkretnie scenariusza kompresji wejścia.
4. *H4 (kompresja a model bazowy) – potwierdzona; główny pozytywny wynik pracy.* Skuteczność modeli trenowanych na danych skompresowanych nie różni się istotnie od modelu bazowego trenowanego na PNG (różnice mAP od $-0,007$ do $+0,006$, w granicach szumu). Przypadki, w których model skompresowany nominalnie przewyższa model bazowy, nie są realnym „efektem regularyzacji”, lecz przejawem szumu pojedynczego ziarna, ponieważ trening na danych zdegradowanych nie może przyczynowo poprawić skuteczności na danych czystych. Poprawnym sformułowaniem wniosku jest zatem brak dowodu na utratę – w badanym zadaniu klasyfikacyjnym, przy teście na oryginalnych PNG – informacji istotnej dla rozpoznania obecności segmentów. Nie jest to równoznaczne z brakiem wpływu kompresji na pełną wartość diagnostyczną angiografii klinicznej, której niniejsza praca nie ocenia.
5. *H5 (kompresja danych testowych) – potwierdzona; wykrywalny efekt kompresji.* W scenariuszu odwrotnym (model trenowany na PNG, test na obrazach skompresowa-

nych) kompresja *istotnie* obniża skuteczność dla formatu JPEG (Spearman $\rho = 0,73$ – $0,77$, $p < 0,01$; spadek mAP do $0,11$ dla EfficientNet-B0), podczas gdy dla JPEG2000 i AVIF degradacja jest słabsza i nieistotna. Ponieważ model jest tu ustalony, jest to efekt deterministyczny, a nie szum treningu. Wynik ten dowodzi zarazem, że zastosowany potok pomiarowy jest czuły na kompresję, gdy ta wpływa na zadanie – co potwierdza, że płaskość Eksperymentu A jest realną własnością tamtego scenariusza. Zestawienie Eksperymentów A i B wskazuje, że koszt niezgodności domen jest *silnie asymetryczny*: dla tej samej pary domen spadek przy artefaktach obecnych wyłącznie w teście (B) jest o rząd wielkości większy niż przy artefaktach obecnych wyłącznie w treningu (A). Decyduje więc nie sama kompresja ani symetryczna (nie)zgodność domen, lecz to, czy model *zetknął się z danym typem artefaktów w treningu*.

6. *H6 (trening na mieszanej kompresji) – potwierdzona dla mAP.* Trening jednego modelu na mieszance poziomów Q (Eksperyment C) niemal całkowicie likwiduje spadek mAP obserwowany w Eksperymentcie B dla JPEG (dla EfficientNet-B0 spadek $Q_{100} \rightarrow Q_{10}$ maleje z $0,109$ do $0,009$), nie obniżając przy tym skuteczności na oryginalnym PNG (mAP w granicach szumu względem modelu bazowego), mimo że PNG nie należy do mieszanki treningowej. Złagodzenie dotyczy jednak *amplitudy*: dla mniejszej architektury monotoniczny trend pozostaje istotny ($\rho \approx 0,8$), choć jego skala spada do poziomu szumu, dlatego mechanizm należy opisywać jako silne złagodzenie, a nie całkowitą eliminację. Wniosek ograniczono do formatu JPEG, do poziomów kompresji znanych z treningu oraz do pojedynczego ziarna ($n = 1$).
7. *Ogólna skuteczność.* F1-macro na poziomie $0,62$ – $0,68$ oraz mAP $0,62$ – $0,66$ stanowią solidny wynik dla wieloetykietowej klasyfikacji 26 klas przy 1000 obrazów treningowych. Hamming accuracy na poziomie $0,87$ – $0,90$ pokazuje, że model poprawnie przewiduje większość pojedynczych pozycji w wektorze etykiet.

10 Podsumowanie

W niniejszej pracy przeprowadzono badanie wpływu kompresji stratnej obrazów angiografii wieńcowej na skuteczność dwóch architektur głębokiego uczenia (ResNet-50, EfficientNet-B0) w zadaniu wieloetykietowej klasyfikacji 26 segmentów naczyniowych według schematu SYNTAX Score. Zbadano trzy formaty kompresji (JPEG, JPEG2000, AVIF) na trzynastu poziomach Q -równoważnych ($Q \in \{10, 20, \dots, 95, 100\}$), gdzie dla JPEG2000 i AVIF poziom Q definiowany jest poprzez zgodność współczynnika kompresji z JPEG (*matched compression ratio*), uzyskaną algorytmem wyszukiwania binarnego. Przeprowadzono trzy komplementarne eksperymenty: różniące się tym, czy kompresji podlegają dane treninowe (Eksperyment A), czy testowe (Eksperyment B), oraz scenariusz mieszany, w którym model uczono na danych o zróżnicowanej kompresji (Eksperyment C).

Najważniejszym wnioskiem łączącym te eksperymenty jest to, że wpływ kompresji jest **silnie asymetryczny**: szkodzą przede wszystkim te artefakty, których model *nie zetknął* w treningu. Gdy kompresji podlega wyłącznie trening, a test odbywa się na oryginałach (Eksperyment A), skuteczność pozostaje praktycznie niezmieniona nawet przy bardzo silnej kompresji ($CR \approx 107\times$); gdy natomiast model trenowany na oryginałach analizuje obrazy skompresowane (Eksperyment B), pojawia się wykrywalny spadek – dla tej samej pary domen o rząd wielkości większy niż w kierunku odwrotnym, istotny statystycznie dla JPEG i zależny od poziomu kompresji oraz architektury. Eksperyment C zamyka ten obraz: gdy artefakty kompresji celowo wprowadzi się do treningu (mieszanka poziomów Q), spadek dla JPEG niemal zanika, i to bez kosztu na danych oryginalnych. Kompresja nie jest więc dla modelu obojętna; jej szkodliwość zależy jednak nie od samego faktu kompresji, lecz od tego, czy model był na dany typ artefaktów przygotowany w treningu.

10.1 Realizacja celów

Zrealizowano wszystkie cele szczegółowe pracy: (1) porównano trzy formaty kompresji pod kątem jakości obrazu (PSNR/SSIM/CR) z zastosowaniem metodologii dopasowanego współczynnika kompresji, (2) zbadano wpływ kompresji danych treningowych na skuteczność dwóch architektur (Eksperyment A), (3) zbadano wpływ kompresji danych testowych na model trenowany na oryginałach (Eksperyment B), (4) sprawdzono, czy trening na mieszanej kompresji uodparnia model na kompresję danych testowych (Eksperyment C), (5) wyznaczono poziomy kompresji bezpieczne dla skuteczności klasyfikacji, (6) sformułowano rekomendacje praktyczne – przy czym (2)–(3) wsparto pełną analizą statystyczną (Friedman, testy sparowane, korekta Holma, test równoważności TOST, korelacja jakość–skuteczność) z modelem bazowym na PNG jako punktem odniesienia, a (4) analizą opisową (spłaszczenie krzywej spadku, korelacja Spearmana). W odniesieniu do celu (4): przy kompresji danych *treningowych* nie zaobserwowano progu degradacji (dopuszczalna kompresja do $CR \approx 107\times$), natomiast przy kompresji danych *testowych* bez-

bezpiecznym progiem dla JPEG jest $Q \gtrsim 30$, a JPEG2000 i AVIF pozostają odporne nawet przy silniejszej kompresji.

10.2 Rekomendacje praktyczne

Na podstawie uzyskanych wyników można sformułować rekomendacje dla systemów PACS i platform telemedycznych przetwarzających obrazy angiograficzne.

Nie wykazano istotnego wpływu formatu kompresji na skuteczność przy dopasowanym współczynniku kompresji – trzy formaty są statystycznie równoważne w obu architekturach (TOST, $\Delta = \pm 0,02$). O wyborze kodeka mogą zatem decydować względy inżynierskie (kompatybilność ze standardem DICOM, czas kodowania, wsparcie sprzętowe), a nie obawa o skuteczność modelu w badanym zadaniu klasyfikacji segmentów. W praktyce JPEG2000 pozostaje bezpiecznym, zgodnym z DICOM wyborem; AVIF jest atrakcyjną alternatywą (nominalnie najwyższa średnia i najmniejszy rozrzut, choć różnice nieistotne statystycznie), mimo braku standaryzacji w DICOM; JPEG pozostaje akceptowalny dzięki prostocie i powszechnemu wsparciu sprzętowemu.

W badanym zakresie dopuszczalna jest agresywna kompresja danych treningowych (do $CR \approx 107\times$) bez wykrywalnego spadku skuteczności na czystym zbiorze testowym, niezależnie od formatu. Trening modeli w domenie skompresowanej jest przy tym bezpieczny pod warunkiem zgodności domeny treningowej i walidacyjnej – skuteczność na czystych danych testowych pozostaje równoważna z modelem bazowym trenowanym wyłącznie na PNG (potwierdzona testem równoważności).

Inaczej przedstawia się scenariusz kompresji danych *wejściowych* w fazie wdrożenia (Eksperyment B). Jeżeli model wytrenowany na obrazach wysokiej jakości ma analizować strumień skompresowany, rekomenduje się **JPEG2000 lub AVIF**, które zachowują skuteczność nawet przy silnej kompresji ($CR \approx 49\times$). **JPEG** jest natomiast bezpieczny jedynie do umiarkowanych poziomów ($Q \gtrsim 30$); przy silniejszej kompresji ($Q \leq 20$) jego artefakty blokowe istotnie obniżają skuteczność, szczególnie dla mniejszej architektury EfficientNet-B0. Najpewniejszym rozwiązaniem pozostaje jednak zachowanie zgodności jakości obrazu między treningiem a wdrożeniem.

10.3 Ograniczenia

- Badanie ograniczone do jednego typu modalności (angiografia rentgenowska) i jednego zbioru danych (ARCADE), co utrudnia generalizację wniosków na inne dziedziny obrazowania medycznego.
- Zadanie SYNTAX Score jest z natury segmentacyjne – niniejsze sformułowanie wieloletykietowe pozwala wykorzystać model klasyfikacyjny, ale nie wykorzystuje pełnej informacji przestrzennej zawartej w maskach segmentacyjnych.

- **Ograniczenia zbioru ARCADE w zakresie pokrycia klas:** jedna z 26 klas ($\text{id}=26$) nie posiada *żadnego* przykładu pozytywnego w żadnym ze splitów, a kolejna ($\text{id}=12$) jest skrajnie rzadka (1 próbka treningowa). F1 i Average Precision są dla klas bez pozytywów nieokreślone, dlatego metryki uśredniane są z pominięciem takich klas w danym splicie (raportowana jest liczba klas faktycznie obecnych). Jest to ograniczenie danych, nie metody, lecz oznacza, że metryki *macro* odnoszą się do podzbioru 24 efektywnie obecnych klas.
- **Pojedyncze ziarno na warunek ($n = 1$)** – to najważniejsze ograniczenie. Każda konfiguracja ($\text{format} \times Q$) wytrenowana została jednokrotnie, bez oszacowania zmienności wewnątrz-warunkowej. Odchylenie standardowe wyników po Q ($\sigma \approx 0,007\text{--}0,012$ mAP) jest tego samego rzędu co badane różnice, więc ewentualny efekt $< 1\text{--}2$ pp jest dla tego planu niewykrywalny. Trening nie jest też w pełni bitowo-reprodukowalny (AMP, niezdeteminizowane jądra CUDA). Wnioski o braku różnic należy więc czytać jako „brak dowodu na efekt”, a nie „dowód braku efektu”; pełne rozstrzygnięcie wymaga powtórzenia z 3–5 ziarnami.
- Analiza statystyczna (Friedman, testy sparowane, Holm, TOST) wykazała brak istotnych różnic i praktyczną równoważność formatów, lecz przy $n = 1$ jej moc jest ograniczona – test wyklucza różnice $\gtrsim 2$ pp, ale nie mniejsze. Granicę równoważności przyjęto jako $\Delta = \pm 0,02$ mAP ($\sim 2 \times$ próg szumu pojedynczego ziarna); węższe progi raportowano jako analizę czułości.
- Implementacja JPEG2000 w bibliotece Pillow (oparta na OpenJPEG) wymagała ręcznej kalibracji parametru `quality_layers` przez wyszukiwanie binarne – wyniki mogą różnić się od profesjonalnych implementacji zgodnych z DICOM.

10.4 Kierunki dalszych badań

- Rozszerzenie treningu na mieszanej kompresji (Eksperyment C) na poziomy Q *nieobecne* w treningu (np. trening na $Q \in \{30, 50, 70\}$, test na $Q = 10$), aby oddzielić rzeczywistą generalizację na artefakty od dopasowania rozkładu treningu do testu. Pozwoliłoby to także sprawdzić, czy uodpornienie przenosi się między formatami (np. trening na JPEG, test na artefaktach AVIF) oraz – przy powtórzeniu z wieloma ziarnami – czy resztkowy trend obserwowany dla EfficientNet-B0 jest realny, czy stanowi szum.
- Powtórzenie eksperymentów z wieloma ziarnami losowymi (3–5) w celu uzyskania przedziałów ufności i odzyskania mocy statystycznej – jedyny sposób rozstrzygnięcia, czy nominalna tendencja AVIF rzędu $\sim 0,5$ pp jest realna, czy stanowi szum.

- Analiza map cech (*feature maps*) za pomocą entropii spektralnej i entropii Shannona w celu zbadania, jak kompresja wpływa na wewnętrzną reprezentację modelu.
- Rozszerzenie badania na zadania segmentacji naczyniowej i detekcji zwężeń, gdzie wpływ kompresji może być bardziej widoczny.
- Walidacja zewnętrzna na drugim zbiorze danych z tej samej dziedziny (np. CADICA, ImageCAS) w celu sprawdzenia, czy wnioski generalizują się poza zbiór ARCADE.

Spis rysunków

1	Jakość kompresji (PSNR, SSIM, współczynnik kompresji) w funkcji poziomu jakości Q dla trzech formatów przy dopasowanym CR. Oś Q odwrócona – kompresja rośnie w prawo.	18
2	Eksperyment A: mAP w funkcji poziomu kompresji Q dla ResNet-50 i EfficientNet-B0; pozioma linia przerywana oznacza model bazowy (PNG). Oś Q odwrócona – kompresja rośnie w prawo.	22
3	Eksperyment A: F1-macro w funkcji poziomu kompresji Q dla obu architektur; pozioma linia przerywana oznacza model bazowy (PNG).	23
4	Skuteczność klasyfikacji (mAP testowe) w funkcji średniej wierności percepcyjnej danych treningowych (PSNR). Brak spójnego dodatniego trendu między architekturami wskazuje, że PSNR/SSIM nie są dobrym predyktorem skuteczności w tym zadaniu.	24
5	Eksperyment B: mAP w funkcji poziomu kompresji <i>zbioru testowego</i> Q (model trenowany na PNG). Linia przerywana – wynik bazowy (test na PNG). Oś Q odwrócona – kompresja rośnie w prawo. W odróżnieniu od Eksperymentu A widoczny jest spadek skuteczności przy silnej kompresji, najsilniejszy dla JPEG.	27
6	Eksperyment C: mAP w funkcji kompresji zbioru testowego dla JPEG – model trenowany na PNG (Eksperyment B, krzywa opadająca) wobec modelu trenowanego na mieszanej kompresji (Eksperyment C, krzywa płaska). Linia przerywana – wynik bazowy (test na PNG). Oś Q odwrócona. Trening mieszany niemal całkowicie likwiduje spadek JPEG.	30

Spis tabel

1	Średnie metryki jakości kompresji dla zadania Syntax (dopasowane CR; wartości uśrednione po 1000 obrazach treningowych). Pełny przebieg na rys. 1.	17
2	Wyniki modeli bazowych: trening, walidacja i test na oryginalnym PNG (zadanie Syntax)	18
3	Eksperyment A, ResNet-50: trening na danych skompresowanych, test na oryginalnym PNG	19
4	Eksperyment A, EfficientNet-B0: trening na danych skompresowanych, test na oryginalnym PNG	20
5	Średnia F1-macro i mAP po wszystkich 13 poziomach Q ($n = 13$) względem modelu bazowego	21

6	Eksperyment B: średnie mAP po 13 poziomach Q ($n = 13$) oraz spadek mAP między $Q = 100$ a $Q = 10$. Model bazowy testowany na obrazach skompresowanych. Wartość bazowa (test na PNG): ResNet-50 mAP = 0,655; EfficientNet-B0 mAP = 0,622.	27
7	Eksperyment C wobec B (mAP): spadek mAP między $Q = 100$ a $Q = 10$ oraz Spearman ρ dla modelu trenowanego na PNG (B) i na mieszanej kompresji (C), a także mAP modelu C na oryginalnym PNG (w nawiasie różnica względem modelu bazowego). PNG nie wchodzi w skład mieszanki treningowej. Wartość bazowa (test na PNG): ResNet-50 0,655; EfficientNet-B0 0,622.	29

Bibliografia

- [1] Alliance for Open Media. (2019). *AV1 Image File Format (AVIF)*. <https://aomediacodec.github.io/av1-avif/>
- [2] Ansari, M. M. (2025). Evaluating Stenosis Detection with Grounding DINO, YOLO, and DINO-DETR. *arXiv preprint arXiv:2503.01601*. <https://arxiv.org/abs/2503.01601>
- [3] Gayet, R., Abd El Al, A., Meyer, A., Hennemuth, A., Ivantsits, M. i Popp, A. (2025). Coronary Tree Segmentation and Labelling in X-ray Angiography Images Using Graph Deep Learning. W *Bildverarbeitung für die Medizin 2025*, 235–240. Springer. https://doi.org/10.1007/978-3-658-47422-5_51
- [4] He, K., Zhang, X., Ren, S. i Sun, J. (2016). Deep Residual Learning for Image Recognition. W *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- [5] National Electrical Manufacturers Association. (2024). *DICOM Standard*. <https://www.dicomstandard.org/>
- [6] Popov, A., Sirazitdinov, I., Illarionova, S., Bochko, V. i Tiulpin, A. (2024). Dataset for Automatic Region-based Coronary Artery Disease Diagnostics Using X-Ray Angiography Images. *Scientific Data*, 11, 20. <https://doi.org/10.1038/s41597-023-02871-z>
- [7] Ren, H., Li, D., Jing, F., Zhang, X., Tian, X., Xie, S., Zhang, E., Wang, R., He, H., He, Y., Xue, Y., Liu, C., Sun, Y. i Cheng, W. (2025). LASF: A Local Adaptive Segmentation Framework for Coronary Angiogram Segments. *Health Information Science and Systems*, 13, 19. <https://doi.org/10.1007/s13755-025-00339-5>
- [8] Taubman, D. i Marcellin, M. (2002). *JPEG2000: Image Compression Fundamentals, Standards and Practice*. Springer. <https://doi.org/10.1007/978-1-4615-0799-4>

- [9] Wang, Z., Bovik, A. C., Sheikh, H. R. i Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>
- [10] Yang, Q., Yi, H., Yi, L., Liu, M. i Chen, X. (2025). Accurate Segmentation and Labeling of Coronary Artery Segments in X-ray Angiography with an Improved UNet-based cGAN Architecture. *Biomedical Signal Processing and Control*. <https://doi.org/10.1016/j.bspc.2025.108812>
- [11] Urbaniak, I. A. (2024). Using Compressed JPEG and JPEG2000 Medical Images in Deep Learning: A Review. *Applied Sciences*, 14(22), 10524. <https://doi.org/10.3390/app142210524>
- [12] Urbaniak, I. A., Vrscaj, E. R., Wang, Z. i Obara, B. (2012). The impact of skull bone intensity on the quality of compressed CT neuro images. W *Proceedings of SPIE Medical Imaging 2012*, 8319, 83190L. <https://doi.org/10.1117/12.912467>
- [13] Tan, M. i Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. W *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 6105–6114. <https://arxiv.org/abs/1905.11946>
- [14] Tajbakhsh, N., Shin, J. Y., Gurudu, S. R., Hurst, R. T., Kendall, C. B., Gotway, M. B. i Liang, J. (2016). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning? *IEEE Transactions on Medical Imaging*, 35(5), 1299–1312. <https://doi.org/10.1109/TMI.2016.2535302>