

Wpływ kompresji obrazu na skuteczność modeli głębokiego uczenia w diagnostyce kardiologicznej

1 Wstęp

Obrazowanie medyczne stanowi fundament współczesnej diagnostyki kardiologicznej. Wraz ze wzrostem liczby wykonywanych badań oraz rozdzielczości obrazów rośnie zapotrzebowanie na efektywne metody przechowywania i przesyłania danych. Kompresja obrazu jest powszechnie stosowanym rozwiązaniem tego problemu, a jej wpływ na jakość obrazu medycznego oraz na skuteczność algorytmów analizy obrazu był przedmiotem licznych badań [11, 12]. Wpływ kompresji na skuteczność automatycznych systemów diagnostycznych opartych na głębokim uczeniu pozostaje jednak niedostatecznie zbadany, w szczególności dla nowszych formatów oraz w zadaniu klasyfikacji segmentów tętnic wieńcowych [11].

W niniejszej pracy zbadano wpływ trzech formatów kompresji – JPEG, JPEG2000 oraz AVIF – na skuteczność dwóch architektur głębokiego uczenia (ResNet-50 i EfficientNet-B0) w zadaniu klasyfikacji segmentów tętnic wieńcowych w obrazach angiografii rentgenowskiej. Każdy obraz angiograficzny zawiera kilka segmentów naczyniowych z różnych klas, dlatego problem sformułowano jako klasyfikację wieloetykietową (*multi-label*). Przeprowadzono Eksperyment A: trening modeli na danych skompresowanych z ewaluacją na oryginałach, dodatkowo zbudowano model bazowy (*baseline*) trenowany na oryginalnych obrazach PNG jako górny punkt odniesienia. Aby zapewnić uczciwe porównanie formatów, zastosowano metodologię *matched compression ratio* – dla każdego obrazu poziom kompresji JPEG2000 i AVIF dobierany jest tak, aby uzyskać identyczny rozmiar pliku jak JPEG przy zadanym parametrze jakości Q . Badania wykonano na zbiorze danych ARCADE zawierającym 1500 obrazów opatrzonych adnotacjami eksperckimi dla zadania klasyfikacji według schematu SYNTAX Score.

2 Motywacja i kontekst pracy

Systemy archiwizacji obrazów medycznych (PACS – *Picture Archiving and Communication System*) oraz platformy telemedyczne wymagają kompresji danych w celu redukcji kosztów przechowywania i przyspieszenia transmisji. Standard DICOM (*Digital Imaging and Communications in Medicine*) dopuszcza stosowanie kompresji stratnej, w tym formatów JPEG i JPEG2000 [5]; co więcej, towarzystwa radiologiczne (m.in. Royal College of Radiologists oraz Canadian Association of Radiologists) opublikowały zalecane współczynniki kompresji stratnej zależne od modalności i okolicy anatomicznej, uznając taką kompresję za diagnostycznie akceptowalną [11]. Brak jest natomiast jednoznacznych wytycznych dotyczących dopuszczalnego poziomu kompresji w kontekście automatycznej analizy z użyciem modeli głębokiego uczenia.

Jednocześnie modele głębokiego uczenia coraz częściej wspomagają diagnostykę chorób tętnic wieńcowych (CAD – *Coronary Artery Disease*), które pozostają główną przyczyną zgonów na świecie. Angiografia rentgenowska jest złotym standardem w diagnostyce CAD, a automatyczna klasyfikacja segmentów naczyniowych według schematu SYNTAX Score umożliwia obiektywną ocenę stopnia zaawansowania choroby.

Pojawienie się nowoczesnego formatu AVIF (opartego na kodeku AV1, 2019 [1]) otwiera nowe możliwości kompresji, lecz jego przydatność w obrazowaniu medycznym nie została dotychczas zbadana. Niniejsza praca wypełnia tę lukę, porównując trzy formaty kompresji pod kątem ich wpływu na modele AI stosowane w kardiologii.

3 Cele i założenia

3.1 Cel główny

Określenie wpływu kompresji stratnej obrazów angiografii rentgenowskiej na skuteczność modeli głębokiego uczenia w zadaniu klasyfikacji segmentów tętnic wieńcowych.

3.2 Cele szczegółowe

1. Porównanie trzech formatów kompresji (JPEG, JPEG2000, AVIF) pod kątem jakości obrazu mierzonej wskaźnikami PSNR i SSIM.
2. Zbadanie wpływu kompresji danych treningowych na skuteczność modelu, mierzoną względem modelu bazowego trenowanego na danych oryginalnych (Eksperyment A).
3. Wyznaczenie optymalnego poziomu kompresji zapewniającego maksymalną redukcję rozmiaru przy minimalnej utracie dokładności klasyfikacji.
4. Sformułowanie rekomendacji dla systemów PACS i platform telemedycznych.

3.3 Hipoteza

Postawiono następujące hipotezy badawcze:

- H1: Format JPEG2000, będący standardem DICOM, zapewnia lepsze zachowanie skuteczności modeli AI niż klasyczny JPEG przy porównywalnym stopniu kompresji.
- H2: Format AVIF, dzięki nowoczesnym technikom predykcji wewnątrzramkowej, zachowuje skuteczność modeli na poziomie co najmniej porównywalnym z JPEG2000 przy tym samym współczynniku kompresji.
- H3: Istnieje progowy poziom kompresji, poniżej którego następuje wyraźny spadek skuteczności klasyfikacji, przy czym próg ten zależy od zastosowanego formatu.
- H4: Model trenowany na danych skompresowanych osiąga skuteczność porównywalną z modelem bazowym trenowanym na oryginalnych danych PNG, jeżeli faza ewaluacji odbywa się na oryginałach – tj. kompresja danych treningowych nie powoduje istotnej utraty informacji diagnostycznej.

4 Zawartość pracy

Praca składa się z następujących rozdziałów. W rozdziale 5 przedstawiono przegląd literatury dotyczącej kompresji obrazów medycznych oraz zastosowań głębokiego uczenia w angiografii wieńcowej. Rozdział 6 zawiera opis zastosowanych metod, modeli i mierników skuteczności. W rozdziale 7 opisano przebieg eksperymentów, strukturę danych oraz kolejne etapy badania. Rozdział 8 prezentuje uzyskane wyniki w formie tabel i wykresów wraz z ich interpretacją. W rozdziale 9 sformułowano wnioski, a w rozdziale 10 dokonano podsumowania pracy.

5 Przegląd literatury

5.1 Kompresja obrazów medycznych

Kompresja obrazów medycznych jest przedmiotem badań od lat 90. XX wieku, a jej wpływ na jakość diagnostyczną oraz na metryki percepcyjne pozostaje aktywnym obszarem badawczym [11, 12]. Wyróżnia się kompresję bezstratną (zachowującą pełną informację) oraz stratną (wprowadzającą nieodwracalne zmiany). W systemach PACS powszechnie stosowany jest format JPEG2000, włączony do standardu DICOM jako jeden z obsługiwanych formatów kompresji stratnej [5].

Format JPEG (Joint Photographic Experts Group) wykorzystuje dyskretną transformatę kosinusową (DCT) operującą na blokach 8×8 pikseli, co przy niskich poziomach jakości prowadzi do charakterystycznych artefaktów blokowych [8]. Format JPEG2000 stosuje transformatę falkową (DWT – *Discrete Wavelet Transform*), operującą na całym obrazie, dzięki czemu eliminuje artefakty blokowe; wprowadza jednak własne zniekształcenia, przede wszystkim rozmycie oraz artefakty typu *ringing* (oscylacje wokół ostrych krawędzi) [8, 12]. Wykazano ponadto, że jakość obrazu skompresowanego falkowo zależy od jego zawartości – np. dla obrazów CT obecność kości o wysokiej intensywności wpływa na jakość rekonstrukcji przy danym współczynniku kompresji [12].

AVIF (*AV1 Image File Format*) jest formatem kompresji obrazu opartym na kodeku wideo AV1, opublikowanym w 2019 roku [1]. Wykorzystuje techniki predykcji wewnątrzramkowej i transformaty, dzięki czemu uzyskuje wyższą efektywność kompresji niż formaty poprzedniej generacji [1].

5.2 Zbiór danych ARCADE

ARCADE (*Automatic Region-based Coronary Artery Disease diagnostics using x-ray angiography images*) jest publicznie dostępnym zbiorem danych opublikowanym w ramach wyzwania MICCAI 2023. Zbiór zawiera 3000 obrazów angiografii rentgenowskiej opatrzonych adnotacjami eksperckimi podzielonych na dwa podzbiory: 1500 obrazów do klasyfikacji segmentów naczyniowych według schematu SYNTAX Score (26 klas) oraz 1500 obrazów do detekcji zwężeń [6].

5.3 Zastosowania głębokiego uczenia w angiografii wieńcowej

W ostatnich latach opublikowano szereg prac wykorzystujących zbiór ARCADE do różnych zadań diagnostycznych. Architektura LASF oparta na YOLOv8 osiągnęła wysoką skuteczność w segmentacji naczyń wieńcowych, przewyższając architektury U-Net i DeepLabV3Plus [7]. Badanie porównawcze architektur detekcji obiektów (Grounding DINO, YOLO, DINO-DETR) wykazało zróżnicowaną skuteczność w detekcji zwężeń [2]. Mo-

del UCNet oparty na warunkowej sieci generatywnej (cGAN) osiągnął średnią miarę F1 84,43% w klasyfikacji 20 segmentów tętnic wieńcowych [10]. Zastosowanie grafowych sieci konwolucyjnych do reprezentacji struktury drzewa wieńcowego pozwoliło na osiągnięcie miary F1 równej 53,68 [3].

Żadna z dotychczasowych prac nie badała jednak wpływu kompresji obrazu na skuteczność modeli klasyfikacji w angiografii wieńcowej, co stanowi istotną lukę badawczą.

6 Materiały i metody

6.1 Formaty kompresji

6.1.1 JPEG

Format JPEG wykorzystuje dyskretną transformatę kosinusową (DCT) stosowaną na blokach 8×8 pikseli. Współczynniki DCT podlegają kwantyzacji sterowanej natywnym parametrem jakości $Q \in [1, 100]$, gdzie wyższe wartości oznaczają mniejszą stratę informacji. Parametr Q jest bezpośrednim argumentem wejściowym kodera JPEG i nie ma odpowiednika w innych formatach. Przy niskich wartościach Q pojawiają się charakterystyczne artefakty blokowe na granicach bloków DCT. Kompresja JPEG jest zawsze stratna – nawet wartość $Q = 100$ wprowadza niewielkie zniekształcenia kwantyzacyjne, wizualnie nierozróżnialne od oryginału.

6.1.2 JPEG2000

Format JPEG2000 wykorzystuje dyskretną transformatę falkową (DWT), operującą na całym obrazie zamiast na blokach. Eliminuje to artefakty blokowe i umożliwia progresywną dekompresję, wprowadza jednak własne zniekształcenia – rozmycie drobnych struktur oraz artefakty typu *ringing* wokół ostrych krawędzi [8, 12]. Format JPEG2000 jest jednym z formatów kompresji stratnej obsługiwanych przez standard DICOM; przedmiotem rekomendacji towarzystw radiologicznych nie jest jednak sam format, lecz dopuszczalne współczynniki kompresji dla poszczególnych modalności, formułowane zarówno dla JPEG, jak i JPEG2000 [11]. JPEG2000 *nie posiada* natywnego parametru Q analogicznego do JPEG – stopień kompresji jest sterowany docelową przepływnością (*rates*) lub liczbą warstw jakościowych (*quality layers*). Format obsługuje zarówno tryb stratny (*irreversible*, transformata 9/7), jak i bezstratny (*reversible*, transformata 5/3).

6.1.3 AVIF

Format AVIF bazuje na kodeku wideo AV1, wykorzystując zaawansowane techniki predykcji wewnątrzramkowej z blokami o zmiennym rozmiarze (od 4×4 do 64×64 pikseli). AVIF *nie posiada* natywnego parametru Q identycznego z JPEG – biblioteka Pillow eksponuje parametr `quality` $\in [0, 100]$, lecz jego skala i mapowanie na bitrate są różne od JPEG, a format obsługuje też tryb bezstratny.

6.1.4 Definicja Q -równoważnego dla JPEG2000 i AVIF

Aby umożliwić uczciwe porównanie trzech formatów na tych samych poziomach kompresji, w niniejszej pracy przyjęto metodologię Q -równoważnego (*Q-equivalent*) opartą

na **dopasowanym współczynniku kompresji** (*matched compression ratio*). Procedura jest następująca:

1. Dla każdego oryginalnego obrazu wyznaczany jest rozmiar jego surowego (nieskompresowanego) bufora pikseli $S_{\text{raw}} = H \cdot W \cdot C$ (8 bitów na próbkę), zgodnie z definicją CR w podrozdziale 6.2.3.
2. Obraz jest kompresowany do JPEG przy natywnym parametrze $Q \in \{10, 20, 30, 40, 50, 60, 70, 75, 80\}$, co daje rozmiar pliku $S_{\text{JPEG}}(Q)$ oraz **referencyjny** współczynnik kompresji $\text{CR}_{\text{ref}}(Q) = S_{\text{raw}}/S_{\text{JPEG}}(Q)$.
3. Dla JPEG2000 i AVIF docelowy rozmiar pliku jest ustalony jako $S_{\text{cel}} = S_{\text{JPEG}}(Q)$. Ponieważ żaden z tych formatów nie pozwala bezpośrednio kontrolować rozmiaru wyjściowego, stosowany jest **algorytm wyszukiwania binarnego** po parametrze sterującym kompresją (odpowiednio: `quality_layers` dla JPEG2000 oraz `quality` dla AVIF), do osiągnięcia $|S_{\text{wyj}} - S_{\text{cel}}|$ poniżej tolerancji 5% lub po 20 iteracjach.
4. Wynikowe pliki JPEG2000 i AVIF mają rozmiar bardzo zbliżony do JPEG przy danym Q , a więc **jednakowy współczynnik kompresji**, co umożliwia bezpośrednie porównanie skuteczności formatów przy ustalonym budżecie pamięciowym.

Etykieta Q stosowana w dalszej części pracy dla JPEG2000 i AVIF **nie odnosi się** zatem do natywnego parametru jakości tych formatów, lecz oznacza *poziom kompresji równoważny JPEG przy parametrze jakości Q* . Wszystkie trzy formaty są w niniejszej pracy stratne dla każdego Q , łącznie z $Q = 100$, ponieważ docelowy rozmiar dla JPEG2000 i AVIF jest dyktowany przez stratny JPEG $Q = 100$ (typowo $\text{CR} \approx 4\times$ względem surowego bufora pikseli). Tryb bezstratny formatów nie jest w niniejszej pracy wykorzystywany.

6.2 Mierniki jakości obrazu

6.2.1 PSNR (Peak Signal-to-Noise Ratio)

Szczytowy stosunek sygnału do szumu wyrażony w decybelach:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right) \quad (1)$$

gdzie MAX_I to maksymalna wartość piksela (255 dla obrazów 8-bitowych), a MSE to średni błąd kwadratowy między obrazem oryginalnym a skompresowanym. Wartości powyżej 40 dB wskazują na bardzo wysoką jakość, wartości 30–40 dB na akceptowalną jakość, natomiast wartości poniżej 30 dB na istotną degradację.

6.2.2 SSIM (Structural Similarity Index Measure)

Wskaźnik podobieństwa strukturalnego [9] porównujący luminancję, kontrast i strukturę:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2)$$

gdzie μ_x , μ_y to średnie, σ_x^2 , σ_y^2 to wariancje, σ_{xy} to kowariancja, a C_1 , C_2 to stałe stabilizacyjne. SSIM przyjmuje wartości z przedziału $[0, 1]$, gdzie 1 oznacza identyczność obrazów.

6.2.3 Współczynnik kompresji

Stosunek rozmiaru nieskompresowanego (surowego) bufora pikseli do rozmiaru pliku skompresowanego:

$$\text{CR} = \frac{S_{\text{raw}}}{S_{\text{skompresowany}}}, \quad S_{\text{raw}} = H \cdot W \cdot C \cdot \frac{\text{bity}}{8} \quad (3)$$

gdzie S_{raw} to rozmiar surowego obrazu w bajtach ($H \times W$ pikseli, C kanałów, 8 bitów na próbkę). Przyjęcie surowego bufora (a nie rozmiaru bezstratnego pliku PNG) jako odniesienia jest zgodne z konwencją ISO 15444 / DICOM i zapewnia, że CR mierzy bezwzględny stopień kompresji informacji obrazowej, niezależnie od formatu źródłowego.

6.3 Sformułowanie problemu: klasyfikacja wieloetykietowa

Każdy obraz w zbiorze ARCADE/Syntax zawiera średnio około pięciu segmentów naczyniowych, należących typowo do różnych klas wśród 26 zdefiniowanych przez schemat SYNTAX Score. Próba sprowadzenia adnotacji do pojedynczej etykiety dominującej (najczęściej występującej) prowadzi do silnie zaszumionego sygnału – analiza adnotacji wykazała, że w 99,3% obrazów zbioru treningowego liczba adnotacji każdej klasy obecnej w obrazie jest taka sama, czyli wybór „dominującej” kategorii rozstrzygany jest arbitralnie kolejnością w pliku adnotacji. Z tego powodu w niniejszej pracy zastosowano sformułowanie **wieloetykietowe** (*multi-label*): etykietą obrazu jest wektor binarny $\mathbf{y} \in \{0, 1\}^{26}$, w którym pozycja k -ta przyjmuje wartość 1 wtedy i tylko wtedy, gdy w obrazie znajduje się przynajmniej jeden segment klasy k .

6.4 Modele klasyfikacji

Do klasyfikacji segmentów tętnic wieńcowych wykorzystano dwie architektury sieci konwolucyjnych: **ResNet-50** [4] oraz **EfficientNet-B0** [13], obie z wagami wstępnie nauczonymi na zbiorze ImageNet. Strojenie sieci wstępnie nauczonych na ImageNet jest standardową i skuteczną strategią w analizie obrazów medycznych, dorównującą lub przewyższającą trening od podstaw, zwłaszcza przy ograniczonej liczbie obrazów treningowych [14].

Warstwa wyjściowa w obu modelach została zastąpiona warstwą w pełni połączoną z 26 neuronami odpowiadającymi klasom SYNTAX Score, bez aktywacji końcowej – prawdopodobieństwa są wyliczane przez funkcję sigmoid w funkcji kosztu.

ResNet-50 [4] jest jedną z najczęściej stosowanych architektur w analizie obrazów medycznych i stanowi powszechnie przyjmowany punkt odniesienia [14]. EfficientNet-B0 [13], mimo pięciokrotnie mniejszej liczby parametrów (5,3 mln wobec 25,5 mln dla ResNet-50), uzyskuje na ImageNet porównywalną dokładność i może być atrakcyjnym wyborem dla zastosowań o ograniczonych zasobach obliczeniowych. Porównanie obu modeli pozwala ocenić, czy wnioski dotyczące wpływu kompresji są niezależne od wyboru architektury.

6.5 Funkcja kosztu i ważenie klas

Z uwagi na znaczne nie zrównoważenie klas w zbiorze ARCADE/Syntax (klasa najczęstsza obecna w 536 obrazach treningowych z 1000, klasa najrzadsza w zaledwie jednym obrazie, a jedna z 26 klas nie występuje w ogóle w zbiorze treningowym) zastosowano funkcję kosztu **Binary Cross-Entropy with Logits** z wagą pozytywną (*pos_weight*) wyliczaną osobno dla każdej z 26 klas jako stosunek liczby próbek negatywnych do pozytywnych w zbiorze treningowym:

$$w_k^+ = \frac{N - n_k^+}{n_k^+}, \quad (4)$$

gdzie n_k^+ to liczba obrazów zawierających klasę k , a N to całkowita liczba obrazów treningowych. Mechanizm ten zwiększa wkład rzadkich klas w funkcję kosztu i przeciwdziała zjawisku, w którym model uczy się przewidywać wyłącznie najczęstsze klasy.

6.6 Mierniki skuteczności klasyfikacji wieloetykietowej

W klasyfikacji wieloetykietowej standardowa dokładność typu top-1 nie jest miarodajna, ponieważ każdy obraz ma kilka prawdziwych etykiet jednocześnie. Zastosowano następujące mierniki obliczane na zbiorze testowym po progowaniu wyjść sigmoidalnych przy wartości 0,5:

6.6.1 F1-macro i F1-micro

Dla każdej klasy k wyznaczana jest miara F1 jako średnia harmoniczna precyzji i czułości. *F1-macro* to nieważona średnia F1 po wszystkich klasach (równa waga każdej klasy, niezależnie od jej liczebności), *F1-micro* agreguje TP, FP i FN globalnie przed wyliczeniem F1 (waga proporcjonalna do liczebności klasy).

6.6.2 Hamming accuracy

Odsetek poprawnie przewidzianych pozycji w wektorze etykiet, uśredniony po wszystkich obrazach i klasach:

$$\text{Hamming acc} = 1 - \frac{1}{N \cdot K} \sum_{i=1}^N \sum_{k=1}^K \mathbb{I}[\hat{y}_{ik} \neq y_{ik}]. \quad (5)$$

6.6.3 Subset accuracy

Odsetek obrazów, dla których wszystkie 26 etykiet zostało przewidzianych poprawnie. Jest to bardzo rygorystyczna miara – wystarczy jedna pomyłka, aby obraz został zaliczony jako błędny. Z uwagi na jej niski poziom i ograniczoną informacyjność (rzędu 0,10–0,14, por. Tabela 2) raportujemy ją jedynie dla modeli bazowych; w analizie porównawczej Eksperymentu A opieramy się na mAP, F1 oraz Hamming accuracy.

6.6.4 mAP (mean Average Precision)

Dla każdej klasy obecnej w zbiorze testowym wyznaczana jest średnia precyzja (AP), będąca polem pod krzywą precyzja–czułość, a zatem niezależna od wyboru progu klasyfikacji; wartości AP są następnie uśredniane makroskopowo po klasach. mAP jest powszechnie stosowaną miarą w zadaniach wieloetykietowych oraz w wyszukiwaniu informacji.

7 Eksperyment

7.1 Schemat eksperymentu

Przeprowadzono badanie składające się z następujących etapów:

1. **Przygotowanie danych** – pobranie zbioru ARCADE (1500 obrazów PNG dla zadania Syntax).
2. **Kompresja JPEG** – wygenerowanie skompresowanych wersji obrazów dla trzynastu poziomów jakości ($Q \in \{10, 20, 30, 40, 50, 60, 70, 75, 80, 85, 90, 95, 100\}$); zapisanie referencyjnego rozmiaru pliku $S_{\text{JPEG}}(Q)$ dla każdego obrazu i poziomu.
3. **Kompresja JPEG2000 i AVIF z dopasowanym CR** – dla każdego obrazu i poziomu Q algorytm wyszukiwania binarnego dobiera parametr sterujący tak, aby wynikowy rozmiar pliku zbliżyć do $S_{\text{JPEG}}(Q)$ (procedura opisana w podrozdziale 6.1.4).
4. **Pomiar jakości kompresji** – obliczenie PSNR, SSIM i współczynnika kompresji dla wszystkich wariantów.
5. **Trening modelu bazowego** – trening ResNet-50 i EfficientNet-B0 na oryginalnych obrazach PNG, walidacja i test również na PNG. Stanowi to górny punkt odniesienia dla Eksperymentu A.
6. **Eksperyment A** – trening modeli na danych skompresowanych z walidacją w tej samej domenie (te same Q i format) oraz ewaluacja końcowa na oryginalnych danych testowych PNG.
7. **Analiza wyników** – porównanie formatów, wyznaczenie wpływu kompresji względem modelu bazowego oraz optymalnego poziomu kompresji.

7.2 Opis danych

Zbiór ARCADE zawiera 3000 obrazów angiografii rentgenowskiej tętnic wieńcowych o rozdzielczości 512×512 pikseli w formacie PNG. Dane podzielone są na dwa zadania:

- **Syntax** (1500 obrazów) – klasyfikacja segmentów naczyń do 26 klas według schematu SYNTAX Score.
- **Stenosis** (1500 obrazów) – segmentacja zwężeń naczyń.

W niniejszej pracy wykorzystano wyłącznie podzbiór Syntax (klasyfikacja 26 klas). Podzbiór Stenosis zawiera adnotacje segmentacyjne wyłącznie jednej kategorii („stenosis”), co uniemożliwia sensowną klasyfikację wieloetykietową.

Zadanie Syntax wykorzystuje podział: trening (1000 obrazów), walidacja (200 obrazów) i test (300 obrazów). Adnotacje zapisane są w formacie COCO JSON. Każdy obraz zawiera zwykle kilka adnotacji segmentacyjnych z różnych klas; dla potrzeb klasyfikacji wieloetykietowej (zob. podrozdział 6.3) etykietę obrazu stanowi 26-elementowy wektor binarny, w którym wartość 1 oznacza obecność co najmniej jednego segmentu danej klasy, a 0 – jej brak.

7.3 Procedura kompresji

Dla każdego z 1500 oryginalnych obrazów PNG zadania Syntax wygenerowano 39 wersji skompresowanych (3 formaty $\times$ 13 poziomów jakości). JPEG kompresowano natywnym parametrem Q (subsampling 4:4:4 dla zachowania pełnej rozdzielczości chrominancji w obrazach medycznych). JPEG2000 i AVIF kompresowano przy użyciu wyszukiwania binarnego po parametrze sterującym, do osiągnięcia rozmiaru pliku odpowiadającego JPEG dla tego samego obrazu i tego samego Q z tolerancją 5% (zob. podrozdział 6.1.4). Kompresję przeprowadzono z wykorzystaniem biblioteki Pillow (JPEG, JPEG2000) oraz wtyczki `pillow-avif-plugin` (AVIF). Wszystkie skompresowane obrazy zostały zapisane na dysku, a następnie ponownie wczytane do macierzy numerycznych w celu obliczenia metryk jakości obrazu.

7.4 Konfiguracja treningu

Parametry treningu identyczne dla obu modeli:

- Architektury: ResNet-50 oraz EfficientNet-B0, obie z wagami wstępnie wytrenowanymi na ImageNet (biblioteka `timm`); ostatnia warstwa zastąpiona warstwą w pełni połączoną o 26 wyjściach
- Funkcja kosztu: `BCEWithLogitsLoss` z per-klasowym `pos_weight` wyliczanym ze zbioru treningowego
- Rozmiar wejścia: 224×224 pikseli (skalowanie z oryginalnych 512×512 , podyktowane wymaganiami modeli wstępnie wytrenowanych na ImageNet)
- Optymalizator: Adam ($\beta_1 = 0,9$, $\beta_2 = 0,999$, $\text{weight decay} = 10^{-4}$)
- Szybkość uczenia: 10^{-4} z harmonogramem cosine annealing
- Wielkość batcha: 16
- Liczba epok: do 50 z wczesnym zatrzymaniem ($\text{patience} = 10$ epok, kryterium: F1-macro na zbiorze walidacyjnym)
- Normalizacja: średnia i odchylenie standardowe ze zbioru ImageNet

- Augmentacja treningowa: losowy obrót ($\pm 15^\circ$) oraz drobne zaburzenia jasności, kontrastu i saturacji ($\pm 0,1$). **Świadomie nie zastosowano odbicia poziomego** – anatomia tętnic wieńcowych jest asymetryczna (lewa tętnica wieńcowa obejmuje segmenty 5–15, a prawa segmenty 1–4), więc odbicie zmieniałoby przypisanie klas.
- Walidacja i test: bez augmentacji, jedynie skalowanie
- Mieszana precyzja (AMP) na karcie GPU z CUDA
- Ziarno losowe: 42 (dla powtarzalności wyników)

Trening i ewaluacja przebiegały zgodnie z zasadą zachowania domeny: model trenowany na obrazach skompresowanych formatem F z poziomem Q jest **walidowany na obrazach z tej samej domeny** (F, Q). Końcowa ewaluacja na zbiorze testowym jest natomiast wykonywana na **oryginalnych obrazach PNG** – pytanie badawcze brzmi: *czy model wytrenowany na obrazach skompresowanych potrafi generalizować na dane wysokiej jakości?*

7.5 Eksperyment A: Trening na danych skompresowanych

W Eksperymentcie A zbadano wpływ jakości danych treningowych na końcową skuteczność modelu. Dla każdego formatu kompresji ($\in \{\text{JPEG}, \text{JPEG2000}, \text{AVIF}\}$), poziomu jakości ($Q \in \{10, 20, 30, 40, 50, 60, 70, 75, 80, 85, 90, 95, 100\}$) oraz architektury ($\in \{\text{ResNet-50}, \text{EfficientNet-B0}\}$) wytrenowano oddzielny model. Łącznie wykonano 78 treningów Eksperymentu A oraz dwa treningi modeli bazowych (po jednym dla każdej architektury), co daje 80 trenowanych modeli.

8 Wyniki


8.1 Jakość kompresji

Pomiary jakości obrazu przeprowadzono na zbiorze treningowym (1000 obrazów $\times$ 13 poziomów $Q \times 3$ formaty). Procedura dopasowanego CR (zob. podrozdział 6.1.4) działa poprawnie: przy każdym poziomie Q wszystkie trzy formaty osiągają niemal identyczny współczynnik kompresji (mediana błędu względem JPEG $\approx 2\text{--}3\%$, w granicach założonej tolerancji 5%). Wyjątkiem jest $Q = 100$: JPEG2000 i AVIF mają fizyczną dolną granicę kompresji stratnej (dla obrazów medycznych o niskiej entropii $\sim \text{CR } 4\text{--}5\times$) i nie osiągają tak dużego pliku jak JPEG $Q = 100$, dlatego punkt $Q = 100$ pozostaje poza ścisłym reżimem dopasowanego współczynnika kompresji i jest podawany jedynie informacyjnie.

Tabela 1 przedstawia średnie metryki jakości (uśrednione po obrazach) dla wybranych poziomów Q . Pełny przebieg PSNR/SSIM/CR w funkcji Q ilustruje rysunek 1. Przy dopasowanym CR nowsze formaty zachowują wyższą wierność: dla każdego Q zachodzi $\text{AVIF} \gtrsim \text{JPEG2000} > \text{JPEG}$ zarówno w PSNR, jak i SSIM (np. przy $Q = 50$, $\text{CR} \approx 32\times$: PSNR 38,8 / 38,4 / 37,1 dB; przy $Q = 95$, $\text{CR} \approx 6,6\times$: 49,6 / 48,9 / 44,2 dB). Uporządkowanie to jest spójne dla średnich i median; dla niewielkiego odsetka ($\sim 2\%$) obrazów o bardzo wysokiej entropii (gęsta tekstura wysokoczęstotliwościowa) transformata falkowa 9/7 JPEG2000 wypada jednak wyraźnie słabiej – jest to znana cecha kodeka, która nieznacznie zaniża jego *średni* PSNR, lecz nie zmienia rankingu formatów.

Tabela 1: Średnie metryki jakości kompresji dla zadania Syntax (dopasowane CR; wartości uśrednione po 1000 obrazach treningowych). Pełny przebieg na rys. 1.

Format	Q	PSNR [dB]	SSIM	CR
JPEG	95	44,2	0,978	6,6 $\times$
JPEG	50	37,1	0,889	32,3 $\times$
JPEG	10	32,4	0,759	107,4 $\times$
JPEG2000	95	48,9	0,992	6,6 $\times$
JPEG2000	50	38,4	0,910	32,4 $\times$
JPEG2000	10	35,7	0,838	107,5 $\times$
AVIF	95	49,6	0,994	6,7 $\times$
AVIF	50	38,8	0,921	32,3 $\times$
AVIF	10	36,1	0,849	107,6 $\times$



Rysunek 1: Jakość kompresji (PSNR, SSIM, współczynnik kompresji) w funkcji poziomu jakości Q dla trzech formatów przy dopasowanym CR. Oś Q odwrócona – kompresja rośnie w prawo.

8.2 Modele bazowe (trening na oryginalnym PNG)

Tabela 2 przedstawia skuteczność modeli trenowanych i ewaluowanych wyłącznie na oryginalnych obrazach PNG. Wartości te stanowią górny punkt odniesienia dla wszystkich wariantów Eksperymentu A.

Tabela 2: Wyniki modeli bazowych: trening, walidacja i test na oryginalnym PNG (zadanie Syntax)

Architektura	F1-macro	F1-micro	mAP	Hamming acc	Subset acc
ResNet-50	0,678	0,780	0,655	0,887	0,143
EfficientNet-B0	0,628	0,784	0,622	0,900	0,103

8.3 Eksperyment A: Wpływ kompresji danych treningowych

W Tabelach 3 i 4 przedstawiono wyniki Eksperymentu A dla obu architektur. Modele trenowane są na obrazach skompresowanych, walidowane w tej samej domenie (te same Q i format), a testowane na oryginalnych PNG (300 obrazów).

Tabela 3: Eksperyment A, ResNet-50: trening na danych skompresowanych, test na oryginalnym PNG

Format	Q	F1-macro	F1-micro	mAP	Hamming acc
JPEG	100	0,669	0,766	0,650	0,876
JPEG	95	0,668	0,764	0,650	0,874
JPEG	90	0,668	0,769	0,646	0,880
JPEG	85	0,669	0,760	0,650	0,871
JPEG	80	0,672	0,781	0,646	0,888
JPEG	75	0,679	0,780	0,666	0,887
JPEG	70	0,661	0,761	0,640	0,873
JPEG	60	0,667	0,770	0,655	0,880
JPEG	50	0,664	0,770	0,651	0,880
JPEG	40	0,665	0,762	0,640	0,874
JPEG	30	0,666	0,751	0,642	0,864
JPEG	20	0,676	0,769	0,646	0,877
JPEG	10	0,670	0,769	0,650	0,881
JPEG2000	100	0,685	0,778	0,661	0,883
JPEG2000	95	0,665	0,780	0,650	0,888
JPEG2000	90	0,676	0,782	0,662	0,888
JPEG2000	85	0,670	0,771	0,649	0,881
JPEG2000	80	0,674	0,775	0,665	0,884
JPEG2000	75	0,669	0,766	0,628	0,877
JPEG2000	70	0,661	0,779	0,650	0,887
JPEG2000	60	0,674	0,774	0,641	0,883
JPEG2000	50	0,683	0,779	0,645	0,884
JPEG2000	40	0,677	0,787	0,643	0,893
JPEG2000	30	0,679	0,784	0,649	0,889
JPEG2000	20	0,670	0,759	0,649	0,870
JPEG2000	10	0,662	0,748	0,632	0,862
AVIF	100	0,676	0,780	0,654	0,886
AVIF	95	0,672	0,775	0,656	0,883
AVIF	90	0,663	0,769	0,642	0,882
AVIF	85	0,664	0,767	0,658	0,879
AVIF	80	0,671	0,778	0,662	0,886
AVIF	75	0,674	0,772	0,660	0,882
AVIF	70	0,668	0,771	0,650	0,881
AVIF	60	0,680	0,782	0,656	0,888
AVIF	50	0,675	0,773	0,648	0,882
AVIF	40	0,687	0,784	0,659	0,888
AVIF	30	0,667	0,763	0,652	0,876
AVIF	20	0,673	0,761	0,649	0,871
AVIF	10	0,663	0,773	0,641	0,884

Tabela 4: Eksperyment A, EfficientNet-B0: trening na danych skompresowanych, test na oryginalnym PNG

Format	Q	F1-macro	F1-micro	mAP	Hamming acc
JPEG	100	0,611	0,739	0,604	0,858
JPEG	95	0,622	0,759	0,612	0,881
JPEG	90	0,639	0,786	0,628	0,901
JPEG	85	0,623	0,779	0,629	0,899
JPEG	80	0,636	0,784	0,632	0,900
JPEG	75	0,606	0,737	0,602	0,869
JPEG	70	0,611	0,775	0,618	0,895
JPEG	60	0,628	0,768	0,617	0,887
JPEG	50	0,621	0,790	0,634	0,904
JPEG	40	0,632	0,780	0,629	0,896
JPEG	30	0,632	0,775	0,634	0,895
JPEG	20	0,627	0,767	0,628	0,884
JPEG	10	0,547	0,743	0,611	0,886
JPEG2000	100	0,623	0,760	0,611	0,880
JPEG2000	95	0,628	0,792	0,627	0,906
JPEG2000	90	0,627	0,788	0,629	0,904
JPEG2000	85	0,636	0,781	0,634	0,897
JPEG2000	80	0,620	0,744	0,610	0,863
JPEG2000	75	0,628	0,785	0,627	0,902
JPEG2000	70	0,629	0,777	0,629	0,897
JPEG2000	60	0,626	0,746	0,613	0,863
JPEG2000	50	0,631	0,778	0,634	0,896
JPEG2000	40	0,633	0,781	0,636	0,896
JPEG2000	30	0,631	0,763	0,625	0,881
JPEG2000	20	0,611	0,784	0,628	0,901
JPEG2000	10	0,622	0,787	0,622	0,899
AVIF	100	0,623	0,784	0,622	0,900
AVIF	95	0,640	0,783	0,629	0,900
AVIF	90	0,628	0,783	0,635	0,898
AVIF	85	0,623	0,781	0,628	0,899
AVIF	80	0,638	0,776	0,629	0,895
AVIF	75	0,633	0,779	0,631	0,897
AVIF	70	0,629	0,780	0,628	0,897
AVIF	60	0,629	0,772	0,621	0,890
AVIF	50	0,620	0,783	0,631	0,897
AVIF	40	0,643	0,784	0,633	0,898
AVIF	30	0,640	0,777	0,630	0,893
AVIF	20	0,639	0,782	0,635	0,899
AVIF	10	0,626	0,756	0,612	0,866

8.3.1 Średnie wartości po formatach

W Tabeli 5 zestawiono średnie po trzynastu poziomach jakości oraz odchylenie standardowe wewnątrz formatu; przebieg F1-macro w funkcji Q dla obu architektur przedstawia rys. 3. Dodatkowo podano różnicę względem modelu bazowego (średnia w obrębie formatu minus wynik modelu bazowego). Wszystkie różnice – zarówno między formatami, jak i względem modelu bazowego – są rzędu pojedynczych punktów procentowych i mieszczą się w zakresie odchylenia standardowego po Q ($\sigma \approx 0,007$ – $0,024$); ich istotność oceniono formalnie w podrozdziale 8.4.

Tabela 5: Średnia F1-macro i mAP po wszystkich 13 poziomach Q ($n = 13$) względem modelu bazowego

Architektura	Format	$\overline{\text{F1-macro}} \pm \sigma$	różnica (F1)	$\overline{\text{mAP}} \pm \sigma$	różnica (mAP)
ResNet-50	model bazowy	0,678	—	0,655	—
ResNet-50	AVIF	$0,672 \pm 0,007$	$-0,007$	$0,653 \pm 0,007$	$-0,002$
ResNet-50	JPEG2000	$0,673 \pm 0,007$	$-0,006$	$0,648 \pm 0,011$	$-0,007$
ResNet-50	JPEG	$0,669 \pm 0,005$	$-0,009$	$0,648 \pm 0,007$	$-0,006$
EfficientNet-B0	model bazowy	0,628	—	0,622	—
EfficientNet-B0	AVIF	$0,632 \pm 0,007$	$+0,003$	$0,628 \pm 0,006$	$+0,006$
EfficientNet-B0	JPEG2000	$0,626 \pm 0,006$	$-0,002$	$0,625 \pm 0,009$	$+0,003$
EfficientNet-B0	JPEG	$0,618 \pm 0,024$	$-0,010$	$0,621 \pm 0,012$	$0,000$

8.3.2 Analiza wyników

Trening na obrazach skompresowanych nie powoduje utraty skuteczności wykrywalnej w tym planie badawczym. Średnia mAP w obrębie każdego formatu różni się od modelu bazowego o nie więcej niż 0,007 (ResNet-50) i 0,006 (EfficientNet-B0), a różnice te są mniejsze niż odchylenie standardowe wyników po Q ($\sigma \approx 0,007$ – $0,012$ dla mAP) i mieszczą się w granicach szumu treningowego.

Zmienność wyników między poziomami Q ma charakter szumu treningu, a nie efektu kompresji. Wynik modelu bazowego (trening i test na PNG) leży wewnątrz rozrzutu wyników modeli trenowanych na danych skompresowanych, a dla kilku poziomów Q modele skompresowane formalnie przewyższają model bazowy (np. EfficientNet-B0/AVIF: średnia mAP 0,628 wobec 0,622 dla modelu bazowego). Ponieważ trening na danych zdegradowanych nie może przyczynowo dać lepszego modelu testowanego na danych czystych, obserwowane fluktuacje pochodzą z losowości pojedynczego treningu (jedno ziarno na warunek, zob. ograniczenia), a nie – wbrew uproszczonej interpretacji – z „efektu regularyzacji przez kompresję”.


Nie obserwuje się monotonicznego trendu skuteczności względem Q . Korelacja mAP z poziomem Q jest słaba i niespójna: dla ResNet-50 dodatnia (Spearman $\rho \leq 0,63$, w większości nieistotna), dla EfficientNet-B0 bliska zeru lub ujemna. Zmiana znaku korelacji

między architekturami wskazuje, że w tym układzie nie istnieje stabilna, wykrywalna zależność między jakością obrazu a skutecznością (rys. 2).


AVIF osiąga nominalnie najwyższą średnią w obu architekturach (mAP 0,653 dla ResNet-50 i 0,628 dla EfficientNet-B0), lecz przewaga ta jest nieistotna statystycznie (po korekcie Holma $p \geq 0,12$) i niespójna między metrykami – dla F1-macro na ResNet-50 nominalnie prowadzi JPEG2000. Stanowi ona zatem co najwyżej drobną tendencję na granicy szumu, a nie dowód przewagi formatu (zob. podrozdział 8.4).

Wniosek o braku istotnej różnicy między formatami jest spójny między architekturami. Mimo pięciokrotnej różnicy w liczbie parametrów oraz silniejszego przeuczenia EfficientNet-B0 (luka trening-walidacja ~ 20 pp), obie architektury prowadzą do tej samej obserwacji jakościowej.

Nie stwierdzono również stabilnego, zależnego od formatu progu degradacji. Pojedyncze spadki (np. EfficientNet-B0/JPEG przy $Q = 10$: F1-macro 0,547) są odosobnionymi punktami mieszczącymi się w rozrzucie pojedynczego ziarna i nie powtarzają się spójnie między architekturami. Przy $N_{\text{test}} = 300$ i $n = 1$ ewentualny próg degradacji rzędu 1–2 pp pozostaje poniżej granicy wykrywalności tego planu badawczego.



Rysunek 2: Eksperyment A: mAP w funkcji poziomu kompresji Q dla ResNet-50 i EfficientNet-B0; pozioma linia przerywana oznacza model bazowy (PNG). Oś Q odwrócona – kompresja rośnie w prawo.



Rysunek 3: Eksperyment A: F1-macro w funkcji poziomu kompresji Q dla obu architektur; pozioma linia przerywana oznacza model bazowy (PNG).

8.4 Analiza statystyczna


Skuteczność formatów porównano w schemacie **sparowanym/blokowym**: poziomy jakości Q stanowią bloki wspólne dla wszystkich trzech formatów (ta sama siatka Q , te same obrazy), więc obserwacje są sparowane względem Q . Zastosowano test omnibus Friedmana (z miarą efektu Kendall's W), a następnie porównania parami sparowanym testem t oraz testem kolejności par Wilcoxona, z korektą Holma-Bonferroniego na wielokrotne porównania. Metryką wiodącą jest mAP (bezprogowa, odporna na nieoptymalność progu 0,5 przy silnym ważeniu klas); F1-macro i Hamming accuracy pełnią rolę pomocniczą.

Test omnibus. Dla mAP test Friedmana nie wykazał istotnych różnic między formatami w żadnej z architektur: ResNet-50 $\chi^2 = 2,00$, $p = 0,37$, $W = 0,08$; EfficientNet-B0 $\chi^2 = 3,23$, $p = 0,20$, $W = 0,12$ (efekt znikomy). Po korekcie Holma żadne z porównań parami nie jest istotne (najniższe skorygowane $p = 0,12$ dla pary AVIF–JPEG na EfficientNet-B0).

Test równoważności (TOST). Brak istotnej różnicy nie jest jeszcze dowodem równoważności, dlatego przeprowadzono dwustronny test równoważności (TOST) dla par formatów. Jako główną granicę równoważności przyjęto $\Delta = \pm 0,02$ mAP (2 pp). Podstawowym uzasadnieniem jest praktyczna nieistotność: różnica skuteczności rzędu 2 punktów procentowych mAP jest pomijalna z punktu widzenia zastosowania wspomagającego decyzję kliniczną. Próg ten jest dodatkowo spójny ze skalą szumu treningowego: odpowiada w przybliżeniu dwukrotności obserwowanego odchylenia standardowego wyników po Q ($\sigma \approx 0,007\text{--}0,012$ mAP), czyli najmniejszej różnicy, którą układ z jednym ziarnem mógłby w ogóle przypisać formatowi, a nie losowości treningu. Przy $\Delta = \pm 0,02$ wszystkie pary formatów są statystycznie równoważne w obu architekturach ($p \leq 0,005$). Jako analizę czułości podano także węższe granice: przy $\Delta = \pm 0,015$ równoważność nadal zachodzi dla wszystkich par ($p \leq 0,013$), a dopiero przy $\Delta = \pm 0,01$ spada do 4 z 6 par (niespełnione

pozostają dwie pary z AVIF, niosące drobną tendencję $\sim 0,5$ pp). Porównanie formatów odnosimy do reżimu dopasowanego CR ($Q = 10\text{--}95$); wykluczenie punktu $Q = 100$ nie zmienia wniosku (Friedman $p = 0,37 / 0,34$; równoważność TOST utrzymana). Należy zaznaczyć, że poziomy Q tworzące pary w teście pochodzą z pojedynczego ziarna treningowego na warunek, więc wynik TOST orzeka równoważność wyłącznie w granicach zmienności wynikającej z siatki Q , nie obejmując zmienności między ziarnami (zob. ograniczenia).

Wierność percepcyjna a skuteczność. Zbadano, czy lepsze metryki jakości obrazu (PSNR/SSIM) przekładają się na skuteczność klasyfikacji (rys. 4). Korelacja mAP z PSNR jest *niespójna między architektuрами*: dla ResNet-50 dodatnia (Spearman $\rho \approx +0,45$ dla danych łączonych), dla EfficientNet-B0 bliska zeru/ujemna ($\rho \approx -0,16$, nieistotna). Gdyby wierność percepcyjna realnie determinowała skuteczność, zależność byłaby dodatnia i spójna w obu architekturach. Brak takiej spójności jest dodatkowym argumentem, że przy dopasowanym CR *wyraźna przewaga JPEG2000/AVIF w PSNR/SSIM nie przekłada się na skuteczność klasyfikacji*, a obserwowana zmienność jest zdominowana przez szum treningu. (Korelacje łączone liczone na $n = 39$ punktach mają charakter opisowy – 13 poziomów Q jest współdzielonych przez formaty, a każda komórka to pojedyncze ziarno.)



Rysunek 4: Skuteczność klasyfikacji (mAP testowe) w funkcji średniej wierności percepcyjnej danych treningowych (PSNR). Brak spójnego dodatniego trendu między architektuрами wskazuje, że PSNR/SSIM nie są dobrym predyktorem skuteczności w tym zadaniu.

Podsumowanie analizy. Główny wynik należy raportować jako *brak dowodu na wpływ formatu kompresji na skuteczność* (a nie „dowód braku różnicy”), wzmocniony pozytywnym wynikiem testu równoważności przy $\Delta = \pm 0,02$ (oraz $\pm 0,015$). Przy pojedynczym ziarnie na warunek ($n = 1$) ewentualny efekt mniejszy niż $\sim 1\text{--}2$ pp jest poniżej granicy wykrywalności.

8.5 Porównanie formatów kompresji

Na podstawie wyników Eksperymentu A oraz porównania z modelami bazowymi można sformułować kilka obserwacji dotyczących porównania formatów.

Formalna analiza nie wykazała istotnych różnic skuteczności między JPEG, JPEG2000 i AVIF przy dopasowanym współczynniku kompresji (test Friedmana: $p = 0,37$ dla ResNet-50 i $p = 0,20$ dla EfficientNet-B0; wszystkie porównania parami nieistotne po korekcie Holma – zob. podrozdział 8.4). Test równoważności (TOST, $\Delta = \pm 0,02$) potwierdza wręcz praktyczną równoważność wszystkich trzech formatów w obu architekturach.

AVIF osiąga najwyższą średnią mAP w obu architekturach oraz nominalnie najmniej rozrzut wyników po Q , jednak wartości te nie zostały potwierdzone formalnie (różnica nieistotna po korekcie Holma; rozrzut nietestowany i na poziomie szumu pojedynczego ziarna), a tendencja jest kierunkowo niespójna między metrykami (dla F1-macro na ResNet-50 prowadzi JPEG2000). Nie uprawnia to do twierdzenia, że AVIF poprawia skuteczność. Z kolei JPEG ma największe odchylenie standardowe F1-macro (na EfficientNet-B0 podbite przez pojedynczy punkt $Q = 10$), lecz nie obserwuje się spójnego, monotonicznego spadku skuteczności przy najsilniejszej kompresji – model trenowany na JPEG $Q = 10$ osiąga wyniki porównywalne z wysokimi Q .

Wniosek o braku istotnej różnicy między formatami jest identyczny dla obu architektur mimo pięciokrotnej różnicy w liczbie parametrów i odmiennego reżimu przeuczenia, co wskazuje, że jest to cecha zadania, a nie pojedynczej architektury. Mimo wyraźnie wyższych wartości PSNR/SSIM dla JPEG2000 i AVIF przy dopasowanym CR przewaga w metrykach percepcyjnych nie przekłada się na skuteczność klasyfikacji (korelacja mAP–PSNR niespójna między architekturami). Przy dopasowanym CR wybór kodeka jest więc raczej decyzją inżynierską (kompatybilność, czas kodowania, wsparcie sprzętowe) niż decyzją wpływającą na jakość diagnostyczną modelu.

9 Wnioski

Na podstawie przeprowadzonych eksperymentów sformułowano następujące wnioski w odniesieniu do postawionych hipotez:

1. *H1 (JPEG2000 a JPEG) – nie potwierdzona.* Średnie skuteczności JPEG2000 i JPEG różnią się o ułamki punktu procentowego, a różnica jest nieistotna statystycznie (sparowany test t i Wilcozona po korekcie Holma, $p > 0,3$ dla mAP w obu architekturach), przy czym test równoważności wskazuje na praktyczną równoważność obu formatów. Nie ma więc danych potwierdzających przewagę JPEG2000 nad JPEG w skuteczności klasyfikacji przy dopasowanym CR – mimo wyraźnie wyższej wierności percepcyjnej (PSNR/SSIM) JPEG2000.
2. *H2 (AVIF) – potwierdzona w sensie równoważności.* AVIF osiąga skuteczność statystycznie równoważną z JPEG2000 i JPEG (TOST, $\Delta = \pm 0,02$). Nominalnie najwyższa średnia AVIF oraz najmniejszy rozrzut wyników po Q nie są jednak istotne statystycznie (rozrzut pozostaje na poziomie szumu pojedynczego ziarna i nie był testowany formalnie) i nie stanowią dowodu przewagi.
3. *H3 (próg degradacji) – nie potwierdzona.* Nie wykryto stabilnego, zależnego od formatu progu degradacji: skuteczność jest w przybliżeniu płaska w całym zakresie Q (10–100), a pojedyncze niskie punkty (np. EfficientNet-B0/JPEG przy $Q = 10$) nie powtarzają się spójnie między architekturami i mieszczą się w rozrzucie pojedynczego ziarna. W badanym zakresie nawet silna kompresja (do CR $\approx 107\times$) zachowuje więc informację istotną dla zadania – lub ewentualny próg leży poniżej granicy wykrywalności tego planu badawczego.
4. *H4 (kompresja a model bazowy) – potwierdzona; główny pozytywny wynik pracy.* Skuteczność modeli trenowanych na danych skompresowanych nie różni się istotnie od modelu bazowego trenowanego na PNG (różnice mAP od $-0,007$ do $+0,006$, w granicach szumu). Przypadki, w których model skompresowany nominalnie przewyższa model bazowy, nie są realnym „efektem regularyzacji”, lecz przejawem szumu pojedynczego ziarna, ponieważ trening na danych zdegradowanych nie może przyczynowo poprawić skuteczności na danych czystych. Poprawnym sformułowaniem wniosku jest zatem brak dowodu na utratę informacji diagnostycznej wskutek kompresji danych treningowych.
5. *Ogólna skuteczność.* F1-macro na poziomie 0,62–0,68 oraz mAP 0,62–0,66 stanowią solidny wynik dla wieloetykietowej klasyfikacji 26 klas przy 1000 obrazów treningowych. Hamming accuracy na poziomie 0,87–0,90 pokazuje, że model poprawnie przewiduje większość pojedynczych pozycji w wektorze etykiet.

10 Podsumowanie

W niniejszej pracy przeprowadzono badanie wpływu kompresji stratnej obrazów angiografii wieńcowej na skuteczność dwóch architektur głębokiego uczenia (ResNet-50, EfficientNet-B0) w zadaniu wieloetykietowej klasyfikacji 26 segmentów naczyniowych według schematu SYNTAX Score. Zbadano trzy formaty kompresji (JPEG, JPEG2000, AVIF) na trzynastu poziomach Q -równoważnych ($Q \in \{10, 20, \dots, 95, 100\}$), gdzie dla JPEG2000 i AVIF poziom Q definiowany jest poprzez zgodność współczynnika kompresji z JPEG (*matched compression ratio*), uzyskaną algorytmem wyszukiwania binarnego.

10.1 Realizacja celów

Zrealizowano cele szczegółowe pracy: (1) ujednolicono porównanie trzech formatów kompresji poprzez metodologię dopasowanego współczynnika kompresji oraz zmierzono PSNR/SSIM/CR na zbiorze treningowym, (2) zbadano wpływ kompresji danych treningowych na skuteczność dwóch architektur modeli (ResNet-50 i EfficientNet-B0), (3) przeprowadzono trening modeli bazowych na PNG jako górny punkt odniesienia, (4) przeprowadzono pełną analizę statystyczną (Friedman, testy sparowane, korekta Holma, test równoważności TOST, korelacja jakość–skuteczność), (5) sformułowano rekomendacje praktyczne. W odniesieniu do celu dotyczącego *optymalnego poziomu kompresji*: w badanym zakresie nie zaobserwowano progu degradacji skuteczności, zatem „optymalny” poziom sprowadza się do wniosku, że dopuszczalna jest agresywna kompresja (do $CR \approx 107\times$) bez wykrywalnej utraty skuteczności na czystym zbiorze testowym.

10.2 Rekomendacje praktyczne

Na podstawie uzyskanych wyników można sformułować rekomendacje dla systemów PACS i platform telemedycznych przetwarzających obrazy angiograficzne.

Nie wykazano istotnego wpływu formatu kompresji na skuteczność przy dopasowanym współczynniku kompresji – trzy formaty są statystycznie równoważne w obu architekturach (TOST, $\Delta = \pm 0,02$). O wyborze kodeka mogą zatem decydować względy inżynierskie (kompatybilność ze standardem DICOM, czas kodowania, wsparcie sprzętowe), a nie obawa o jakość diagnostyczną modelu. W praktyce JPEG2000 pozostaje bezpiecznym, zgodnym z DICOM wyborem; AVIF jest atrakcyjną alternatywą (nominalnie najwyższa średnia i najmniejszy rozrzut, choć różnice nieistotne statystycznie), mimo braku standaryzacji w DICOM; JPEG pozostaje akceptowalny dzięki prostocie i powszechnemu wsparciu sprzętowemu.

W badanym zakresie dopuszczalna jest agresywna kompresja danych treningowych (do $CR \approx 107\times$) bez wykrywalnego spadku skuteczności na czystym zbiorze testowym, niezależnie od formatu. Trening modeli w domenie skompresowanej jest przy tym bezpieczny

pod warunkiem zgodności domeny treningowej i walidacyjnej – skuteczność na czystych danych testowych pozostaje równoważna z modelem bazowym trenowanym wyłącznie na PNG (potwierdzona testem równoważności).

10.3 Ograniczenia

- Badanie ograniczone do jednego typu modalności (angiografia rentgenowska) i jednego zbioru danych (ARCADE), co utrudnia generalizację wniosków na inne dziedziny obrazowania medycznego.
- Zadanie SYNTAX Score jest z natury segmentacyjne – niniejsze sformułowanie wieloetykietowe pozwala wykorzystać model klasyfikacyjny, ale nie wykorzystuje pełnej informacji przestrzennej zawartej w maskach segmentacyjnych.
- **Ograniczenia zbioru ARCADE w zakresie pokrycia klas:** jedna z 26 klas ($\text{id}=26$) nie posiada *żadnego* przykładu pozytywnego w żadnym ze splitów, a kolejna ($\text{id}=12$) jest skrajnie rzadka (1 próbka treningowa). F1 i Average Precision są dla klas bez pozytywów nieokreślone, dlatego metryki uśredniane są z pominięciem takich klas w danym splicie (raportowana jest liczba klas faktycznie obecnych). Jest to ograniczenie danych, nie metody, lecz oznacza, że metryki *macro* odnoszą się do podzbioru 24 efektywnie obecnych klas.
- **Pojedyncze ziarno na warunek ($n = 1$)** – to najważniejsze ograniczenie. Każda konfiguracja ($\text{format} \times Q$) wytrenowana została jednokrotnie, bez oszacowania zmienności wewnątrz-warunkowej. Odchylenie standardowe wyników po Q ($\sigma \approx 0,007\text{--}0,012$ mAP) jest tego samego rzędu co badane różnice, więc ewentualny efekt $< 1\text{--}2$ pp jest dla tego planu niewykrywalny. Trening nie jest też w pełni bitowo-reprodukowalny (AMP, niezdeteminizowane jądra CUDA). Wnioski o braku różnic należy więc czytać jako „brak dowodu na efekt”, a nie „dowód braku efektu”; pełne rozstrzygnięcie wymaga powtórzenia z 3–5 ziarnami.
- Analiza statystyczna (Friedman, testy sparowane, Holm, TOST) wykazała brak istotnych różnic i praktyczną równoważność formatów, lecz przy $n = 1$ jej moc jest ograniczona – test wyklucza różnice $\gtrsim 2$ pp, ale nie mniejsze. Granicę równoważności przyjęto jako $\Delta = \pm 0,02$ mAP ($\sim 2\times$ próg szumu pojedynczego ziarna); węższe progi raportowano jako analizę czułości.
- Implementacja JPEG2000 w bibliotece Pillow (oparta na OpenJPEG) wymagała ręcznej kalibracji parametru `quality_layers` przez wyszukiwanie binarne – wyniki mogą różnić się od profesjonalnych implementacji zgodnych z DICOM.

10.4 Kierunki dalszych badań

- Eksperyment B (trening na danych oryginalnych, test na skompresowanych) – pomiar odporności już wyuczonego modelu na kompresję wejścia w scenariuszach telemedycznych.
- Powtórzenie eksperymentów z wieloma ziarnami losowymi (3–5) w celu uzyskania przedziałów ufności i odzyskania mocy statystycznej – jedyny sposób rozstrzygnięcia, czy nominalna tendencja AVIF rzędu $\sim 0,5$ pp jest realna, czy stanowi szum.
- Analiza map cech (*feature maps*) za pomocą entropii spektralnej i entropii Shannona w celu zbadania, jak kompresja wpływa na wewnętrzną reprezentację modelu.
- Rozszerzenie badania na zadania segmentacji naczyniowej i detekcji zwężeń, gdzie wpływ kompresji może być bardziej widoczny.
- Walidacja zewnętrzna na drugim zbiorze danych z tej samej dziedziny (np. CADICA, ImageCAS) w celu sprawdzenia, czy wnioski generalizują się poza zbiór ARCADE.

Spis rysunków

1	Jakość kompresji (PSNR, SSIM, współczynnik kompresji) w funkcji poziomu jakości Q dla trzech formatów przy dopasowanym CR. Oś Q odwrócona – kompresja rośnie w prawo.	16
2	Eksperyment A: mAP w funkcji poziomu kompresji Q dla ResNet-50 i EfficientNet-B0; pozioma linia przerywana oznacza model bazowy (PNG). Oś Q odwrócona – kompresja rośnie w prawo.	20
3	Eksperyment A: F1-macro w funkcji poziomu kompresji Q dla obu architektur; pozioma linia przerywana oznacza model bazowy (PNG).	21
4	Skuteczność klasyfikacji (mAP testowe) w funkcji średniej wierności percepcyjnej danych treningowych (PSNR). Brak spójnego dodatniego trendu między architekturami wskazuje, że PSNR/SSIM nie są dobrym predyktorem skuteczności w tym zadaniu.	22

Spis tabel

1	Średnie metryki jakości kompresji dla zadania Syntax (dopasowane CR; wartości uśrednione po 1000 obrazach treningowych). Pełny przebieg na rys. 1.	15
2	Wyniki modeli bazowych: trening, walidacja i test na oryginalnym PNG (zadanie Syntax)	16
3	Eksperyment A, ResNet-50: trening na danych skompresowanych, test na oryginalnym PNG	17
4	Eksperyment A, EfficientNet-B0: trening na danych skompresowanych, test na oryginalnym PNG	18
5	Średnia F1-macro i mAP po wszystkich 13 poziomach Q ($n = 13$) względem modelu bazowego	19

Bibliografia

- [1] Alliance for Open Media. (2019). *AV1 Image File Format (AVIF)*. <https://aomediacodec.github.io/av1-avif/>
- [2] Ansari, M. M. (2025). Evaluating Stenosis Detection with Grounding DINO, YOLO, and DINO-DETR. *arXiv preprint arXiv:2503.01601*. <https://arxiv.org/abs/2503.01601>
- [3] Gayet, R., Abd El Al, A., Meyer, A., Hennemuth, A., Ivantsits, M. i Popp, A. (2025). Coronary Tree Segmentation and Labelling in X-ray Angiography Images

- Using Graph Deep Learning. W *Bildverarbeitung für die Medizin 2025*, 235–240. Springer. https://doi.org/10.1007/978-3-658-47422-5_51
- [4] He, K., Zhang, X., Ren, S. i Sun, J. (2016). Deep Residual Learning for Image Recognition. W *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
 - [5] National Electrical Manufacturers Association. (2024). *DICOM Standard*. <https://www.dicomstandard.org/>
 - [6] Popov, A., Sirazitdinov, I., Illarionova, S., Bochkov, V. i Tiulpin, A. (2024). Dataset for Automatic Region-based Coronary Artery Disease Diagnostics Using X-Ray Angiography Images. *Scientific Data*, 11, 20. <https://doi.org/10.1038/s41597-023-02871-z>
 - [7] Ren, H., Li, D., Jing, F., Zhang, X., Tian, X., Xie, S., Zhang, E., Wang, R., He, H., He, Y., Xue, Y., Liu, C., Sun, Y. i Cheng, W. (2025). LASF: A Local Adaptive Segmentation Framework for Coronary Angiogram Segments. *Health Information Science and Systems*, 13, 19. <https://doi.org/10.1007/s13755-025-00339-5>
 - [8] Taubman, D. i Marcellin, M. (2002). *JPEG2000: Image Compression Fundamentals, Standards and Practice*. Springer. <https://doi.org/10.1007/978-1-4615-0799-4>
 - [9] Wang, Z., Bovik, A. C., Sheikh, H. R. i Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>
 - [10] Yang, Q., Yi, H., Yi, L., Liu, M. i Chen, X. (2025). Accurate Segmentation and Labeling of Coronary Artery Segments in X-ray Angiography with an Improved UNet-based cGAN Architecture. *Biomedical Signal Processing and Control*. <https://doi.org/10.1016/j.bspc.2025.108812>
 - [11] Urbaniak, I. A. (2024). Using Compressed JPEG and JPEG2000 Medical Images in Deep Learning: A Review. *Applied Sciences*, 14(22), 10524. <https://doi.org/10.3390/app142210524>
 - [12] Urbaniak, I. A., Vrscaj, E. R., Wang, Z. i Obara, B. (2012). The impact of skull bone intensity on the quality of compressed CT neuro images. W *Proceedings of SPIE Medical Imaging 2012*, 8319, 83190L. <https://doi.org/10.1117/12.912467>
 - [13] Tan, M. i Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. W *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 6105–6114. <https://arxiv.org/abs/1905.11946>

- [14] Tajbakhsh, N., Shin, J. Y., Gurudu, S. R., Hurst, R. T., Kendall, C. B., Gotway, M. B. i Liang, J. (2016). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning? *IEEE Transactions on Medical Imaging*, 35(5), 1299–1312. <https://doi.org/10.1109/TMI.2016.2535302>